

第 1 章 机器究竟怎样“学习”？——经验风险、泛化与归纳偏置


本章目标

本章不从算法清单开始，而从一个更根本的问题开始：**有限训练样本为什么可能支持对未来数据的可靠预测？**学完本章，你应该能够区分经验风险与总体风险，理解 ERM 的逻辑边界，独立推导有限假设类的统一泛化界，并用“假设空间 + 正则化 + 优化动力学”解释为什么零训练误差并不等于学会。

Prerequisite Recall | 先把这些知识唤醒

- 会读期望 $\mathbb{E}[Z]$ 与样本平均 $\frac{1}{n} \sum_i z_i$ ，但暂时不需要测度论。
- 记住随机变量的“总体量”和某一次样本得到的“经验量”不是同一个对象。
- 会使用集合大小 $|\mathcal{H}|$ 、对数和基本概率不等式。

Visual Derivation | 先看结构，再读公式



这张图把本章唯一的核心理念画出来：训练只接触 S ，但评价最终回到 P 。

Misconception Check | 本章最容易掉进去的坑

最常见误解是把“训练误差很小”直接读成“泛化很好”。反例只需要一个有限训练集：构造一个在训练点上完全一致、在训练点外任意振荡的函数。**零训练误差只说明你解释了已经看到的数据；泛化还需要复杂度、数据假设和归纳偏置。**

Concept Contrast | 把相邻概念主动分开

	经验风险 $\hat{R}_S$	总体风险 R
数据来源	已看到的有限样本	未知分布 P
可直接计算?	是	通常否
优化器直接最小化?	通常是	通常不是
主要问题	优化	统计泛化

Checkpoint | 开始正文前的 30 秒自测

不看正文回答：为什么 Hoeffding 对“固定 h ”成立以后，还不能直接证明 ERM 输出会泛化？

检查答案：因为 $\hat{h}$ 是看过 S 之后选择的；需要让偏差界对算法可能选择的所有 h 同时成立。

1.1 学习问题的四个对象：分布、假设、损失与数据

设输入空间为 $\mathcal{X}$ ，输出空间为 $\mathcal{Y}$ 。现实世界持续产生随机样本

$$(X, Y) \sim P,$$

其中 P 是未知的联合分布。训练集

$$S = \{(x_i, y_i)\}_{i=1}^n \sim P^n$$

只是从这个分布独立抽取的有限观察。模型不是“数据本身”，而是从某个假设空间 $\mathcal{H}$ 中选择的函数 $h: \mathcal{X} \rightarrow \mathcal{Y}$ 。最后还需要损失函数 $\ell(h(x), y)$ 定义预测错得有多严重。

定义 1.1 (总体风险与经验风险). 给定假设 h ，其总体风险 (population risk) 为

$$R(h) = \mathbb{E}_{(X,Y) \sim P}[\ell(h(X), Y)].$$

给定训练集 S ，经验风险 (empirical risk) 为

$$\hat{R}_S(h) = \frac{1}{n} \sum_{i=1}^n \ell(h(x_i), y_i).$$

这两个量长得几乎一样，却承担完全不同的角色。 $R(h)$ 是真正想优化的目标，但因为 P 未知而无法精确计算； $\hat{R}_S(h)$ 可以计算，却只是随机样本上的估计。机器学习最核心的张力之一，就是用一个可观察的随机量去控制一个不可观察的总体量。

把“训练”与“学习”分开

若优化器把 $\hat{R}_S(h)$ 从 1.0 降到 10^{-6} ，我们只能说“训练目标被优化好了”。要说“模型学会了”，还需要说明 $R(h)$ 也小。前者主要是优化问题，后者还包含统计估计与归纳偏置问题。现代大模型经常把训练损失压得非常平滑，但真正关心的能力、鲁棒性、事实性或安全性并不会与训练损失一一同步。

1.2 经验风险最小化：一行公式背后的假设

最基本的学习原则是经验风险最小化：

$$\hat{h} \in \arg \min_{h \in \mathcal{H}} \hat{R}_S(h).$$

若使用参数化模型 $h = f_\theta$ ，则写成

$$\hat{\theta} \in \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \ell(f_\theta(x_i), y_i).$$

线性回归、逻辑回归、神经网络、语言模型都可以放进这个形式。真正改变的是 f_θ 、 ℓ 、数据结构以及优化过程。

例 1.1 (同一个训练集, 无穷多个完美解释). 四个点 $(0, 0), (1, 1), (2, 4), (3, 9)$ 被 $h(x) = x^2$ 完美拟合。但任取一个多项式 $q(x)$ ，只要

$$q(0) = q(1) = q(2) = q(3) = 0,$$

那么 $h_c(x) = x^2 + cq(x)$ 对所有 c 都有零训练误差。有限数据本身不能告诉我们哪一个函数才是未来最可靠的延伸。

这说明“从数据学习”从来不可能完全没有先验。函数类的选择、网络结构、参数化、正则化、初始化、优化器乃至训练停止时间都会形成**归纳偏置** (inductive bias)。

1.3 泛化差距：测试误差从哪里来

对算法 A ，训练集 S 决定输出 $h_S = A(S)$ 。此时

$$R(h_S) = \hat{R}_S(h_S) + \underbrace{(R(h_S) - \hat{R}_S(h_S))}_{\text{generalization gap}}.$$

要注意： h_S 本身依赖 S ，所以不能简单地把固定函数上的“大数定律”直接套在学习算法输出上。我们需要控制“在整个假设空间中，经验风险和总体风险能否同时接近”。

1.4 从 Hoeffding 不等式到统一泛化界

为了第一次看到严格的泛化证明，我们先处理一个足够简单但结构完整的场景： $\mathcal{H}$ 有限，损失取值在 $[0, 1]$ 。

定理 1.1 (Hoeffding 不等式的学习版本). 固定与训练集无关的 h 。若 $0 \leq \ell(h(X), Y) \leq 1$ ，则对任意 $\epsilon > 0$ ，

$$\mathbb{P}(|R(h) - \hat{R}_S(h)| \geq \epsilon) \leq 2e^{-2n\epsilon^2}.$$

这个结论只控制一个固定 h 。但 ERM 会“看完数据再选 h ”，因此我们需要对所有 $h \in \mathcal{H}$ 同时成立。使用 union bound：

$$\mathbb{P}(\exists h \in \mathcal{H} : |R(h) - \hat{R}_S(h)| \geq \epsilon) \leq 2|\mathcal{H}|e^{-2n\epsilon^2}.$$

令右侧等于 δ ，解出 ϵ ：

$$\epsilon = \sqrt{\frac{\log(2|\mathcal{H}|/\delta)}{2n}}.$$

定理 1.2 (有限假设类的统一收敛界). 若 $|\mathcal{H}| < \infty$ 且损失在 $[0, 1]$ ，则以至少 $1 - \delta$ 的概率，对所有 $h \in \mathcal{H}$ 同时有

$$|R(h) - \hat{R}_S(h)| \leq \sqrt{\frac{\log(2|\mathcal{H}|/\delta)}{2n}}.$$

证明思路 | 为什么这个证明值得记住？

后面你会遇到 VC dimension、Rademacher complexity、PAC-Bayes、compression bound。技术细节会变，但逻辑骨架经常仍然是：**先控制固定对象的随机偏差，再为“算法可能选择的所有对象”支付复杂度代价**。研究者真正争论的是：怎样定义一个既可证明、又能解释深网实际泛化的“有效复杂度”。

1.5 ERM 的超额风险界

设

$$h^* \in \arg \min_{h \in \mathcal{H}} R(h), \quad \hat{h} \in \arg \min_{h \in \mathcal{H}} \hat{R}_S(h).$$

若事件

$$\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_S(h)| \leq \epsilon$$

成立，则

$$\begin{aligned} R(\hat{h}) &\leq \hat{R}_S(\hat{h}) + \epsilon \\ &\leq \hat{R}_S(h^*) + \epsilon \\ &\leq R(h^*) + 2\epsilon. \end{aligned}$$

因此

$$R(\hat{h}) - \inf_{h \in \mathcal{H}} R(h) \leq 2\epsilon.$$

这三行是学习理论中非常重要的一种“夹逼”：第一、三步来自统一收敛，第二步来自 ERM 的定义。

样本复杂度怎样读？

若想让统一偏差不超过 ϵ ，置信度至少 $1 - \delta$ ，则足够要求

$$n \gtrsim \frac{\log |\mathcal{H}| + \log(1/\delta)}{\epsilon^2}.$$

这不是说真实神经网络只需要把“参数个数”塞进 $|\mathcal{H}|$ 。恰恰相反：深网的参数空间连续巨大，简单的 worst-case 容量往往给出极松的界，这也是现代泛化理论仍活跃的原因。

1.6 误差分解：先分清“恒等分解”与“非负误差”

令 $h_{\mathcal{H}}^* \in \arg \min_{h \in \mathcal{H}} R(h)$, $\hat{h} \in \arg \min_{h \in \mathcal{H}} \hat{R}_S(h)$, h_T 为训练 T 步后的实际输出。恒等式

$$R(h_T) - R(h_{\text{Bayes}}) = \underbrace{R(h_{\mathcal{H}}^*) - R(h_{\text{Bayes}})}_{\text{approximation}} + \underbrace{R(\hat{h}) - R(h_{\mathcal{H}}^*)}_{\text{estimation term}} + \underbrace{R(h_T) - R(\hat{h})}_{\text{algorithmic remainder}}$$

总是成立，但后三项并不都是非负的“误差”。特别地， $\hat{h}$ 只保证经验风险最小；early stopping 或显式正则化得到的 h_T 完全可能有 $R(h_T) < R(\hat{h})$ ，此时最后一项为负。若要定义非负的 optimization gap，更稳妥的是使用训练目标

$$\hat{R}_S(h_T) - \inf_{h \in \mathcal{H}} \hat{R}_S(h) \geq 0$$

(若训练含正则项，则应对完整训练目标定义 gap)。这个区分避免把“训练问题没有完全解完”和“总体风险比 ERM 更差”误认为同一件事。

1.7 正则化：把偏好写进目标函数

最常见的显式正则化写成

$$\min_{\theta} \hat{R}_S(\theta) + \lambda \Omega(\theta).$$

当 $\Omega(\theta) = \frac{1}{2} \|\theta\|_2^2$ 时得到 L_2 正则或 ridge 型目标。正则化有两个互补解释：其一，它限制或惩罚复杂参数；其二，它改变优化动力学，使不同方向以不同速度衰减。

岭回归闭式解与谱滤波

对

$$L(w) = \frac{1}{2n} \|Xw - y\|_2^2 + \frac{\lambda}{2} \|w\|_2^2,$$

令梯度为零得到

$$\left(\frac{1}{n} X^\top X + \lambda I \right) w = \frac{1}{n} X^\top y.$$

若 $X = U\Sigma V^\top$ ，则

$$\hat{w}_\lambda = V \operatorname{diag} \left(\frac{\sigma_j}{\sigma_j^2 + n\lambda} \right) U^\top y.$$

所以 ridge 不是“统一缩小所有方向”，而是一个**依赖奇异值的谱滤波器**：小奇异值方向被压制得更强。这将在第 2 章和第 5 章再次出现。

1.8 双下降、插值与现代大模型的反直觉

经典偏差-方差图常被画成一条 U 形曲线：模型越复杂，训练误差下降，但测试误差先降后升。现代过参数化模型却经常进入插值区，即训练误差接近零后，继续增加模型规模反而再次改善测试表现，形成 double descent。这个现象并不证明“过拟合不存在”，而是说明“参数量”不是足够细的复杂度变量。

同理，LLM 的参数数目巨大，却受到参数共享、token 分布、优化器、归一化、数据多样性和训练预算等共同约束。研究中更重要的问题已经从“参数多不多”转向“训练过程实际偏向了什么函数”。




图 1.1 训练风险与测试风险没有必然的单调对应关系。图是概念示意，不代表普适定律。

1.9 Research Frontier: Grokking 为什么可以在线性模型里出现？

Research Frontier | To Grok Grokking: Provable Grokking in Ridge Regression

会议身份：ICML 2026 Outstanding Paper Honorable Mention。作者 Mingyue Xu、Gal Vardi、Itay Safran。

核心问题：Grokking 常被描述为“模型先记住训练集，过很久才突然泛化”。它是否必须依赖深层网络的复杂 feature learning？该工作证明：不必。在线性、过参数化的 ridge regression 中，梯度下降配合 weight decay 已可以出现完整的“先过拟合、长时间泛化差、最终泛化好”的三阶段过程，并给出 generalization delay 与超参数相关的定量界。

一个关键几何分解是把参数拆成训练数据行空间中的 $\theta_{\parallel}$ 和其正交补中的 $\theta_{\perp}$ 。经验损失只直接“看见” $\theta_{\parallel}$ ；在零教师等简化设置中，正交补主要依赖 weight decay 缓慢衰减。于是训练误差可以按由数据谱控制的较快时间尺度下降，而总体误差仍被 $\theta_{\perp}$ 长时间拖住。论文进一步表明，小 weight decay 可以显著放大 grokking delay。

研究方法论：看到复杂现象时，先问“最小到什么模型，这个现象仍然存在？”若能在可解析系统中保留机制，研究就从现象描述推进到了因果结构。

官方奖项：ICML 2026 Awards；**论文：**[arXiv:2601.19791](https://arxiv.org/abs/2601.19791)。




图 1.2 机制级复现实验：训练可见的快方向迅速衰减，而总体风险还包含只由弱 weight decay 控制的慢方向，因此出现很长的“训练已经很好、泛化仍然差”的时间窗口。

Mini Lab | Frontier Replication 1: 两时间尺度到 ridge grokking

运行 `labs/frontier/ch01_spectral_grokking.py`。第一层任务是在 CPU 上复现图中的 $t_2 \gg t_1$ ；第二层任务是改变 λ ，验证慢方向的时间尺度近似与 $1/(\eta\lambda)$ 同阶；第三层任务是真正实现 $m > n$ 的随机线性回归，将 θ 显式分解到 $\text{row}(X)$ 与 $\mathcal{N}(X)$ ，比较两部分范数随时间衰减的速度。最后再尝试复现论文中“减小 weight decay 放大 grokking delay”的趋势。

From Textbook to Research | 从教材问题走向研究问题

现在你已经可以提出比“为什么会过拟合”更精确的问题：**哪些参数方向控制训练误差，哪些方向只影响总体误差？这些方向的动力学时间尺度由数据谱、正则化和初始化怎样共同决定？**这类问题会在第 2 章用子空间语言被重新表达，在第 5 章用优化谱分析被重新表达。

1.10 Deep Dive: 从统一收敛走到连续假设空间

有限 $|\mathcal{H}|$ 的界很干净，但神经网络参数连续，因此不能直接使用 $\log |\mathcal{H}|$ 。一个自然策略是寻找“函数类能在样本上产生多少种不同响应”的复杂度。

1.10.1 VC dimension 的核心直觉

对二分类函数类 $\mathcal{H} \subseteq \{0, 1\}^{\mathcal{X}}$ ，如果存在 d 个点，使得 2^d 种二进制标记都能由 $\mathcal{H}$ 中某个函数实现，就说这 d 个点被 $\mathcal{H}$ shatter。最大的这类 d 就是 VC dimension。它衡量的不是参数数目，而是**函数类在任意有限点集上制造标记模式的能力**。

对线性分类器， $\mathbb{R}^d$ 中带偏置的超平面 VC dimension 为 $d + 1$ 。因此即使参数连续无限，统计复杂度仍可以是有限的。深网的 worst-case VC dimension 通常仍然很大，所以它更多提供“可学习性存在”的理论基线，而不一定解释现代网络的实际样本效率。

1.10.2 Rademacher complexity: 让复杂度依赖真实样本

给定样本 $x_1, \dots, x_n$ ，经验 Rademacher complexity 定义为

$$\hat{\mathfrak{R}}_S(\mathcal{F}) = \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \sigma_i f(x_i) \right],$$

其中 σ_i 独立地取 ± 1 。直觉上，它问函数类能多好地拟合一组纯随机符号。如果一个函数类连随机噪声都能轻松追随，那么仅凭训练误差很难相信它会泛化。

命题 1.1 (线性函数类的一个 Rademacher 上界). 令

$$\mathcal{F} = \{x \mapsto w^\top x : \|w\|_2 \leq B\}, \quad \|x_i\|_2 \leq R.$$

则

$$\hat{\mathfrak{R}}_S(\mathcal{F}) \leq \frac{BR}{\sqrt{n}}.$$

证明. 由 Cauchy-Schwarz,

$$\begin{aligned} \hat{\mathfrak{R}}_S(\mathcal{F}) &= \mathbb{E}_\sigma \sup_{\|w\| \leq B} \left\langle w, \frac{1}{n} \sum_i \sigma_i x_i \right\rangle \\ &= B \mathbb{E}_\sigma \left\| \frac{1}{n} \sum_i \sigma_i x_i \right\|_2 \\ &\leq \frac{B}{n} \sqrt{\mathbb{E}_\sigma \left\| \sum_i \sigma_i x_i \right\|_2^2} \\ &= \frac{B}{n} \sqrt{\sum_i \|x_i\|_2^2} \leq \frac{BR}{\sqrt{n}}. \end{aligned}$$

关键一步使用了 $\mathbb{E}[\sigma_i \sigma_j] = 0$ ($i \neq j$)。 □

这个结果揭示了为什么“参数范数”和“输入尺度”会自然进入很多泛化界。它也解释了正则化为什么不仅是数值技巧：限制 $\|w\|$ 会直接压缩函数类在样本上的可变性。

1.11 Deep Dive: 算法稳定性视角

另一条路线不直接度量整个函数类，而问：**删掉或替换一个训练样本，算法输出会变化多少？** 如果学习算法对单个样本扰动非常稳定，那么训练损失就更可能代表总体损失。

设 S 与 $S^{(i)}$ 只在第 i 个样本不同。若对所有测试点 z 都有

$$|\ell(A(S), z) - \ell(A(S^{(i)}), z)| \leq \beta,$$

则称算法具有 uniform stability β 。强凸正则化问题中， β 往往随 $1/(\lambda n)$ 下降。这给出另一种解释： L_2 正则不仅缩小参数，也使学习器对单个样本更不敏感。

1.12 Deep Dive: PAC-Bayes 为什么适合“训练后模型”

经典容量界常问整个函数类有多大，而 PAC-Bayes 考虑参数上的先验分布 P 与训练后后验 Q ，复杂度由

$$D_{\text{KL}}(Q \| P)$$

衡量。一个典型 PAC-Bayes 界的结构是

$$R(Q) \lesssim \hat{R}_S(Q) + \sqrt{\frac{D_{\text{KL}}(Q\|P) + \log(1/\delta)}{n}}.$$

这里 $R(Q)$ 表示先从 Q 抽模型再预测的风险。重要的不是某个具体常数，而是它把“离先验走了多远”作为复杂度。对于大模型，这启发了一个很自然的问题：**参数虽然很多，但训练真正编码进去了多少与数据相关的信息？**

1.13 Deep Dive: Grokking 的子空间机制推导

考虑零教师线性回归，设计矩阵 $X \in \mathbb{R}^{n \times m}$ 且 $m > n$ 。目标

$$L(w) = \frac{1}{2n} \|Xw\|_2^2 + \frac{\lambda}{2} \|w\|_2^2.$$

把 w 唯一分解为

$$w = w_{\parallel} + w_{\perp}, \quad w_{\parallel} \in \text{row}(X), \quad w_{\perp} \in \mathcal{N}(X).$$

因为 $Xw_{\perp} = 0$ ，训练误差只由 $w_{\parallel}$ 决定。梯度下降更新

$$w_{t+1} = \left(I - \eta \frac{X^{\top} X}{n} - \eta \lambda I \right) w_t.$$

于是两个子空间解耦：

$$w_{\perp, t+1} = (1 - \eta \lambda) w_{\perp, t},$$

而行空间中的每个奇异向量方向 v_j 按

$$1 - \eta(\sigma_j^2/n + \lambda)$$

衰减。只要 σ_j^2/n 明显大于 λ ，训练可见方向就比零空间方向快得多。**这就是一个清晰的时间尺度分离机制。**

请注意：这里的推导只是论文完整理论的教学化切片。真实 theorem 还需要对总体协方差、初始化随机性、非零教师和有限样本误差做严格控制。

分层训练 | A 基础层

1. 从 union bound 重新推导有限假设类统一泛化界。
2. 若 $|\mathcal{H}| = 10^6$ 、 $\delta = 0.05$ 、希望 $\text{gap} \leq 0.05$ ，使用本章 Hoeffding 界估算所需样本量。
3. 解释“训练误差为零”为什么既不是泛化的充分条件，也不是必要条件。

分层训练 | B 推导层

1. 完成线性函数类 Rademacher complexity 上界的每一步。
2. 对 ridge regression 的闭式解做 SVD 展开，并画出滤波因子 $\sigma/(\sigma^2 + n\lambda)$ 随 σ 的变化。
3. 在零教师子空间分解中，推导 $\|w_{\perp,t}\|_2$ 达到初始值 ρ 倍所需的步数。

分层训练 | C 研究层

1. 固定 m/n ，扫描 λ 与初始化方差，定义一个可测的 grokking gap $t_2 - t_1$ ，画 phase diagram。
2. 把 squared loss 换成 logistic loss：训练数据可分时，是否还能得到同样的子空间时间尺度解释？
3. 尝试把“训练可见子空间”推广到神经网络的局部 NTK/Jacobian 子空间，并说明这种推广可能在哪里失效。

1.14 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

本章的风险/泛化语言将直接在第 6 章的线性模型、第 15 章的 scaling 与第 18 章的后训练中复用。

Worked Example | 统一收敛界到底在为谁付费？

考虑二分类假设类 $|\mathcal{H}| = 1000$ 、 $n = 2000$ 、 $\delta = 0.05$ 。由定理 1.2，统一偏差上界为

$$\epsilon = \sqrt{\frac{\log(2|\mathcal{H}|/\delta)}{2n}} \approx 0.0515.$$

若 ERM 的训练错误率是 0.08，则这个最粗的界只能保证 $R(\hat{h}) \lesssim 0.1315$ 。关键不是数值紧不紧，而是看清 $\log |\mathcal{H}|$ 来自“看完数据以后再选模型”的选择自由。

Proof Clinic | ERM 超额风险三行证明

令事件 $\sup_h |R(h) - \hat{R}(h)| \leq \epsilon$ 成立。逐行标注依据：

$$R(\hat{h}) \stackrel{(a)}{\leq} \hat{R}(\hat{h}) + \epsilon \stackrel{(b)}{\leq} \hat{R}(h^*) + \epsilon \stackrel{(c)}{\leq} R(h^*) + 2\epsilon.$$

(a)(c) 是统一收敛，(b) 是 ERM 定义。这个 proof pattern 后面会反复出现：真实目标 $\rightarrow$ 可观测代理 $\rightarrow$ 比较基准 $\rightarrow$ 回到真实目标。

Research Assignment | 把泛化曲线变成可证伪实验

使用现有 grokking lab, 固定数据分布与初始化族, 报告不少于 5 个随机种子。必须预先定义 training threshold、generalization threshold 和 delay; 主图之外提交一张 phase diagram, 并写出至少一个能推翻自己机制解释的对照实验。

最低交付: 1 页假设与指标声明; 可复现代码与固定 seed; 主结果图; 至少一个失败/反例; 200–400 字结论边界。**禁止:** 只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. 论文把 grokking 的“先拟合、后泛化”分别用哪两个时间 t_1, t_2 操作化? 为什么必须先定义可测阈值?
2. 零空间分量为什么不影响训练损失, 却可以继续影响总体风险? 这依赖怎样的总体协方差假设?
3. 小 weight decay 为什么会延长慢方向衰减时间? 它是否同时改变最终解?
4. 论文中的理论是 worst-case、high-probability 还是 expectation 结论? 实验能验证哪一部分, 不能验证哪一部分?
5. 如果在另一个非线性网络中也观察到类似曲线, 什么证据才能支持“同一机制”, 而不仅是“同一外观”?

本章小结

本章建立了全书第一根理论支柱: 学习不是“把训练误差降下来”, 而是在未知分布上控制总体风险。ERM 提供优化接口, 统一收敛解释有限数据怎样约束函数类, 正则化与优化路径提供归纳偏置, 而 grokking 告诉我们训练与泛化甚至可能发生在完全不同的时间尺度。下一章将把“假设空间”进一步几何化: 模型到底在什么向量空间里表示、保持和修改信息?