

第 2 章 向量、矩阵与子空间——表示学习的几何语言


本章目标

本章把线性代数从“矩阵计算技巧”升级为表示学习的语言。我们关心的不只是怎样乘矩阵，而是：一个表示保留了哪些方向？哪些方向被压缩到零？低秩意味着什么？投影为什么能保护知识？学完后，你应该能够从列空间、零空间、SVD 与投影的角度解释 least squares、PCA、LoRA、embedding 检索以及 AlphaEdit 的核心约束。

Prerequisite Recall | 先把这些知识唤醒

- 会计算向量点积、矩阵乘法和转置。
- 知道“矩阵的列”与“矩阵表示的线性映射”是两个视角。
- 能区分距离 $\|x - y\|$ 与内积 $x^T y$ 。

Visual Derivation | 先看结构，再读公式



最小二乘、PCA、低秩编辑都会反复使用同一个动作：**把向量拆成“保留的子空间分量 + 正交残差”**。

Misconception Check | 本章最容易掉进去的坑

“低秩”不是“矩阵里很多元素为 0”。一个完全稠密的矩阵也可以 rank 1，例如 uv^T 。低秩描述的是**独立方向少**，稀疏描述的是**非零元素少**；两者是不同结构。

Concept Contrast | 把相邻概念主动分开

	子空间/低秩	稀疏性
约束对象	方向数、维数	非零坐标数
常用工具	SVD、投影	L_1 、support
LLM 例子	low-rank logits / LoRA	sparse attention / MoE routing

Checkpoint | 开始正文前的 30 秒自测

若 P 是到子空间 U 的正交投影，为什么一定有 $P^2 = P$ ？**检查答案：**第一次投影后的向量已经在 U 中，第二次投影不再改变它。

2.1 表示：从对象到坐标

一个向量 $x \in \mathbb{R}^d$ 的本质不是“一系列数字”，而是某个抽象对象在一组基下的坐标。若换一组正交基 Q ，同一个几何对象的坐标可变为 $x' = Q^\top x$ ；很多真正的几何性质却不改变，例如

$$\|x'\|_2 = \|x\|_2, \quad x'^\top y' = x^\top y.$$

因此研究表示时要时刻区分：**哪些现象依赖坐标，哪些现象在换基后仍不变。**

定义 2.1 (内积、范数与夹角). 标准内积为 $\langle x, y \rangle = x^\top y$ 。它诱导欧氏范数

$$\|x\|_2 = \sqrt{x^\top x}.$$

对非零向量，夹角满足

$$\cos \theta = \frac{x^\top y}{\|x\|_2 \|y\|_2}.$$

Embedding 检索常用 cosine similarity，是因为我们有时更在意方向而不是绝对尺度。但这并不意味着余弦相似度天然正确：若向量范数本身编码置信度、频率或其他信息，归一化会主动丢弃这些信息。

2.2 矩阵是线性映射，不是二维表格

矩阵 $A \in \mathbb{R}^{m \times d}$ 定义映射 $x \mapsto Ax$ 。只要知道它如何作用在一组基向量上，就知道它对整个空间的作用。矩阵乘法 BA 对应函数复合：先做 A ，再做 B 。

定义 2.2 (四个基本子空间). 对 $A \in \mathbb{R}^{m \times d}$:

- 列空间 $\text{col}(A) \subseteq \mathbb{R}^m$ ：所有可能输出；
- 行空间 $\text{row}(A) \subseteq \mathbb{R}^d$ ：输入中能被 A 感知的方向；

- 零空间 $\mathcal{N}(A) = \{x : Ax = 0\}$ ：完全被映射抹掉的输入方向；
- 左零空间 $\mathcal{N}(A^\top)$ ：与所有列向量正交的输出方向。

定理 2.1 (秩-零度定理). 若 $A \in \mathbb{R}^{m \times d}$, 则

$$\text{rank}(A) + \dim \mathcal{N}(A) = d.$$

这条定理在大模型里有直接的研究含义：当某个线性约束矩阵秩很高时，可自由修改而不触碰约束的零空间就会变小。于是“保持更多旧知识”和“拥有更强编辑自由度”之间可能出现几何上的硬冲突。

2.3 正交、投影与最小距离

若 $U \in \mathbb{R}^{d \times r}$ 的列正交归一，即 $U^\top U = I_r$ ，则投影到 $\text{span}(U)$ 的矩阵是

$$P = UU^\top.$$

它满足

$$P^2 = P, \quad P^\top = P.$$

正交补投影则为 $P_\perp = I - P$ 。

定理 2.2 (正交投影的最优性). 对任意 $x \in \mathbb{R}^d$, Px 是子空间 $\mathcal{S} = \text{span}(U)$ 中距离 x 最近的点：

$$Px = \arg \min_{z \in \mathcal{S}} \|x - z\|_2.$$

证明. 对任意 $z \in \mathcal{S}$, 分解

$$x - z = (x - Px) + (Px - z).$$

第一项属于 $\mathcal{S}^\perp$, 第二项属于 $\mathcal{S}$, 二者正交。由勾股定理,

$$\|x - z\|_2^2 = \|x - Px\|_2^2 + \|Px - z\|_2^2 \geq \|x - Px\|_2^2.$$

等号仅当 $z = Px$ 。

□

2.4 最小二乘就是投影

线性回归的几何问题是：给定 $X \in \mathbb{R}^{n \times d}$ 与 $y \in \mathbb{R}^n$, 寻找 Xw 逼近 y 。因为 Xw 只能落在 $\text{col}(X)$, 问题

$$\min_w \|Xw - y\|_2^2$$

就是把 y 投影到 $\text{col}(X)$ 。

令残差 $r = y - X\hat{w}$ 。最优性要求 $r \perp \text{col}(X)$ ，因此

$$X^\top(y - X\hat{w}) = 0,$$

得到正规方程

$$X^\top X \hat{w} = X^\top y.$$

若 $X^\top X$ 可逆，

$$\hat{w} = (X^\top X)^{-1} X^\top y.$$

但现代机器学习常常 $d > n$ ，矩阵不可逆。我们真正需要的是伪逆。

2.5 SVD：把任意线性映射拆成三个简单动作

任意 $A \in \mathbb{R}^{m \times d}$ 都有奇异值分解

$$A = U \Sigma V^\top,$$

其中 U, V 的列正交， Σ 对角且奇异值满足

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq 0.$$

几何上， $V^\top$ 先把输入旋转到右奇异向量坐标， Σ 沿各轴缩放， U 再旋转到输出空间。




图 2.1 SVD 把一个复杂矩阵分解为换基、按正交方向缩放、再换基。

定义 2.3 (Moore–Penrose 伪逆). 若 $A = U \Sigma V^\top$ ，将非零奇异值取倒数得到 Σ^+ ，定义

$$A^+ = V \Sigma^+ U^\top.$$

当最小二乘有无穷多个解时， $A^+ y$ 给出最小欧氏范数解。这与过参数化线性模型中的 implicit bias 有直接联系：优化器常常并不是任意选一个插值解，而会偏向特定几何解。

2.6 低秩近似：为什么“少数方向”值得保留

定理 2.3 (Eckart–Young–Mirsky). 设 $A = U \Sigma V^\top$ 。在所有秩不超过 r 的矩阵中，截断 SVD

$$A_r = U_{:,1:r} \Sigma_{1:r,1:r} V_{:,1:r}^\top$$

最小化 Frobenius 误差与谱范数误差。特别地，

$$\|A - A_r\|_F^2 = \sum_{j>r} \sigma_j^2.$$

这个定理解释了为什么谱衰减很快时，低秩近似能高效保留主要结构。LoRA 把权重更新限制为

$$\Delta W = BA, \quad B \in \mathbb{R}^{d_{\text{out}} \times r}, \quad A \in \mathbb{R}^{r \times d_{\text{in}}},$$

因此 $\text{rank}(\Delta W) \leq r$ 。它不是“把原矩阵做 SVD”那么简单，而是直接把可学习更新限制在一个低秩流形中。

2.7 PCA：最大方差方向与重构误差

中心化数据矩阵 $X \in \mathbb{R}^{n \times d}$ 的协方差为

$$C = \frac{1}{n} X^\top X.$$

第一主成分可写成

$$v_1 = \arg \max_{\|v\|=1} v^\top C v.$$

用 Lagrange multiplier 可得 $Cv_1 = \lambda_1 v_1$ ，所以主成分就是协方差矩阵最大特征值对应的特征向量。等价地，它也是 X 的第一右奇异向量。

PCA 同时解决两个问题：保留投影方差最大，以及线性低维重构误差最小。这种“同一个算法有统计解释和几何解释”的习惯非常重要。后面 Attention、KL-regularized RL、DPO 也会反复出现这种多重视角。

2.8 高维几何：距离集中与近似正交

若 $x, y \sim \mathcal{N}(0, I_d)$ 独立，则

$$\mathbb{E}[x^\top y] = 0, \quad \text{Var}(x^\top y) = d.$$

但 $\|x\|_2 \approx \sqrt{d}$ 、 $\|y\|_2 \approx \sqrt{d}$ ，因此归一化后的 cosine similarity 典型尺度约为 $1/\sqrt{d}$ 。维数升高时，随机方向越来越接近正交。

另一方面，许多随机点到查询点的距离也会相对集中，使“最近邻比平均点近很多”的优势变弱。这就是为什么高维检索需要认真考虑度量、归一化和数据流形，而不能把二维图形直觉机械推广。

2.9 Jacobian：非线性网络的局部线性几何

神经网络 $f: \mathbb{R}^d \rightarrow \mathbb{R}^m$ 虽然非线性，但在点 x 附近有一阶近似

$$f(x + \Delta x) \approx f(x) + J_f(x) \Delta x,$$

其中 $J_f(x)$ 是 Jacobian。于是 SVD 又重新出现： J 的大奇异值方向对应输出最敏感的局部扰动，小奇异值或零空间方向对应局部不敏感方向。

这为模型编辑提供了一个自然推广：如果 hidden state 子空间只是一阶代理，我们是否可以直接约束某些输出对参数更新的 Jacobian 变化？这类问题把“线性代数教材知识”直接推进到了可研究的局部几何。

2.10 Research Frontier: AlphaEdit 如何把零空间变成知识保护器

Research Frontier | AlphaEdit: Null-Space Constrained Knowledge Editing for Language Models

会议身份：ICLR 2025 Outstanding Paper。

问题：locating-then-editing 方法会给某些权重加入扰动 ΔW 。目标知识可能被成功修改，但 sequential editing 容易逐步破坏原有知识。AlphaEdit 的核心思想是：先用 preserved knowledge 构造一个需要保护的表示子空间，再把更新投影到它的零空间中。

若需要保持的输入表示组成矩阵 $K \in \mathbb{R}^{d \times m}$ ，希望编辑后对这些表示没有一阶线性影响，可以要求

$$\Delta W K = 0.$$

若 Q 是 $\text{col}(K)$ 的正交基，则允许更新位于其正交补：

$$P_{\perp} = I - QQ^{\top}, \quad \Delta W_{\text{safe}} = \Delta W_{\text{raw}} P_{\perp}.$$

于是

$$\Delta W_{\text{safe}} K = \Delta W_{\text{raw}} (I - QQ^{\top}) K = 0.$$

真实论文的实现和模型编辑目标更复杂，但这个等式抓住了最核心的保护机制：**把“不应改变”翻译成一个线性不变量。**

论文在 LLaMA3、GPT2-XL、GPT-J 等模型上报告，单独加入这一投影可显著改善多种 locating-then-editing 方法，并强调 sequential editing 下的知识保持。

论文：[ICLR Proceedings](#)。




图 2.2 机制级 AlphaEdit 复现：未约束更新在增强编辑效果时会同步伤害 protected subspace；零空间投影可以把保护残差压到数值精度附近。

Mini Lab | Frontier Replication 2: 从二维投影到 sequential editing

运行 `labs/frontier/ch02_alphaedit_nullspace.py`。先验证 $\|\Delta W_{\text{safe}} K\|_F \approx 0$ 。随后把 preserved states 的数量从 1 增到 d ，记录零空间维度与可实现 edit gain 的关系。最后做 sequential editing：连续施加 100 次随机目标更新，比较 unconstrained、固定保护子空间、动态更新保护子空间三种方案的累计破坏。

From Textbook to Research | 本章之后你应该会问什么？

如果知识方向高度重叠，保护子空间越来越大，最终零空间会不会小到无处可编辑？如果真实模型在一个弯曲流形上表示知识，固定线性零空间是否只是局部近似？如果把 K 换成输出关于参数的 Jacobian，能否得到更直接的“行为保持”约束？

2.11 Deep Dive: 伪逆与最小范数插值解

考虑欠定方程 $Xw = y$ ，其中 $X \in \mathbb{R}^{n \times d}$ 、 $d > n$ ，并假设可解。所有解都可以写成

$$w = X^+y + z, \quad z \in \mathcal{N}(X).$$

因为 $X^+y \in \text{row}(X)$ 而 $\mathcal{N}(X) = \text{row}(X)^\perp$ ，所以

$$\|w\|_2^2 = \|X^+y\|_2^2 + \|z\|_2^2.$$

因此 X^+y 是唯一最小范数插值解。这一事实与梯度下降从零初始化训练线性平方损失的 implicit bias 有直接关系：梯度始终位于 $\text{row}(X)$ ，所以参数不会凭空长出零空间分

量，最终恰好趋向最小范数解。

命题 2.1 (零初始化梯度下降保留行空间). 对损失 $L(w) = \frac{1}{2} \|Xw - y\|_2^2$, 若 $w_0 = 0$, 则所有 $w_t \in \text{row}(X)$ 。

证明. 梯度 $\nabla L(w) = X^\top(Xw - y)$ 属于 $\text{col}(X^\top) = \text{row}(X)$ 。由归纳法, $w_{t+1} = w_t - \eta \nabla L(w_t)$ 始终属于行空间。□

2.12 Deep Dive: 条件数与可辨识性

对满秩矩阵 A , 二范数条件数为

$$\kappa_2(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}.$$

若最小奇异值很小, 则某个输入方向几乎被压扁。求逆时, 这个方向上的微小输出噪声会被放大约 $1/\sigma_{\min}$ 。因此条件数同时是数值稳定性和统计可辨识性的指标。

在线性回归中, 若特征高度共线, $X^\top X$ 会病态; 参数估计对数据扰动敏感。加入 ridge 后, 谱从 σ_j^2 变为 $\sigma_j^2 + n\lambda$, 最小方向被“抬高”, 所以正则化也可以被理解为**改善逆问题条件数**。

2.13 Deep Dive: 随机投影与 Johnson–Lindenstrauss 直觉

高维并不意味着必须一直保留原维度。Johnson–Lindenstrauss 引理表明, 对有限的 N 个点, 存在映射到

$$k = O\left(\frac{\log N}{\epsilon^2}\right)$$

维的近似等距嵌入, 使所有点对距离都在 $(1 \pm \epsilon)$ 范围内保持。随机高斯投影经过适当缩放即可高概率实现这种效果。

这个结论告诉我们: “**维数**”与“**可区分信息量**”不是一回事。对有限数据集, 很多几何关系可以在远低于原始维度的空间中保留。现代 embedding、压缩、随机特征和 sketching 方法都与这种思想相通。

2.14 Deep Dive: 低秩更新为何不能简单等于“重要方向”

LoRA 约束 $\Delta W = BA$, 只保证更新秩至多为 r 。但“低秩”并不自动意味着“正确方向”: 若优化得到的 B, A 对任务无关, 低秩仍然会失败。真正的优势来自一个经验假设: 下游适配所需的参数变化具有较低的 intrinsic rank。

可以把这个问题变成可检验假设：先进行 full fine-tuning 得到 ΔW_{full} ，对它做 SVD，检查前 r 个奇异值能解释多少 Frobenius 能量。如果谱衰减很快，低秩适配更有几何依据；若谱平坦，固定小 rank 可能形成明显瓶颈。

2.15 Deep Dive: 从 hidden-state null space 到 Jacobian null space

设要保护的行为输出为 $g(\theta) \in \mathbb{R}^k$ 。参数发生小变化 $\Delta\theta$ 时，

$$g(\theta + \Delta\theta) \approx g(\theta) + J_g(\theta)\Delta\theta.$$

若希望一阶保持行为不变，可约束

$$J_g(\theta)\Delta\theta = 0,$$

即 $\Delta\theta \in \mathcal{N}(J_g)$ 。这比 hidden-state 子空间更直接，但 Jacobian 维度巨大、计算昂贵，而且一阶不变不保证大更新后仍不变。由此自然出现近似 Jacobian、随机 sketch、低秩 Fisher 等研究方向。

分层训练 | A 基础层

1. 证明正交投影矩阵 P 的特征值只能是 0 或 1。
2. 给出一个 3×2 矩阵，手算其四个基本子空间。
3. 解释 cosine similarity 与 Euclidean distance 在单位球面上的关系。

分层训练 | B 推导层

1. 用 SVD 推导 A^+ 并验证 $AA^+A = A$ 。
2. 证明欠定可解系统的伪逆解是最小范数解。
3. 证明截断 SVD 的 Frobenius 误差为 $\sum_{j>r} \sigma_j^2$ 。

分层训练 | C 研究层

1. 设计 sequential editing 实验，画 preserved subspace rank 与 edit success 的 Pareto 曲线。
2. 用自动微分计算一个小 MLP 的 Jacobian，比较 hidden-state null-space 与 Jacobian null-space 保护效果。
3. 对一个真实 PEFT 任务记录 full fine-tuning 的 ΔW 谱，检验“低 intrinsic rank”是否成立。

2.16 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

本章的 SVD、投影与零空间将在第 7 章的 logit rank、第 13 章的 attention 结构与第 22 章的 memory compression 中复用。

Worked Example | SVD 不只是分解，而是最优压缩

设 $A = \text{diag}(5, 2, 0.5)$ 。最佳 rank-2 近似由定理 2.3 直接保留前两个奇异值：

$$A_2 = \text{diag}(5, 2, 0), \quad \|A - A_2\|_F = 0.5.$$

如果随意保留第一、第三方向，误差变为 2。这说明“低秩”不是删掉几个坐标，而是寻找能量最集中的子空间。这个思想会在 Ch7 的 logit rank、Ch13 的 attention score rank 与参数高效微调中重复出现。

Proof Clinic | 为什么零空间编辑能保持旧表示

若 protected hidden states 构成 $H \in \mathbb{R}^{d \times m}$ ，希望更新 ΔW 满足 $\Delta W H = 0$ 。令 $P_{N(H^\top)}$ 为 $H^\top$ 零空间上的投影，取 $\Delta W = B P_{N(H^\top)}$ ，则

$$\Delta W H = B P_{N(H^\top)} H = 0.$$

证明的核心只有“投影后的每个方向与 H 的列空间正交”。研究难点不在这行等式，而在真实模型中 protected set 是否足以代表所有要保护的行为。

Research Assignment | 从 toy null-space 到真实知识编辑

复现 AlphaEdit 机制后，不以 edit success 作为唯一指标。至少同时报告 locality、paraphrase generalization 与 sequential edits；比较精确零空间、截断 SVD 近似零空间和无投影 baseline，并解释数值 rank 阈值如何改变结论。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. AlphaEdit 中“preserved knowledge”最终被表示成什么线性对象？不同采样方式会怎样改变其秩？
2. 投影后 $\Delta W K = 0$ 是精确代数结论，还是对完整 Transformer 输出不变的充分必要条件？区分两者。

3. sequential editing 时，保护子空间应固定还是动态增长？增长会怎样压缩可编辑零空间？
4. 论文报告的平均改进依赖哪些 baseline editing method？“平均提升”是否能代表所有模型和任务？
5. 如果用近似投影或低精度线性代数，保护误差怎样随条件数放大？

本章小结

本章把“表示”变成了可操作的几何对象：矩阵决定哪些方向可见，零空间描述哪些变化不可见，投影给出最小距离约束，SVD 暴露每个方向的增益，低秩把可修改自由度集中到少数方向。下一章我们将从确定性的几何转向不确定性的概率语言：模型为什么能够对一个预测说“我有多相信”？