

第 3 章 概率、似然与贝叶斯推断——模型怎样表示不确定性


本章目标

LLM 的 next-token probability、分类器的置信度、RL 中的随机策略、SMC 的粒子权重都依赖同一套概率语言。本章不以“背常见分布”为目标，而围绕四个动作组织：**分解联合分布、条件化、估计未知参数、用采样近似不可解的期望**。学完后，你应该能从最大似然推导常见损失，解释 Bayes 更新，计算 Monte Carlo 方差，并理解 Twisted SMC 为什么能把推理算力提前投入到更有希望的序列前缀。

Prerequisite Recall | 先把这些知识唤醒

- 会使用乘法法则 $p(x, y) = p(y | x)p(x)$ 。
- 记住概率密度可以大于 1，但概率不能大于 1。
- 知道期望是“对随机结果的加权平均”，而不是一次观测。

Visual Derivation | 先看结构，再读公式



归一化由 evidence $p(D)$ 完成

读 Bayes 时永远先问：哪个量是生成机制，哪个量是观察后的信念？

Misconception Check | 本章最容易掉进去的坑

$p(\theta | D)$ 与 $p(D | \theta)$ 不能因为“看起来都描述数据和参数关系”就互换。前者是观察数据后的信念，后者是参数固定时产生数据的机制；Bayes 公式中还必须支付 prior 与 evidence。

Concept Contrast | 把相邻概念主动分开

	MLE	MAP	Bayes posterior
输出	点估计	点估计	分布
使用 prior	否	是	是
不确定性	不直接表达	不直接表达	显式保留

Checkpoint | 开始正文前的 30 秒自测

若 proposal $q(x)$ 在某个 $p(x) > 0$ 的区域严格为 0, importance sampling 会发生什么? **检查答案:** support 条件被破坏, p/q 无法定义, 该区域永远采不到, 估计可能系统性失效。

3.1 随机变量与分布：不确定性不是模糊语言

随机变量 X 是把随机试验结果映射到数值或离散符号的函数。分布则规定这些可能结果出现的概率。离散情况下概率质量函数满足

$$p(x) \geq 0, \quad \sum_x p(x) = 1.$$

连续变量使用密度 $p(x)$, 概率由积分给出。需要避免一个常见误解：连续密度值可以大于 1, 真正必须落在 $[0, 1]$ 的是积分得到的事件概率。

3.2 联合、边缘与条件：概率模型的三种视角

对随机变量 X, Y , 联合分布 $p(x, y)$ 是完整对象。边缘化得到

$$p(x) = \sum_y p(x, y),$$

条件分布定义为

$$p(y|x) = \frac{p(x, y)}{p(x)}, \quad p(x) > 0.$$

因此乘法规则

$$p(x, y) = p(y|x)p(x)$$

不是技巧, 而是联合分布的重新分解。

对序列 $x_{1:T}$ 反复使用乘法规则得到链式法则:

$$p(x_{1:T}) = \prod_{t=1}^T p(x_t|x_{<t}).$$

这条恒等式本身没有任何 Transformer 假设, 却为 autoregressive language modeling 提供了最基本的概率分解。

3.3 Bayes 公式：观察数据以后，哪些信念应该改变

Bayes 公式写作

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}, \quad p(D) = \int p(D|\theta)p(\theta)d\theta.$$

其中 prior $p(\theta)$ 表示观察当前数据前的结构假设，likelihood $p(D|\theta)$ 衡量参数解释数据的能力，posterior $p(\theta|D)$ 是看到数据后的更新。

例 3.1 (Beta-Bernoulli 共轭更新). 设硬币正面概率 $\theta \sim \text{Beta}(\alpha, \beta)$ ，观察 h 次正面与 t 次反面，则

$$p(\theta|D) \propto \theta^{h+\alpha-1}(1-\theta)^{t+\beta-1},$$

因此

$$\theta|D \sim \text{Beta}(\alpha + h, \beta + t).$$

先验超参数可以解释成 pseudo-count。若先验是 $\text{Beta}(1, 1)$ ，观察 8 正 2 反，后验均值为 $9/12 = 0.75$ ，而 MLE 为 0.8。

3.4 最大似然：把“解释数据”写成优化目标

设独立同分布样本 $D = \{x_i\}_{i=1}^n$ ，似然为

$$L(\theta; D) = \prod_{i=1}^n p_\theta(x_i).$$

最大似然估计

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta; D) = \arg \max_{\theta} \sum_{i=1}^n \log p_\theta(x_i).$$

取对数不改变最优点，因为对数严格单调；同时把乘积变成求和，并避免大量小概率相乘导致的数值下溢。

Bernoulli MLE

若 $x_i \in \{0, 1\}$ 且 $p_\theta(x) = \theta^x(1-\theta)^{1-x}$ ，记 $k = \sum_i x_i$ ，则

$$\ell(\theta) = k \log \theta + (n - k) \log(1 - \theta).$$

求导并令零：

$$\frac{k}{\theta} - \frac{n-k}{1-\theta} = 0 \quad \Rightarrow \quad \hat{\theta} = \frac{k}{n}.$$

所以“样本正例频率”不是拍脑袋估计，而是 Bernoulli 模型下的 MLE。

3.5 MAP：正则化为什么经常像先验

最大后验估计

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} \log p(D|\theta) + \log p(\theta).$$

如果先验为各向同性高斯

$$p(\theta) \propto \exp\left(-\frac{\lambda}{2} \|\theta\|_2^2\right),$$

则 MAP 等价于最小化负对数似然加 L_2 正则。这给第 1 章的正则化提供了概率解释。

但要小心：“weight decay 就是 Bayesian prior”并非在所有深度学习优化器与参数化下都严格成立。MAP 是目标函数层面的等价，优化算法、重参数化和有限训练时间还会继续引入额外偏置。

3.6 期望、方差与大数定律

对离散随机变量，

$$\mathbb{E}[f(X)] = \sum_x p(x)f(x).$$

若 $X_1, \dots, X_N$ 独立同分布，Monte Carlo 估计

$$\hat{\mu}_N = \frac{1}{N} \sum_{i=1}^N f(X_i)$$

满足

$$\mathbb{E}[\hat{\mu}_N] = \mu, \quad \text{Var}(\hat{\mu}_N) = \frac{\text{Var}(f(X))}{N}.$$

所以标准误差按 $1/\sqrt{N}$ 下降。这条平方根定律非常残酷：若想把误差缩小 10 倍，通常需要约 100 倍样本。

Mini-batch SGD 的 batch gradient、模型评测中的平均准确率、RL policy gradient 的 trajectory average，都可以看成 Monte Carlo 估计。

3.7 重要性采样：从“容易采的分布”估计“真正关心的分布”

若目标是

$$\mu = \mathbb{E}_p[f(X)],$$

但从 p 采样困难，而从 proposal q 容易，只要 $p(x) > 0 \Rightarrow q(x) > 0$ ，便有

$$\mu = \mathbb{E}_q\left[f(X) \frac{p(X)}{q(X)}\right].$$

权重

$$w(x) = \frac{p(x)}{q(x)}$$

纠正 proposal 与 target 的错配。

问题是：若少数样本权重极大，估计方差会爆炸。常用诊断是有效样本量

$$\text{ESS} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2},$$

其最大值为 N 。当 ESS 接近 1，意味着几乎所有估计都由一个粒子支配。

3.8 从重要性采样到 Sequential Monte Carlo

对于长序列，直接从 proposal 生成完整 $x_{1:T}$ 再赋权通常极低效，因为“好不好”可能直到最后才知道。SMC 将序列逐步扩展，并在中间阶段根据增量权重重采样：

$$\{x_{1:t-1}^{(i)}, w_{t-1}^{(i)}\} \longrightarrow \{x_{1:t}^{(i)}, w_t^{(i)}\}.$$

核心思想是把有限计算预算动态搬到更有希望的部分轨迹上。




图 3.1 SMC 不只是“多采样”，而是随着序列推进不断重分配粒子预算。

3.9 校准：概率数值有没有统计含义

若模型对一组事件都预测 0.8，理想校准意味着其中大约 80% 最终发生。准确率与校准不同：一个分类器可以排序非常好，却把所有概率过度推向 0 或 1。

常见校准指标包括 Brier score

$$\frac{1}{n} \sum_i (p_i - y_i)^2$$

与分桶后的 expected calibration error (ECE)。但 ECE 依赖 binning，且不同任务的 calibration 定义可能不同。对 LLM，token probability 校准、答案级正确性校准、自我报告置信度也不是同一个对象。

3.10 Research Frontier: 把 LLM 生成重写成概率推断

Research Frontier | Probabilistic Inference in Language Models via Twisted Sequential Monte Carlo

会议身份: ICML 2024 Best Paper, Stephen Zhao, Rob Brekelmans, Alireza Makhzani, Roger Grosse。

很多 LLM 推理问题可以写成未归一化目标分布

$$\pi(x_{1:T}) \propto p_{\text{LM}}(x_{1:T}) \phi(x_{1:T}),$$

或令 $\phi = \exp(R)$ 。基础 LM 提供语言先验, reward/potential 强调想要的全局属性。困难是 ϕ 常在完整序列结束后才真正可计算。

Twisted SMC 引入随前缀变化的 twist function, 估计“从当前前缀继续生成, 未来最终 potential 会有多大”。理想 twist 的形式可理解为

$$\psi_t(x_{1:t}) \approx \mathbb{E}_{p_{\text{LM}}(x_{t+1:T}|x_{1:t})}[\phi(x_{1:T})].$$

于是序列还没生成完, 就能判断哪些前缀值得保留更多粒子。论文还提出学习 twist 的对比式方法, 并用双向 SMC 界估计 log partition function, 从而评估推断分布与目标分布之间的 KL。

研究转变: 生成不再只有 greedy、beam search、temperature sampling。它可以被视为“对一个奖励重加权后的序列分布做近似推断”。

论文: PMLR; **奖项:** ICML 2024 Awards。




图 3.2 机制级复现: 在一个稀有终局奖励的二元序列模型中, 精确 twist 能显著提高有限样本预算下产生目标序列的比例。

Mini Lab | Frontier Replication 3: 先做 exact twist, 再学 twist

运行 `labs/frontier/ch03_twisted_smc.py`。脚本用动态规划计算一个玩具序列任务的 exact twist, 因此先把“为什么有效”与“怎样学习 twist”分开。扩展任务: (1) 限制粒子数, 比较 ancestral / best-of-N / SMC; (2) 用一个小 MLP 从 prefix state 预测 exact twist; (3) 比较 twist 预测误差、ESS 与最终采样质量的关系。

From Textbook to Research | 本章之后你应该会问什么?

如果 reward 本身存在偏差, 更精确地逼近 $p_{\text{LM}}(x) \exp(R(x))$ 会不会反而更高效地 reward hack? 概率推断算法只保证“更接近目标分布”, 它并不保证“目标分布值得接近”。这条区分将在对齐与 Agent 章节变得非常重要。

3.11 Deep Dive: MLE 的一致性为什么需要条件

直觉上, 样本越来越多时, 平均 log-likelihood

$$\frac{1}{n} \sum_i \log p_\theta(X_i)$$

会接近

$$\mathbb{E}_{X \sim p_*} [\log p_\theta(X)].$$

若真实分布 p_* 属于模型族, 且模型可辨识、正则性条件成立, 那么最大化经验 log-likelihood 可趋向真实参数。但若模型错设 (misspecified), MLE 会趋向使

$$D_{\text{KL}}(p_* \| p_\theta)$$

最小的“最佳近似”参数, 而不是真实世界不存在的某个完美参数。第 4 章会严格推导这个 KL 关系。

3.12 Deep Dive: Laplace 近似把 Bayes 与二阶优化连起来

后验

$$p(\theta|D) \propto e^{-F(\theta)}$$

若在 MAP 点 $\hat{\theta}$ 附近二阶展开

$$F(\theta) \approx F(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^\top H(\theta - \hat{\theta}),$$

则后验近似高斯

$$p(\theta|D) \approx \mathcal{N}(\hat{\theta}, H^{-1}).$$

因此 Hessian 不仅描述优化曲率，也近似描述参数不确定性：曲率大意味着后验窄，曲率小意味着后验宽。当然，深网后验高度非高斯且存在大量对称性，因此 Laplace 只是局部近似。

3.13 Deep Dive：自归一化重要性采样

当目标分布只知道未归一化密度 $\tilde{p}(x)$ ，归一化常数 Z 未知时，可使用

$$\tilde{w}_i = \frac{\tilde{p}(x_i)}{q(x_i)}, \quad \hat{\mu}_{\text{SNIS}} = \frac{\sum_i \tilde{w}_i f(x_i)}{\sum_i \tilde{w}_i}.$$

它一般有有限样本偏差，但在适当条件下一致。LLM 中 reward-reweighted sequence distribution 往往正是未归一化目标，因此 partition function 与自归一化权重自然出现。

3.14 Deep Dive：SMC 权重的递推结构

设目标序列密度可逐步写为未归一化 $\gamma_t(x_{1:t})$ ，proposal 为

$$q_t(x_t | x_{1:t-1}).$$

则增量权重为

$$\alpha_t = \frac{\gamma_t(x_{1:t})}{\gamma_{t-1}(x_{1:t-1})q_t(x_t | x_{1:t-1})}.$$

总权重是增量权重乘积。好的 twist 实际上是在重新设计一组中间目标 γ_t ，让未来终局信息提前进入当前权重，从而减少粒子退化。

3.15 Deep Dive：从 twist 到 soft value function

若

$$\pi(x_{1:T}) \propto p_0(x_{1:T})e^{\beta R(x_{1:T})},$$

定义

$$V_t(x_{1:t}) = \frac{1}{\beta} \log \mathbb{E}_{p_0(x_{t+1:T} | x_{1:t})}[e^{\beta R(x_{1:T})}],$$

则 $e^{\beta V_t}$ 就是一个理想的未来 potential。这个 log-moment-generating 结构与 maximum-entropy / soft RL 的 value function 非常接近。于是 SMC 与 RL 的联系不是类比，而来自同一个指数重加权目标。

分层训练 | A 基础层

1. 推导 Bernoulli MLE 与 Beta-Bernoulli posterior。
2. 证明 Monte Carlo 均值的方差为 σ^2/N 。
3. 给出一个准确率相同但校准显著不同的二分类器构造。

分层训练 | B 推导层

1. 推导高斯均值未知、方差已知时的 MLE。
2. 证明标准重要性采样估计在 proposal 支持覆盖 target 时无偏。
3. 从序列 target 与 proposal 推导 SMC 的增量权重公式。

分层训练 | C 研究层

1. 在 Frontier Lab 中故意训练一个有偏 twist，测量 twist MSE 与终局 KL/成功率之间是否单调。
2. 设计 reward misspecification: reward 偏好某个伪特征，比较 ancestral、best-of-N、twisted SMC 的 reward hacking 强度。
3. 对小语言模型实现 token-level particle filtering，并记录 ESS 随生成长度的退化曲线。

3.16 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

Bayes posterior 将在第 17 章的 ICL 与第 20 章的 belief-state POMDP 中重新出现。

Worked Example | 一次 Bayes 更新要写全归一化常数

袋中硬币类型 $Z \in \{F, B\}$ ，先验 $P(F) = 0.3$ ，其中公平硬币 $P(H|F) = 0.5$ ，偏置硬币 $P(H|B) = 0.8$ 。观察两次正面后：

$$P(F|HH) = \frac{0.3 \cdot 0.5^2}{0.3 \cdot 0.5^2 + 0.7 \cdot 0.8^2} \approx 0.1434.$$

posterior 下降不是因为“公平硬币变差”，而是 evidence 在两个 hypothesis 下的相对似然不同。

Proof Clinic | MLE 与交叉熵的桥

若数据经验分布为 $\hat{p}(x)$ ，最大化 $\sum_i \log p_\theta(x_i)$ 等价于最小化

$$-\sum_x \hat{p}(x) \log p_\theta(x) = H(\hat{p}, p_\theta).$$

又因为 $H(\hat{p}, p_\theta) = H(\hat{p}) + D_{\text{KL}}(\hat{p}||p_\theta)$ ，且第一项与 θ 无关，所以 MLE 等价于把 forward KL 压低。这是 Ch11 next-token training 的概率根基。

Research Assignment | Twisted SMC 的机制复现

在至少三个 target sharpness 下比较 ancestral sampling、importance sampling 与 twisted SMC 的 ESS、估计偏差和 wall-clock。必须画 ESS 随时间/序列位置变化，并说明 proposal 越好为什么不等于估计无偏性自动成立。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. Twisted SMC 的 target distribution 与 base LM distribution 之间差了哪个 potential? 归一化常数为什么难算?
2. 理想 twist 需要知道未来什么量? 现实系统为什么必须学习或近似它?
3. ESS 低代表什么? 重采样能解决哪类退化, 又会引入什么样的粒子多样性损失?
4. 和 best-of-N 相比, SMC 的优势来自“样本更多”还是“更早淘汰低潜力前缀”? 如何设计控制实验区分?
5. 双向 SMC bound 为什么能帮助评估近似推断质量? 它与直接只看 reward 有什么不同?

本章小结

概率提供了描述不确定性的统一语言；最大似然把统计估计变成优化；Bayes 把先验与证据组合；Monte Carlo 把不可积的期望变成样本平均；SMC 再把有限采样预算沿序列动态分配。下一章我们将问一个更深的问题：当模型分配了“错误的概率”时，究竟应该怎样量化两个分布之间的差异？