

第 4 章 信息论与交叉熵——从最短编码到语言建模

本章目标

本章回答一个贯穿 LLM 的问题:为什么最大似然、cross-entropy、KL、perplexity、蒸馏和对齐会不断出现同一组公式? 核心答案是: 概率分布同时也是编码方案。一个模型给真实事件的概率越低, 就需要越长的码字来描述它。学完后, 你应该能证明 Gibbs inequality, 推导交叉熵与 MLE 的等价关系, 解释 KL 的方向差异, 理解 mutual information 与 data processing, 并能从描述长度视角分析“预训练行为”和“后训练对齐”的竞争。

Prerequisite Recall | 先把这些知识唤醒

- 熟悉 $-\log p$ 随 p 变小而增大。
- 知道期望的分布必须写清楚: $\mathbb{E}_{x \sim p}[\cdot]$ 。
- 已掌握 MLE 与条件概率。

Misconception Check | 本章最容易掉进去的坑

“交叉熵小”不等于“熵小”。 $H(p)$ 是数据源自己的不确定性; $H(p, q)$ 还包含模型错配成本。把二者混在一起, 会误以为训练能把数据本身的不可约随机性消掉。

Concept Contrast | 把相邻概念主动分开

	$H(p)$	$H(p, q) = H(p) + D_{KL}(p q)$
谁决定	真实分布 p	p 与模型 q
可通过换模型降低?	否	KL 部分可以
编码解释	最优平均码长	用错误码本的平均码长

Checkpoint | 开始正文前的 30 秒自测

当 $p = q$ 时交叉熵为什么仍不一定是 0? 检查答案: 因为 $H(p, q) = H(p)$; 只有数据源本身是确定性的, 熵才为 0。

4.1 信息量：为什么稀有事件更“惊讶”

若事件 x 的概率为 $p(x)$ ，定义自信息

$$I(x) = -\log p(x).$$

它满足三个合理要求：概率越小信息量越大；独立事件同时发生时信息量相加；概率为 1 的事件信息量为 0。若用底数 2，单位是 bit；自然对数则单位是 nat。

对随机变量取平均得到熵：

$$H(X) = \mathbb{E}[-\log p(X)] = -\sum_x p(x) \log p(x).$$

例 4.1 (一次公平硬币与一次极偏硬币). 公平硬币 $p = (1/2, 1/2)$ 的熵为 1 bit。若 $p = (0.99, 0.01)$ ，熵约为 0.081 bit。第二种试验虽然仍有两个可能结果，但大多数时候几乎不需要“新信息”就能猜中结果。

4.2 熵与编码： $-\log p$ 不是巧合

前缀码长度 $\ell(x)$ 必须满足 Kraft 不等式

$$\sum_x 2^{-\ell(x)} \leq 1.$$

若理想化地允许实数码长，选择

$$\ell(x) = -\log_2 p(x)$$

正好满足等式。Shannon coding 表明真实整数码长也能做到平均长度距离熵不到 1 bit。于是熵具有直接操作意义：**它是按照真实分布压缩数据时的基本平均码长尺度。**

4.3 交叉熵：用错误模型编码真实数据要付多少代价

若真实数据来自 p ，但使用模型 q 设计码长，则平均码长为

$$H(p, q) = -\sum_x p(x) \log q(x).$$

它称为交叉熵。定义 KL divergence

$$D_{\text{KL}}(p\|q) = \sum_x p(x) \log \frac{p(x)}{q(x)}.$$

直接展开：

$$H(p, q) = H(p) + D_{\text{KL}}(p\|q).$$

所以使用错误模型 q 比使用真实 p 多出的平均码长，恰好就是 $D_{\text{KL}}(p\|q)$ 。

定理 4.1 (Gibbs inequality). 对任意分布 p, q , 只要 p 的支持包含于 q 的支持,

$$D_{\text{KL}}(p\|q) \geq 0,$$

且等号当且仅当 $p = q$ (几乎处处)。

证明. 令 $S = \{x : p(x) > 0\}$ 。由 support 假设, $q(x) > 0$ 对 $x \in S$ 成立。利用 $\log u \leq u - 1$, 令 $u = q(x)/p(x)$, 得到

$$-D_{\text{KL}}(p\|q) = \sum_{x \in S} p(x) \log \frac{q(x)}{p(x)} \leq \sum_{x \in S} (q(x) - p(x)) = q(S) - 1 \leq 0.$$

因此 $D_{\text{KL}}(p\|q) \geq 0$ 。取等号不仅要求 $q(x) = p(x)$ 对 $x \in S$ 成立, 还要求 $q(S) = 1$, 所以 S 外不能有额外概率质量; 最终 $p = q$ (在离散情形下逐点成立)。□

4.4 最大似然为什么就是最小交叉熵

设经验分布

$$\hat{p}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[x_i = x].$$

模型平均 NLL 为

$$\begin{aligned} -\frac{1}{n} \sum_{i=1}^n \log q_\theta(x_i) &= -\sum_x \hat{p}_n(x) \log q_\theta(x) \\ &= H(\hat{p}_n, q_\theta). \end{aligned}$$

因此 MLE 就是在训练样本经验分布下最小化交叉熵。由于 $H(\hat{p}_n)$ 与 θ 无关, 也等价于

$$\min_{\theta} D_{\text{KL}}(\hat{p}_n\|q_\theta).$$

这条等价关系把第 3 章的统计估计与本章的信息论完全接上了。

4.5 语言模型：每一个 token 都在支付码长

自回归语言模型有

$$p_\theta(x_{1:T}) = \prod_{t=1}^T p_\theta(x_t | x_{<t}).$$

所以序列 NLL 为

$$-\log p_\theta(x_{1:T}) = -\sum_{t=1}^T \log p_\theta(x_t | x_{<t}).$$

训练一个 next-token model, 可以理解成不断缩短真实语料的条件码长。

若每 token 平均 NLL（自然对数）为 L ，perplexity 为

$$\text{PPL} = e^L.$$

若使用 base-2 log，则 $\text{PPL} = 2^{H_{\text{bits}}}$ 。它常被粗略解释为“等效分支数”，但这只是直觉：真实词表概率通常极不均匀，也不意味着模型每步只在 PPL 个 token 里选择。

为什么不同 tokenizer 的 perplexity 不能直接横比？

一个 tokenizer 可能把同一句话切成 10 个 token，另一个切成 16 个。per-token NLL 的归一化单位已经改变。更公平的比较需要统一 tokenizer，或换成按字符/字节归一化的 bits-per-byte 等指标。

4.6 KL 的方向：cover 还是 seek？

KL 不对称：

$$D_{\text{KL}}(p\|q) \neq D_{\text{KL}}(q\|p).$$

若 p 在某区域有正概率而 q 给零概率， $D_{\text{KL}}(p\|q) = \infty$ ，因此 forward KL 强烈惩罚“漏掉真实分布支持”。反向 KL 在近似推断的某些场景中更容易选择一个高密度 mode，而忽略其他 mode。

例 4.2 (双峰分布的方向直觉). 设目标 p 有两个相隔很远的峰，而近似族 q 只能使用一个单峰高斯。最小化 $D_{\text{KL}}(p\|q)$ 往往迫使 q 覆盖两个峰之间的大区域；最小化 $D_{\text{KL}}(q\|p)$ 则可能把 q 放在其中一个峰附近。这个“mode-covering / mode-seeking”只是常见直觉，不是对任意分布族的无条件定理。

4.7 互信息：一个表示里保留了多少关于另一个变量的信息

定义

$$I(X; Z) = D_{\text{KL}}(p(x, z)\|p(x)p(z)).$$

等价形式包括

$$I(X; Z) = H(X) - H(X|Z) = H(Z) - H(Z|X).$$

若 X 与 Z 独立，则互信息为零；若 Z 完全决定 X ，则 $H(X|Z) = 0$ 。

定理 4.2 (Data Processing Inequality). 若 $X \rightarrow Z \rightarrow Y$ 构成 Markov chain，即给定 Z 后 Y 与 X 条件独立，则

$$I(X; Y) \leq I(X; Z).$$

这表示：纯粹的后处理不能凭空创造关于 X 的信息。一个压缩表示一旦真正丢掉某类信息，后续 deterministic layer 无法魔法般恢复它；但模型可以利用先验相关性“猜”出看似合理的内容，所以行为上看似恢复并不等于信息论意义上的恢复。

4.8 最小描述长度：模型复杂度也要付码长

仅用训练 NLL 作为编码长度会偏好越来越复杂的模型。Minimum Description Length (MDL) 的核心思想是考虑

$$L(\text{model}) + L(\text{data}|\text{model}).$$

模型本身越复杂，第一项越长；数据压缩越好，第二项越短。它把 Occam's razor 变成“总描述长度最短”的原则，并与 Bayesian evidence、PAC-Bayes 等产生深刻联系。

对 LLM 来说，参数量巨大且训练流程复杂，真正的 MDL 分析并不简单。但“某种行为需要多少额外信息才能覆盖预训练分布中的强偏好”是一个非常有力量的问题。

4.9 Research Frontier：对齐为什么可能具有“弹性”

Research Frontier | Language Models Resist Alignment: Evidence From Data Compression

会议身份：ACL 2025 Best Paper。

论文关注一个令人不安的现象：完成 alignment fine-tuning 的模型，在进一步微调后可能逐渐回到预训练阶段形成的行为分布。作者将其称为 post-alignment model 的 elasticity，并从 compression theory 给出理论分析：与规模巨大的预训练信息相比，后训练对齐写入的行为可能更容易被后续微调破坏。论文在不同模型类型和规模上做了实证，并报告 elasticity 与模型规模、预训练数据扩展呈正相关趋势。

为什么这是信息论问题？如果预训练把大量规律“压缩”进模型，而 alignment 只用相对少量数据重塑输出分布，那么两阶段写入参数的信息量、描述长度与稳固程度可能极不对称。研究问题不再只是“对齐后准确率多高”，而是**这种行为改变对后续训练扰动有多稳定？**

论文：[ACL Anthology](#)；**奖项：**[ACL 2025 Awards](#)。




图 4.1 课堂机制实验：一个分类分布先向 alignment target 移动，再继续在 pretraining distribution 上优化；对齐分布的码长重新升高，而预训练分布码长下降。该实验只展示“弹性”概念，不等同于论文中的压缩理论。

Mini Lab | Frontier Replication 4: 把“行为改变”测成额外码长

运行 `labs/frontier/ch04_compression_elasticity.py`。先把 alignment 看成从 p_0 到 p_a 的分布移动，记录两套 cross-entropy。扩展任务：(1) 改变 alignment steps 与学习率，测恢复速度；(2) 用一个小字符语言模型先 pretrain、再做格式/偏好 SFT、再继续 pretrain，记录 bits-per-character；(3) 区分“参数距离小”与“行为 KL 小”，检验二者是否一致。

From Textbook to Research | 本章之后你应该会问什么？

Cross-entropy 只要求给观察到的 token 更高概率，却没有直接要求模型形成可验证的推理、稳定的价值观或因果世界模型。一个高层能力究竟需要多少 token-level 信息才能稳定写入？不同训练目标是在改变表面输出分布，还是改变内部可复用表示？

4.10 Deep Dive: 交叉熵与 proper scoring rule

对二分类真实概率 $p = \mathbb{P}(Y = 1)$ ，模型报告 q 。期望 log loss 为

$$L(q) = -p \log q - (1 - p) \log(1 - q).$$

求导：

$$L'(q) = -\frac{p}{q} + \frac{1-p}{1-q}.$$

令零得 $q = p$ ，二阶导为正。因此 log loss 是 strictly proper scoring rule：在期望意义下，诚实报告真实概率最优。这解释了为什么 cross-entropy 不只是分类方便，它还具有“激励概率诚实”的统计性质。

但有限模型容量、分布偏移、优化误差和 label noise 会使训练后的 softmax 并不自动校准。proper loss 保证的是理想期望问题的最优报告，不是现实神经网络必然得到完美概率。

4.11 Deep Dive: KL 与 Bregman divergence

负熵函数

$$F(p) = \sum_i p_i \log p_i$$

是凸函数。由它诱导的 Bregman divergence

$$D_F(p, q) = F(p) - F(q) - \nabla F(q)^\top (p - q)$$

恰好等于 $D_{\text{KL}}(p \| q)$ 。这说明 KL 的不对称不是缺陷，而来自 Bregman divergence 的定向结构。许多优化、mirror descent 与 exponential family 的几何都从这里连接起来。

4.12 Deep Dive: 互信息估计为什么危险

离散变量可直接由频数估计，但高维连续表示中的互信息常涉及密度比

$$\log \frac{p(x, z)}{p(x)p(z)}.$$

神经网络 hidden states 维度很高，有限样本密度估计非常困难。MINE、InfoNCE 等方法通常给界或代理目标，而不是无假设地精确得到真实 MI。因此看到“某层 mutual information 上升/下降”的论文图时，第一反应应是检查：估计器是什么？是上界还是下界？对表示的 deterministic transform 是否会产生病态情况？

4.13 Deep Dive: InfoNCE 与对比学习

给正样本对 (x, z^+) 与 $K - 1$ 个负样本 z_j^- ，典型 InfoNCE loss 为

$$-\log \frac{e^{s(x, z^+)/\tau}}{e^{s(x, z^+)/\tau} + \sum_j e^{s(x, z_j^-)/\tau}}.$$

它看起来像 softmax 分类，实质上是在学习密度比或互信息下界。Embedding 学习因此又回到本章主题：一个相似度分数经过 log-sum-exp 归一化后，就变成了概率判别与信息估计问题。

4.14 Deep Dive: MDL、Bayes evidence 与 Occam factor

Bayesian evidence

$$p(D) = \int p(D|\theta)p(\theta)d\theta$$

天然平均了整个参数空间。一个高度灵活的模型即使存在极高 likelihood 的窄区域，也必须为大量低 likelihood 参数区域付出积分代价。Laplace 近似下，evidence 中会出现 Hessian 行列式相关项，可解释为 posterior volume 与 prior volume 的比值，即一种 Occam factor。

这与 MDL 的“模型描述成本 + 数据描述成本”不是完全同一公式，但两者共享一个深层原则：只看训练拟合度不足以比较模型，还要考虑为了获得这种拟合付出了多少有效复杂度。

4.15 Deep Dive: token-level KL 与 sequence-level KL

若 p, q 都按自回归分解，则 sequence-level forward KL 可以分解：

$$\begin{aligned} D_{\text{KL}}(p(x_{1:T})||q(x_{1:T})) &= \mathbb{E}_p \left[\log \frac{p(x_{1:T})}{q(x_{1:T})} \right] \\ &= \sum_{t=1}^T \mathbb{E}_{p(x_{<t})} D_{\text{KL}}(p(x_t|x_{<t})||q(x_t|x_{<t})). \end{aligned}$$

所以每一步很小的条件分布偏差会沿长度累积。对长链 Agent，这意味着局部 policy shift 即使看起来微小，也可能在长 horizon 产生显著轨迹分布变化。

分层训练 | A 基础层

1. 计算 $p = (0.9, 0.1)$ 的熵以及用 $q = (0.5, 0.5)$ 编码的交叉熵。
2. 证明 $H(p, q) = H(p) + D_{\text{KL}}(p||q)$ 。
3. 解释为什么 PPL 不能在不同 tokenizer 间直接比较。

分层训练 | B 推导层

1. 用 $\log u \leq u - 1$ 证明 Gibbs inequality。
2. 证明 sequence-level KL 的自回归分解。
3. 对二分类 log loss 证明 strict propriety。

分层训练 | C 研究层

1. 在小语言模型上比较 parameter distance、logit KL、sequence KL 与行为指标的相关性。

2. 设计“对齐弹性”实验：固定 alignment 数据量，改变 pretraining 数据量，观察进一步 fine-tuning 后的行为恢复速度。
3. 用 bits-per-byte 而非 PPL 比较两个 tokenizer 不同的小模型，讨论结论是否改变。

4.16 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

KL、互信息与 data processing 将贯穿 第 11 章的语言建模、第 18 章的 KL-regularized RL 与 第 19 章的信息获取。

Worked Example | 交叉熵差一位意味着什么

真实分布 $p = (0.9, 0.1)$ 。模型 $q_1 = (0.8, 0.2)$ 与 $q_2 = (0.6, 0.4)$ 的 nats 交叉熵分别为

$$H(p, q_1) = -0.9 \log 0.8 - 0.1 \log 0.2 \approx 0.362,$$

$$H(p, q_2) \approx 0.551.$$

差值约 0.189 nats/token。对十亿 token 的数据，这个很小的 per-token 差异累积成约 1.89×10^8 nats 的总对数似然差。

Proof Clinic | 从 Gibbs inequality 到 MLE

由定理 4.1, $D_{\text{KL}}(p||q) \geq 0$, 故

$$H(p, q) = H(p) + D_{\text{KL}}(p||q) \geq H(p).$$

等号仅在 $p = q$ (几乎处处) 时成立。这给交叉熵一个严格解释：它不是随意挑的分类损失，而是使用 q 编码来自 p 的数据时，相对最优编码多付出的平均代价。

Research Assignment | 信息论指标审计

选择一个语言模型实验，除 accuracy 外同时报告 NLL/BPB、calibration 与 selective prediction。要求解释每个指标是否 proper、是否受 tokenizer 改变影响，以及能否从指标变化推出模型‘知道更多信息’。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. 论文中的“compression”进入了哪一部分正式推导，而哪些表述只是解释性直觉？
2. elasticity 的实验操作定义是什么？它测量的是参数恢复、输出分布恢复还是某个行为 benchmark 的恢复？
3. “模型越大 elasticity 越强”的相关关系可以推出哪些结论，不能推出哪些因果结论？
4. 预训练分布与 alignment 分布存在冲突时，怎样用 KL/description length 写出一个可检验的假设？
5. 如果 alignment 使用更大的数据集或不同 objective，compression-based 预测应怎样改变？

本章小结

信息论把“预测概率”变成了“描述长度”：熵是最佳平均码长，交叉熵是使用错模型的码长，KL 是额外代价，互信息衡量两个变量共享多少可预测结构。对 LLM 来说，next-token training 正是在压缩序列；但“压缩得好”与“行为稳定、可验证、对齐”之间仍有很长距离。下一章将进入优化：这些概率与信息目标，最终究竟怎样在数十亿参数中被找到？