

第 5 章 优化与学习动力学——参数究竟怎样被找到


本章目标

前四章已经告诉我们“什么目标值得最小化”。本章讨论另一个同样重要的问题：**优化器沿什么路径找到参数，而这条路径为什么会改变最终学到的函数？** 我们将从梯度与 Hessian 出发，推导 smooth convex function 上的梯度下降，分析二次型的谱动力学，再进入 SGD、momentum、AdamW、预条件化、natural gradient 和矩阵型优化。最后用 ICLR 2026 Honorable Mention *The Polar Express* 展示一个典型前沿研究范式：经典数值线性代数如何在 GPU、低精度与大模型训练约束下被重新发明。

Prerequisite Recall | 先把这些知识唤醒

- 会求一元/多元导数与梯度。
- 能把二次函数写成 $\frac{1}{2}x^T Ax - b^T x$ 。
- 记住“局部下降方向”和“全局最优”不是同义词。

Visual Derivation | 先看结构，再读公式



病态优化的核心不是“山谷很长”这句比喻，而是不同 Hessian 特征方向拥有完全不同的稳定时间尺度。

Misconception Check | 本章最容易掉进去的坑

“梯度指向最陡上升”依赖你采用的内积/度量。换一个预条件矩阵后，同一个微分对应的最陡方向会改变。因此 Adam、natural gradient、matrix optimizer 不只是“不同步长公式”。

Concept Contrast | 把相邻概念主动分开

	梯度下降	预条件梯度
更新	$-\eta g$	$-\eta P^{-1}g$
几何	欧氏	由 P 定义
目标	同一个标量 loss	同一个 loss
路径	可完全不同	可改善病态方向

Checkpoint | 开始正文前的 30 秒自测

对 Hessian 特征值最大为 L 的二次型，为什么步长过大可能发散？**检查答案：**每个谱方向乘以 $1 - \eta\lambda_i$ ；若某方向绝对值大于 1，误差会被放大。

5.1 梯度：局部最陡下降依赖你选择的几何

对可微函数 $L: \mathbb{R}^d \rightarrow \mathbb{R}$ ，一阶 Taylor 展开为

$$L(\theta + \Delta) = L(\theta) + \nabla L(\theta)^\top \Delta + o(\|\Delta\|).$$

若约束 $\|\Delta\|_2 \leq \epsilon$ ，要让线性近似下降最多，Cauchy-Schwarz 给出

$$\Delta^* = -\epsilon \frac{\nabla L}{\|\nabla L\|_2}.$$

因此“负梯度是最陡下降方向”隐含了一个条件：**我们使用欧氏范数定义一步有多大。**换一种参数空间度量，最陡方向也会改变，这正是 preconditioning 与 natural gradient 的入口。

5.2 Hessian：局部曲率决定稳定步长

二阶 Taylor 近似

$$L(\theta + \Delta) \approx L(\theta) + g^\top \Delta + \frac{1}{2} \Delta^\top H \Delta,$$

其中 $g = \nabla L(\theta)$ ， $H = \nabla^2 L(\theta)$ 。Hessian 的特征值描述各局部正交方向的曲率。大正特征值表示该方向非常“硬”，步长稍大就可能越过谷底；接近零的特征值对应平坦方向；负特征值则表示存在下降的负曲率方向。

5.3 凸性与 smoothness：什么时候梯度下降可证明收敛

定义 5.1 (凸函数). 若对所有 x, y 和 $\alpha \in [0, 1]$,

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y),$$

则称 f 为凸函数。

对可微凸函数，等价的一阶条件是

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x).$$

如果梯度还是 L -Lipschitz:

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L \|x - y\|_2,$$

则有 descent lemma:

$$f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2} \|y - x\|_2^2.$$

令 $y = x - \eta \nabla f(x)$, 当 $\eta \leq 1/L$:

$$f(x_{t+1}) \leq f(x_t) - \frac{\eta}{2} \|\nabla f(x_t)\|_2^2.$$

所以损失单调下降。

定理 5.1 (smooth convex 梯度下降的 $O(1/t)$ 收敛). 若 f 为凸且 L -smooth, 使用 $\eta = 1/L$, 则对最优解 x^* 有

$$f(x_t) - f(x^*) \leq \frac{L \|x_0 - x^*\|_2^2}{2t}.$$

深网一般非凸，所以这个 theorem 不是 LLM 训练保证。但它给我们建立了“步长-曲率-下降速度”的基本语法。

5.4 二次型：优化动力学的显微镜

考虑

$$L(w) = \frac{1}{2} w^\top A w - b^\top w, \quad A \succ 0.$$

最优解满足 $Aw^* = b$ 。令误差 $e_t = w_t - w^*$, 梯度下降更新为

$$e_{t+1} = (I - \eta A) e_t.$$

若 $A = Q \Lambda Q^\top$, 换到特征向量坐标 $z_t = Q^\top e_t$:

$$z_{t+1,j} = (1 - \eta \lambda_j) z_{t,j}.$$

每个谱方向独立收敛。稳定需要

$$|1 - \eta \lambda_j| < 1,$$

因此

$$0 < \eta < \frac{2}{\lambda_{\max}}.$$

若条件数

$$\kappa = \frac{\lambda_{\max}}{\lambda_{\min}}$$

很大，则一个全局步长必须照顾最陡方向，导致平坦方向进展极慢。这正是狭长峡谷中“之字形”的数学来源。

5.5 强凸性与线性收敛

若 f 是 μ -strongly convex 且 L -smooth, 则合适步长下梯度下降误差按几何级数衰减。对二次型, 取

$$\eta^* = \frac{2}{L + \mu}$$

时最坏方向收缩因子为

$$\rho = \frac{\kappa - 1}{\kappa + 1}.$$

条件数越大, ρ 越接近 1, 收敛越慢。这个公式给出了优化器设计的一个核心目标: 让不同方向看到更接近的有效曲率。

5.6 SGD: 噪声不是实现瑕疵, 而是动力学的一部分

经验风险

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n \ell_i(\theta)$$

的全梯度成本与 n 成正比。随机 mini-batch B 给出

$$g_B(\theta) = \frac{1}{|B|} \sum_{i \in B} \nabla \ell_i(\theta).$$

在均匀采样下它通常满足

$$\mathbb{E}[g_B(\theta)] = \nabla L(\theta).$$

但存在随机噪声

$$\xi_t = g_B - \nabla L.$$

小 batch 增大噪声, 大 batch 降低方差但提高单步成本。更微妙的是, 噪声结构并非总是各向同性, 它会与数据和 Hessian 几何耦合, 从而影响模型停留在哪类解附近。

5.7 Momentum: 用状态累积穿过狭长谷底

一种常见写法为

$$v_{t+1} = \beta v_t + g_t, \quad \theta_{t+1} = \theta_t - \eta v_{t+1}.$$

如果梯度在某方向长期同号, 动量会累积速度; 若在陡峭方向反复翻转, 则正负更新会相互抵消。因此 momentum 可以减少某些方向的振荡, 并加速持续一致的方向。

对二次型可以把更新写成二阶线性递推, 并分析其特征根。Nesterov acceleration 则通过“先看前方位置再计算梯度”得到凸优化中的 $O(1/t^2)$ 目标误差率。

5.8 Adam 与 AdamW：坐标自适应到底做了什么

Adam 维护一阶与二阶矩指数平均：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t,$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2,$$

再做逐坐标缩放：

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}.$$

它的直觉是：历史上梯度幅度大的坐标步子缩小，幅度小的坐标相对放大。

L2 regularization 与 weight decay 在 Adam 中为何不同？

若把 $\frac{\lambda}{2} \|\theta\|^2$ 加入 loss，梯度多出 $\lambda\theta$ ，随后这个项会一起被 Adam 的坐标自适应因子缩放。AdamW 则把衰减直接从参数更新中解耦：

$$\theta \leftarrow (1 - \eta\lambda)\theta - \eta \frac{\hat{m}}{\sqrt{\hat{v}} + \epsilon}.$$

因此在 adaptive optimizer 中，“加 L2 penalty”和“做 decoupled weight decay”一般不是同一个更新。

5.9 预条件化：真正改变参数空间的度量

一般化更新

$$\Delta\theta = -\eta M^{-1}g, \quad M \succ 0.$$

等价于在度量

$$\|\Delta\|_M^2 = \Delta^\top M \Delta$$

下做最陡下降。Newton 法取 $M = H$ ；若二阶近似准确，便能把局部椭圆谷地“白化”为圆形。

在概率模型中，natural gradient 使用 Fisher information matrix

$$F(\theta) = \mathbb{E}_{x \sim p_\theta} [\nabla \log p_\theta(x) \nabla \log p_\theta(x)^\top],$$

更新

$$\Delta\theta = -\eta F^{-1}g.$$

它的核心动机是：参数坐标不同不应该改变“模型分布实际走了多远”。Fisher 提供了参数化不变的局部分布几何。

5.10 从逐元素优化到矩阵型优化

Transformer 的许多参数天然就是矩阵 $W \in \mathbb{R}^{m \times n}$ 。逐元素 Adam 把每个元素视为独立坐标，但矩阵还具有行、列、奇异值和旋转结构。Muon 一类方法尝试对矩阵梯度进行正交化/极分解相关变换，使更新更接近矩阵几何中的“均衡方向”。

对矩阵 G ，极分解写成

$$G = QH,$$

其中 Q 为半正交 polar factor, $H = (G^\top G)^{1/2} \succeq 0$ 。若 $G = U\Sigma V^\top$ ，则

$$Q = UV^\top.$$

这相当于把所有非零奇异值归一成 1，只保留左右奇异向量结构。

5.11 Research Frontier: The Polar Express

Research Frontier | The Polar Express: Optimal Matrix Sign Methods and their Application to the Muon Algorithm

会议身份: ICLR 2026 Outstanding Paper Honorable Mention。作者 Noah Amsel, David Persson, Christopher Musco, Robert M. Gower。

经典数值分析早已研究 polar decomposition 与 matrix sign，但传统算法往往追求高精度。深度学习里的需求不同：GPU 上矩阵乘法极快，训练更在意吞吐、固定少量迭代、低精度稳定，而不是把分解算到机器精度。

Polar Express 设计只用 matrix-matrix multiplication 的多项式迭代，并在每一步通过 minimax optimization 选择更新，使最坏情形逼近误差尽可能小。论文同时处理 bfloat16 的有限精度问题，并把方法接入 Muon，在 GPT-2 / FineWeb 的十亿级 token 训练设置中报告跨学习率的验证损失改进。

研究方法论: 一个“几十年前就解决”的数学问题，换到新硬件、新误差预算和新下游目标后，可能需要重新定义什么叫最优。前沿创新经常发生在目标函数改变，而不只是“发明一个新模块”。

论文: ICLR Proceedings; **奖项:** ICLR 2026 Awards。




图 5.1 经典 Newton-Schulz 型矩阵乘法迭代逐步逼近 SVD 给出的 polar factor。Frontier Lab 用它建立机制直觉；Polar Express 的创新在于进一步用 minimax 方法优化多项式更新，并处理现代低精度训练约束。

Mini Lab | Frontier Replication 5: 从 polar factor 到 optimizer ablation

运行 `labs/frontier/ch05_matrix_polar.py`，先验证只用矩阵乘法也能逼近 $UV^\top$ 。然后做三层扩展：(1) 改变条件数与矩阵长宽比，比较收敛速度；(2) 用 float32/float16 模拟低精度，观察数值失稳；(3) 在小 MLP 上比较 SGD、AdamW、以及“先把矩阵梯度近似正交化再更新”的 Muon-style toy optimizer，保持总计算预算近似一致。

From Textbook to Research | 本章之后你应该会问什么？

参数是矩阵时，什么才是“合理的一步”？逐元素坐标、自适应对角度量、Kronecker 近似、Fisher 几何、polar normalization 各自在保留什么不变量？优化器之间的差异究竟来自更快降低训练 loss，还是来自它们选择了不同的函数解？

5.12 Deep Dive: descent lemma 的完整推导

设 f 的梯度 L -Lipschitz。令 $\gamma(t) = x + t(y - x)$ ，定义 $g(t) = f(\gamma(t))$ 。由微积分基本定理，

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \nabla f(\gamma(t))^\top (y - x) dt \\ &= \nabla f(x)^\top (y - x) + \int_0^1 [\nabla f(\gamma(t)) - \nabla f(x)]^\top (y - x) dt. \end{aligned}$$

由 Cauchy-Schwarz 与 Lipschitz 条件, 第二项不超过

$$\int_0^1 Lt \|y - x\|^2 dt = \frac{L}{2} \|y - x\|^2.$$

这就得到 descent lemma。它展示了一个典型证明套路：把多维函数沿线段降成一维, 再用梯度平滑性控制积分余项。

5.13 Deep Dive: 强凸梯度下降的收敛因子

对 μ -strongly convex、 L -smooth 函数, 梯度映射具有夹逼。二次型已经给出最清楚图景: 每个特征方向的收缩因子是 $|1 - \eta\lambda_j|$ 。选

$$\eta = \frac{2}{L + \mu}$$

让端点 $\lambda = \mu, L$ 的绝对收缩率相等, 得到

$$\rho = \frac{L - \mu}{L + \mu} = \frac{\kappa - 1}{\kappa + 1}.$$

这是一种 minimax 选择: 优化最坏谱方向, 而不是平均方向。注意这个思想与 Polar Express 的“每步优化最坏逼近误差”在方法论上高度相似。

5.14 Deep Dive: Momentum 的特征根

对一维二次函数 $f(x) = \frac{1}{2}\lambda x^2$, heavy-ball 更新

$$x_{t+1} = x_t - \eta\lambda x_t + \beta(x_t - x_{t-1})$$

给出递推

$$x_{t+1} - (1 - \eta\lambda + \beta)x_t + \beta x_{t-1} = 0.$$

特征方程

$$r^2 - (1 - \eta\lambda + \beta)r + \beta = 0$$

决定收敛与振荡。不同 λ 对应不同根, 因此选择 η, β 本质上是在设计一个同时控制整段谱区间的二阶滤波器。

5.15 Deep Dive: 为什么 gradient clipping 改变优化问题

global norm clipping 常写成

$$\tilde{g} = g \cdot \min\left(1, \frac{c}{\|g\|}\right).$$

它常被描述为“避免梯度爆炸”，但从动力学看，它把大梯度区域的更新方向保留、长度截断，使有效步长依赖当前梯度范数。于是 clipping 不只是数值保护，也改变了连续时间极限和不同 batch 的贡献权重。在 LLM 训练中，如果频繁触发 clipping，记录 clipping fraction 是理解优化状态的重要诊断。

5.16 Deep Dive: 自然梯度来自 KL 局部二阶展开

我们希望最小化一阶损失变化 $g^\top \Delta$ ，同时限制模型分布不要走太远：

$$D_{\text{KL}}(p_\theta \| p_{\theta+\Delta}) \leq \epsilon.$$

在 $\Delta = 0$ 附近，KL 的一阶项为零，二阶近似

$$D_{\text{KL}}(p_\theta \| p_{\theta+\Delta}) \approx \frac{1}{2} \Delta^\top F(\theta) \Delta.$$

于是问题变成

$$\min_{\Delta} g^\top \Delta \quad \text{s.t.} \quad \frac{1}{2} \Delta^\top F \Delta \leq \epsilon.$$

Lagrange multiplier 给出

$$\Delta \propto -F^{-1}g.$$

所以 natural gradient 不是凭空提出的预条件矩阵，而是“在固定 KL 步长下下降最快”的方向。

5.17 Deep Dive: 极分解与 matrix sign

对满秩矩阵 $G = U\Sigma V^\top$ ，polar factor $Q = UV^\top$ 。若构造对称块矩阵

$$M = \begin{bmatrix} 0 & G \\ G^\top & 0 \end{bmatrix},$$

其 matrix sign 与 Q 有紧密关系。多项式迭代可以用反复矩阵乘法把奇异值映射到接近 1，同时保持奇异向量。这正适合 GPU：GEMM 吞吐极高，而显式 SVD/QR 往往更昂贵或同步更复杂。

经典 Newton-Schulz 极分解迭代可写成

$$X_{k+1} = \frac{3}{2}X_k - \frac{1}{2}X_k X_k^\top X_k,$$

在适当缩放与谱条件下把奇异值推向 1。Polar Express 的关键不是发明“用多项式近似 matrix sign”本身，而是针对有限迭代预算与现代数值条件重新优化多项式。

5.18 Deep Dive: 优化器研究怎样做公平实验

比较优化器非常容易得到误导结果。至少要控制：

- 相同 token / sample budget，而不只是相同 step；
- 分别调优学习率，因为不同优化器的最佳尺度不同；
- 报告 wall-clock 与 FLOPs，而不只报告 step 数；
- 控制 weight decay、gradient clipping、warmup、schedule；
- 多随机种子与置信区间；
- 既看训练 loss，也看 validation loss 与最终任务指标。

若一个新 optimizer 每步贵 30%，却只按 step 比较 loss，就可能把额外计算量误认成算法优势。

分层训练 | A 基础层

1. 对 $f(x, y) = \frac{1}{2}(x^2 + 100y^2)$ 写出梯度和 Hessian。
2. 推导二次型梯度下降稳定步长 $0 < \eta < 2/\lambda_{\max}$ 。
3. 解释 mini-batch 从 32 增到 1024 对单步梯度方差与计算成本的影响。

分层训练 | B 推导层

1. 完整证明 descent lemma。
2. 推导 heavy-ball 在一维二次函数上的特征方程并画稳定区域。
3. 从 KL 约束优化推导 natural gradient 方向。

分层训练 | C 研究层

1. 对同一小 Transformer，比较 AdamW 与 matrix-orthogonalized toy optimizer 的训练曲线、wall-clock 与谱统计。
2. 统计每层梯度矩阵的 singular value distribution，研究“正交化更新”改变了哪些谱方向。
3. 在 float16 中实现 Newton-Schulz，系统扫描初始缩放与条件数，寻找失稳边界，再与 float32 对比。

5.19 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

本章的谱动力学和预条件化会进入 第 10 章的大模型训练与 第 18 章的 policy optimization。

Worked Example | 二次型上的 GD 是谱滤波

对 $f(w) = \frac{1}{2}w^T H w - b^T w$, $H = \text{diag}(1, 9)$, $\eta = 0.1$ 。误差在特征方向上满足

$$e_{t+1,j} = (1 - \eta\lambda_j)e_{t,j}.$$

因此两个方向的倍率分别是 0.9 和 0.1；曲率大的方向几乎一步被消掉，而平坦方向很慢。优化轨迹因此天然携带数据谱信息。

Proof Clinic | smoothness 为什么给出下降引理

若 ∇f 是 L -Lipschitz, 则

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2.$$

令 $y = x - \eta\nabla f(x)$ 得

$$f(y) \leq f(x) - \eta(1 - L\eta/2)\|\nabla f(x)\|^2.$$

所以 $0 < \eta < 2/L$ 时每步不增。这是后面分析深网局部稳定、学习率 scaling 与预条件化的最小模板。

Research Assignment | Muon/Polar 的数值稳定性审计

对随机矩阵族扫描 condition number, 比较 SGD、Adam-like diagonal preconditioner 与 matrix-sign/polar update 的方向性。必须报告迭代残差、矩阵谱、计算成本, 并检查低精度下 Newton-Schulz 型迭代何时失稳。

最低交付: 1 页假设与指标声明; 可复现代码与固定 seed; 主结果图; 至少一个失败/反例; 200–400 字结论边界。**禁止:** 只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. Polar Express 真正近似的数学对象是什么? 为什么 polar factor 与 Muon 更新有关?

2. 论文优化的是平均逼近误差还是 worst-case/minimax 误差？这种选择为什么适合固定少量迭代？
3. 为什么 GPU 场景偏好纯 matrix multiplication 的方法？若在 CPU 或高精度科学计算中，结论会不会不同？
4. bfloat16 的误差会在哪些谱区域最危险？“理论上收敛”是否足以保证低精度实现稳定？
5. 新 polar solver 带来的 validation loss 改善是否抵消了它本身的额外计算成本？应怎样报告端到端收益？

本章小结

优化器不是一个把 loss 自动变小的黑盒。梯度取决于度量，Hessian 决定局部曲率，条件数决定谱方向的时间尺度，SGD 噪声与 momentum 改变轨迹，AdamW 改变坐标尺度，预条件化与 natural gradient 则显式重写几何。到这里，第一篇“学习的数学骨架”已经完整：风险告诉我们学什么，线性代数告诉我们表示在哪里，概率告诉我们怎样表达不确定性，信息论告诉我们分布错多少，优化告诉我们参数如何真正移动。下一篇开始，我们把这些数学部件装进具体模型。