

第 6 章 线性回归不是“简单模型”——投影、隐式偏置与谱动力学

本章目标

线性回归是本书第一个可以把统计估计、几何投影、闭式解、优化路径、正则化、泛化与训练时间放进同一个坐标系的模型。本章不把它当作“深度学习之前的旧算法”，而把它当作复杂学习现象的可解析实验室。你将推导 OLS 与 ridge，证明投影与最小范数性质，得到梯度下降逐谱方向的精确动力学，并理解 early stopping 为什么本身就是一种正则化。最后用 ICML 2026 的 grokking 工作展示：一个看似只属于大模型的“先记忆、后泛化”现象，怎样被压缩到 ridge regression 中做可证明研究。

Prerequisite Recall | 先把这些知识唤醒

- 已掌握投影、SVD、伪逆（第 2 章）与梯度下降谱动力学（第 5 章）。
- 会区分估计参数 $\hat{w}$ 与预测 $X\hat{w}$ 。
- 记住“解不唯一”不必意味着“训练集预测不唯一”。

Misconception Check | 本章最容易掉进去的坑

过参数化时 $Xw = y$ 有无穷多解，并不意味着梯度下降会任意选一个。初始化与优化动力学可以产生**隐式偏置**，例如从零初始化的线性最小二乘倾向最小范数解。

Concept Contrast | 把相邻概念主动分开

	Ridge	Early stopping
类型	显式正则	动力学正则
谱滤波	$\sigma/(\sigma^2 + \lambda)$	随训练时间变化
是否完全等价	否	否
共同点	先学/保留大奇异值方向，抑制病态方向	

Checkpoint | 开始正文前的 30 秒自测

若 X 秩不足，为什么 w 可以不唯一但 fitted value Xw 仍可唯一？**检查答案：**两个解之差可落在 $\mathcal{N}(X)$ ，而 null-space 分量不会改变 Xw 。

6.1 从单变量直线到矩阵问题

给定设计矩阵 $X \in \mathbb{R}^{n \times d}$ 与目标 $y \in \mathbb{R}^n$ ，线性预测写成

$$\hat{y} = Xw, \quad w \in \mathbb{R}^d.$$

取平方损失

$$L(w) = \frac{1}{2n} \|Xw - y\|_2^2.$$

展开并求梯度：

$$L(w) = \frac{1}{2n} (w^\top X^\top X w - 2y^\top X w + y^\top y),$$

$$\nabla L(w) = \frac{1}{n} X^\top (Xw - y).$$

驻点满足正规方程

$$X^\top X w = X^\top y.$$

若 X 列满秩，得到唯一解

$$\hat{w} = (X^\top X)^{-1} X^\top y.$$

6.2 几何解释：最小二乘就是正交投影

预测向量 Xw 必须落在 X 的列空间 $\mathcal{C}(X)$ 中。我们真正做的是：在这个子空间里寻找距离 y 最近的点。

命题 6.1 (最小二乘残差与列空间正交). 任一最小二乘解 $\hat{w}$ 的残差 $r = y - X\hat{w}$ 满足

$$X^\top r = 0.$$

因此 $r \perp \mathcal{C}(X)$ 。

证明. 正规方程给出 $X^\top (X\hat{w} - y) = 0$ ，即 $X^\top r = 0$ 。这意味着 r 与 X 的每一列正交，也就与整个位于这些列张成空间中的向量正交。□

为什么这个几何视角如此重要？

以后在 embedding、LoRA、子空间编辑和低秩优化里，我们会反复问：“一个更新应该落在哪个子空间？”最小二乘已经给出原型：**学习可以被理解为把目标投影到模型能够表达的集合上。**

6.3 秩不足时：解不唯一，但预测可以唯一

当 $d > n$ 或特征高度共线时， $X^\top X$ 可能奇异。如果 $z \in \mathcal{N}(X)$ ，那么

$$X(w + z) = Xw.$$

因此不同参数可以表示完全相同的训练集预测。此时 Moore–Penrose 伪逆给出

$$\hat{w}_{\min} = X^+ y,$$

它在所有最小二乘解中具有最小 ℓ_2 范数。

定理 6.1 (最小范数插值解). 若 $Xw = y$ 可解，则 $w^* = X^+ y$ 满足 $Xw^* = y$ ，且对任意其他解 w 都有

$$\|w^*\|_2 \leq \|w\|_2.$$

证明思路 | 用行空间与零空间分解证明

任意解都可唯一写成 $w = w_{\parallel} + w_{\perp}$ ，其中 $w_{\parallel} \in \text{row}(X)$ ， $w_{\perp} \in \mathcal{N}(X)$ 。因为 $Xw_{\perp} = 0$ ，能决定训练预测的只有 $w_{\parallel}$ ；而

$$\|w\|_2^2 = \|w_{\parallel}\|_2^2 + \|w_{\perp}\|_2^2.$$

因此最小范数解必令 $w_{\perp} = 0$ 。伪逆恰好选择这一解。

6.4 统计视角：什么时候 OLS 是一个好估计量？

考虑线性数据生成模型

$$y = Xw_* + \varepsilon, \quad \mathbb{E}[\varepsilon \mid X] = 0,$$

并假设 X 固定、列满秩。则

$$\hat{w} = w_* + (X^\top X)^{-1} X^\top \varepsilon,$$

于是

$$\mathbb{E}[\hat{w} \mid X] = w_*.$$

若进一步 $\text{Cov}(\varepsilon \mid X) = \sigma^2 I$ ，则

$$\text{Cov}(\hat{w} \mid X) = \sigma^2 (X^\top X)^{-1}.$$

小特征值方向对应巨大的参数方差：这已经预告了为什么病态矩阵会让泛化不稳定。

定理 6.2 (Gauss–Markov, 简化表述). 在线性模型、零均值同方差噪声以及 X 满列秩条件下，OLS 是所有对 y 线性的无偏估计量中协方差最小的一个。

注 6.1. “BLUE” 不是说 OLS 在所有可能估计器中永远最好；它依赖**线性、无偏、同方差**这些限定。加入先验、允许偏差或模型错设后，ridge 等估计器可能有更低的预测风险。

6.5 SVD 把问题拆成彼此独立的谱方向

令

$$X = U\Sigma V^\top,$$

奇异值为 $\sigma_1 \geq \dots \geq \sigma_r > 0$ 。最小范数解为

$$X^+y = V\Sigma^+U^\top y = \sum_{i=1}^r \frac{u_i^\top y}{\sigma_i} v_i.$$

如果 σ_i 很小，噪声分量 $u_i^\top \varepsilon$ 会被 $1/\sigma_i$ 放大。SVD 因此把“共线性”“高方差”“条件数差”统一成了同一个现象：**小奇异值方向缺少可靠数据证据**。

6.6 Ridge：显式地压制不可靠方向

岭回归最小化

$$L_\lambda(w) = \frac{1}{2} \|Xw - y\|_2^2 + \frac{\lambda}{2} \|w\|_2^2,$$

闭式解为

$$\hat{w}_\lambda = (X^\top X + \lambda I)^{-1} X^\top y.$$

代入 SVD:

$$\hat{w}_\lambda = \sum_{i=1}^r \frac{\sigma_i}{\sigma_i^2 + \lambda} (u_i^\top y) v_i.$$

相对于 OLS 的 $1/\sigma_i$ ，ridge 的有效系数可写成

$$\frac{1}{\sigma_i} \underbrace{\frac{\sigma_i^2}{\sigma_i^2 + \lambda}}_{\text{spectral shrinkage}}.$$

$\sigma_i^2 \ll \lambda$ 的方向被强烈压缩。

Ridge 与高斯 MAP

若观测噪声 $y | w \sim \mathcal{N}(Xw, \sigma^2 I)$ ，先验 $w \sim \mathcal{N}(0, \tau^2 I)$ ，则负 log posterior（忽略常数）为

$$\frac{1}{2\sigma^2} \|Xw - y\|^2 + \frac{1}{2\tau^2} \|w\|^2.$$

因此 MAP 等价于 ridge，且 $\lambda = \sigma^2/\tau^2$ 。同一个公式同时是数值稳定化、频率学派正则化和 Bayesian 先验。

6.7 梯度下降：时间本身就是谱滤波器

对 $L(w) = \frac{1}{2n} \|Xw - y\|^2$ 做梯度下降：

$$w_{t+1} = w_t - \eta \frac{1}{n} X^\top (Xw_t - y).$$

记 $H = X^\top X/n = V\Lambda V^\top$ 。若从 $w_0 = 0$ 开始，并把最小范数解记为 w^+ ，则在第 i 个特征方向上

$$\langle w_t, v_i \rangle = [1 - (1 - \eta\lambda_i)^t] \langle w^+, v_i \rangle.$$

因此滤波系数是

$$g_t(\lambda) = 1 - (1 - \eta\lambda)^t.$$

大 λ 方向很快接近 1，小 λ 方向要很久才被学到。




图 6.1 同一个梯度下降在不同谱方向拥有不同时间尺度。早停等价于在训练尚未结束时主动丢弃慢的小特征值方向，因此是一种隐式谱正则化。

命题 6.2 (零初始化 GD 的最小范数隐式偏置). 若线性系统可插值，且 $w_0 = 0$ 、步长使 GD 收敛，则迭代始终位于 $\text{row}(X)$ ，极限解为最小范数插值解 X^+y 。

证明. 梯度 $X^\top(Xw - y)$ 总属于 $\text{row}(X)$ 。从 $0 \in \text{row}(X)$ 出发，每一步仍在行空间。所有插值解中唯一位于行空间的解就是 X^+y 。□

6.8 Early stopping 与 ridge：相像，但不是同一个滤波器

Ridge 的谱滤波器为

$$g_\lambda^{\text{ridge}}(s) = \frac{s}{s + \lambda},$$

而 GD early stopping 为

$$g_t^{\text{GD}}(s) = 1 - (1 - \eta s)^t.$$

二者都会先保留大特征值方向、抑制小特征值方向，但函数形状不同。因此“训练轮数”不是 ridge 系数的精确同义词；二者只是共享了谱偏置。

6.9 Interpolation、double descent 与现代过参数化

经典直觉常把训练误差降到 0 等同于过拟合，但现代模型常处于 interpolation regime：参数远多于样本，训练集被完全拟合，测试误差仍可能下降。一个关键原因是：**参数个数并不能单独决定有效复杂度**。解的范数、数据谱、噪声、优化路径和参数化都会改变被选中的插值函数。

在线性随机特征模型中，当参数数接近样本数时，小奇异值可能使噪声被剧烈放大；继续增加参数后，最小范数解的几何又发生变化，于是可能出现 double descent。这个现象提醒我们：研究深网泛化时不能只数参数。

6.10 Research Frontier：把 Grokking 压缩进 Ridge Regression

Research Frontier | To Grok Grokking: Provable Grokking in Ridge Regression

会议身份：ICML 2026 Outstanding Paper Honorable Mention。^a

Grokking 描述一种反直觉训练轨迹：模型很快把训练集拟合得很好，但测试表现长期很差；继续训练后，泛化突然或显著改善。该工作表明，这种两阶段行为无需依赖 Transformer、离散算法任务或神秘的 feature emergence；在 ridge regression 这样纯线性、可解析的模型里也能构造并证明。

本章视角：一旦把数据分解到不同谱/子空间方向，“先拟合”与“后泛化”就可以对应不同时间尺度。研究者的关键动作不是给现象起名字，而是寻找**最小仍保留该现象的模型**，使训练动力学可以精确求解。

方法论：当深网出现一个难解释现象时，先问它是否能在 linear regression、deep linear network、kernel 或 teacher-student model 中复现。若能，先证明 toy model，再回到大模型验证哪些机制真正迁移。

^aICML 2026 官方奖项页：[Announcing the ICML 2026 Awards](#).

Mini Lab | Frontier Replication 6：谱滤波、早停与两阶段时间尺度

运行 `labs/frontier/ch06_spectral_filters.py`。脚本构造两个特征值相差约 30 倍的方向，并画出 GD 的谱滤波系数。**基础任务：**验证达到 50% 学习比例所需步数近似与 $1/(\eta\lambda_i)$ 成正比。**进阶任务：**加入标签噪声，比较 test risk 随训练时间的 U 型曲线与 ridge 曲线。**研究任务：**构造三组谱带，使训练表现出现三个明显时间尺度，再讨论什么条件下这种“阶段性”足以被称为 grokking。

From Textbook to Research | 从线性模型去哪里？

我们已经看到：即使损失凸、闭式解已知，**优化路径仍然会选择特定函数**。进入分类与深网后，闭式解消失，但 implicit bias 不会消失。下一章将看到一个更惊人的例子：可分数据上的 logistic regression 没有有限最优参数，梯度下降却仍会把方向推向最大间隔分类器。

6.11 Deep Dive: 从 Gradient Flow 得到连续时间谱滤波

把步长趋近 0，梯度下降变成微分方程

$$\dot{w}(t) = -X^\top(Xw(t) - y).$$

在 $X^\top X = V\Lambda V^\top$ 的特征坐标中，每个方向满足一阶线性 ODE：

$$\dot{z}_i(t) = -\lambda_i(z_i(t) - z_i^*).$$

从 $z_i(0) = 0$ 出发，解为

$$z_i(t) = (1 - e^{-\lambda_i t})z_i^*.$$

因此连续时间滤波器是 $1 - e^{-\lambda t}$ 。若 $\lambda t \ll 1$ ，它近似 λt ；若 $\lambda t \gg 1$ ，才接近 1。一个方向何时真正“进入模型”，由无量纲量 λt 控制。

6.12 Deep Dive: Bias–Variance 的逐谱分解

在固定设计、同方差噪声下，ridge 第 i 个方向的估计近似为

$$\hat{w}_i = \frac{\sigma_i^2}{\sigma_i^2 + \lambda} w_{*,i} + \frac{\sigma_i}{\sigma_i^2 + \lambda} u_i^\top \varepsilon.$$

第一项带来 bias，第二项带来 variance。对应平方误差包含

$$\underbrace{\left(\frac{\lambda}{\sigma_i^2 + \lambda}\right)^2 w_{*,i}^2}_{\text{bias}^2} + \underbrace{\sigma_\varepsilon^2 \frac{\sigma_i^2}{(\sigma_i^2 + \lambda)^2}}_{\text{variance}}.$$

小奇异值方向通常更值得 shrink，因为它们的信噪比最差。这比笼统地说“正则化防止过拟合”更精确。

6.13 Deep Dive: 为什么相关不等于因果

OLS 估计的是观测分布中的条件关系。如果

$$y = \beta x + \gamma z + \varepsilon,$$

但 z 被遗漏且与 x 相关，那么回归 $y \sim x$ 的系数会吸收一部分 z 的效应。即使训练误差极低，也不能把该系数直接解释为干预 $do(x)$ 的因果效应。LLM 能准确续写“吸烟”与“疾病”的共现，同样不自动等于拥有可干预的因果模型。

分层训练 | 本章分层训练

- A | 计算：**给定 $X = \text{diag}(10, 0.1)$ ，计算 OLS 与 $\lambda = 1$ 的 ridge 谱 shrinkage。
B | 推导：证明 $P = X(X^\top X)^{-1}X^\top$ 在满列秩时满足 $P^2 = P = P^\top$ 。
B | 证明：从零初始化证明 GD 在欠定线性回归中不会产生零空间分量。
C | 研究：比较 ridge、early stopping 与 truncated SVD 三种谱正则化器，在相同训练误差下哪一种对低信噪比方向更激进？

6.14 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

线性模型是第 8 章 feature learning 的对照组，也是第 17 章分析 ICL 算法的可解析实验场。

Worked Example | 正规方程、投影与伪逆是同一个故事

设

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad y = (1, 2, 2)^\top.$$

OLS 满足 $X^\top(X\hat{w} - y) = 0$ 。解得 $\hat{w} = (7/6, 1/2)^\top$ 。因此预测 $X\hat{w}$ 是 y 在 $\text{col}(X)$ 上的正交投影；若列不满秩，伪逆会选取同一预测对应的最小范数参数。

Proof Clinic | GD 为什么偏向最小范数解

对欠定线性系统 $Xw = y$ ，从 $w_0 = 0$ 开始的 GD 每一步增量都在 $\text{row}(X)$ 中。因此所有 w_t 都没有 $\mathcal{N}(X)$ 分量。若收敛到插值解，它只能是行空间中的唯一插值解，也就是定理 6.1 给出的最小范数解。这里 optimization path 本身就是 regularizer。

Research Assignment | 谱滤波统一实验

把 ridge、early stopping GD 与 truncated SVD 放在同一 synthetic inverse problem 上。横轴用 singular value，纵轴画三种方法的有效 filter；随后比较噪声水平变化时 bias/variance。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-

level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. 论文中的“grokking”是由训练 loss、测试 loss 还是某个结构量定义？不同定义会改变结论吗？
2. 两段时间尺度分别对应哪些谱/子空间量？能否写出显式收敛率？
3. 如果关闭 weight decay、改变初始化或提前停止，现象是否仍然存在？
4. 为什么“闭式解已知”并不会让训练动力学研究失去意义？
5. 线性模型中的机制迁移到 Transformer 时，哪些假设最可能首先失效？

习题

1. 推导正规方程，并从几何上解释为什么残差与列空间正交。
2. 证明满列秩情形下投影矩阵 $P_X = X(X^\top X)^{-1}X^\top$ 对称且幂等。
3. 从 SVD 推导伪逆，并证明最小范数性质。
4. 在 $y = Xw_* + \varepsilon$ 、 $\text{Cov}(\varepsilon) = \sigma^2 I$ 下推导 OLS 协方差。
5. 推导 ridge 闭式解，并写出逐奇异方向的 bias 与 variance。
6. 对二次损失推导 GD 的逐谱方向递推与稳定步长条件。
7. 比较 $g_t^{\text{GD}}(s)$ 与 $g_\lambda^{\text{ridge}}(s)$ ；找出一个让二者在某个指定 s_0 相等的 t, λ ，并说明为何不可能对所有 s 同时相等。
8. 证明从 $w_0 = 0$ 出发的 GD 在可插值欠定线性系统中收敛到最小范数解。
9. 编程构造 condition number 分别为 $10, 10^2, 10^4$ 的设计矩阵，比较 OLS、ridge 与 early stopping 的 test MSE。
10. 设计一个 toy dataset，使训练误差很快接近 0，但某个与泛化相关的慢方向要很久才学到。说明它与 grokking 的相同点和不同点。