

第 7 章 Logistic、Softmax 与 Logit 几何——分类如何变成概率学习

本章目标

分类问题最重要的升级不是“把实数预测改成类别预测”，而是把决策边界写成**条件概率模型**。本章从 odds 与指数族视角推导 logistic regression，从 log-sum-exp 推导 softmax 与交叉熵梯度，进一步分析 Hessian、凸性、可分数据上的 implicit max-margin bias、proper scoring rule 与 calibration。最后进入 ICLR 2026 Oral：如果把大量 prompt-response 的 logits 排成矩阵，为什么现代语言模型会显露出低秩结构？

Prerequisite Recall | 先把这些知识唤醒

- 会写 Bernoulli likelihood 与负对数似然。
- 熟悉点积 $w^T x$ 、凸函数与 Hessian。
- 第 4 章已经建立 cross-entropy/KL 的信息论解释。

Misconception Check | 本章最容易掉进去的坑

分类正确率达到 100% 并不意味着 cross-entropy 已经最小。在可分数据上，logistic loss 还能通过不断放大 margin 继续下降，参数范数甚至可能趋向无穷。

Concept Contrast | 把相邻概念主动分开

	Accuracy	Cross-entropy
只看 argmax?	是	否
关心置信度?	否	是
可微?	通常否	是
可分后仍有梯度?	无意义	通常有

Checkpoint | 开始正文前的 30 秒自测

为什么给所有 logits 同加常数 c 不改变 softmax？这暗示 logits 哪部分不可辨识？
检查答案：归一化分子分母同时乘 e^c ；公共平移方向不可辨识，只有相对 logit 有意义。

7.1 二分类：从 log-odds 到 sigmoid

设 $y \in \{0, 1\}$ 。如果直接假设概率 $p(y = 1 | x)$ 是 $w^\top x$ ，它可能跑出 $[0, 1]$ 。更自然的做法是对 odds 取对数：

$$\log \frac{p(y = 1 | x)}{p(y = 0 | x)} = w^\top x + b = z.$$

因为 $p(y = 0 | x) = 1 - p(y = 1 | x)$ ，解得

$$p(y = 1 | x) = \sigma(z) = \frac{1}{1 + e^{-z}}.$$

决策边界 $p = 1/2$ 等价于 $z = 0$ ，仍然是一个超平面；概率则记录点距离边界的有符号程度。

7.2 MLE 自动导出 binary cross-entropy

Bernoulli 条件似然为

$$p(y | x; w) = p(x)^y [1 - p(x)]^{1-y},$$

其中 $p(x) = \sigma(w^\top x)$ 。负 log-likelihood 为

$$\ell(w; x, y) = -y \log p - (1 - y) \log(1 - p).$$

这就是 binary cross-entropy。它不是工程师拍脑袋选出的“常用损失”，而是条件 Bernoulli 模型的最大似然目标。

单样本梯度为什么变成 $(p - y)x$?

令 $z = w^\top x$ 。利用 $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ ，可得

$$\frac{\partial \ell}{\partial z} = p - y, \quad \nabla_w \ell = (p - y)x.$$

梯度因此是“概率残差 $\times$ 特征”。线性回归里是 $(\hat{y} - y)x$ ；logistic 只把欧氏残差换成了概率空间中的残差。

7.3 凸性：非线性概率并不意味着优化非凸

对数据矩阵 X ，logistic loss 的 Hessian 为

$$\nabla^2 L(w) = \frac{1}{n} X^\top R X,$$

其中 $R = \text{diag}(p_i(1 - p_i)) \succeq 0$ 。因此

$$v^\top \nabla^2 L(w) v = \frac{1}{n} (Xv)^\top R (Xv) \geq 0.$$

所以 logistic regression 对参数 w 是凸问题。注意“模型输出经过 sigmoid 是非线性的”和“损失关于参数非凸”是两件不同的事。

7.4 多分类：Softmax 是多类 log-odds 的归一化

对 K 个类别给出 logits $z_1, \dots, z_K$ ，定义

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}.$$

softmax 满足平移不变性：

$$\text{softmax}(z + c\mathbf{1}) = \text{softmax}(z).$$

因此 logits 的绝对零点没有意义，只有差值有意义。特别地，

$$\log \frac{p_i}{p_j} = z_i - z_j.$$

这就是 logit space 的一个重要“规范自由度”： z 与 $z + c\mathbf{1}$ 表示同一概率分布。

7.5 Log-sum-exp: softmax 的势函数

定义

$$\text{LSE}(z) = \log \sum_j e^{z_j}.$$

它满足

$$\max_j z_j \leq \text{LSE}(z) \leq \max_j z_j + \log K,$$

所以是 max 的光滑近似，并且

$$\frac{\partial \text{LSE}}{\partial z_k} = p_k.$$

对真实类别 y 的 cross-entropy，

$$\ell(z, y) = -z_y + \text{LSE}(z),$$

于是

$$\frac{\partial \ell}{\partial z_k} = p_k - \mathbf{1}[k = y].$$

命题 7.1 (Softmax cross-entropy 的 Hessian). 对 logits z ,

$$\nabla_z^2 \ell = \text{diag}(p) - pp^\top \succeq 0.$$

证明思路 | 把 Hessian 看成类别随机变量的协方差

若 e_Y 是 one-hot 类别向量, $Y \sim p$, 则

$$\text{Cov}(e_Y) = \mathbb{E}[e_Y e_Y^\top] - \mathbb{E}[e_Y] \mathbb{E}[e_Y]^\top = \text{diag}(p) - pp^\top.$$

协方差矩阵总是半正定, 因此 Hessian 半正定。其零空间包含 $\mathbf{1}$, 恰好对应 softmax 的平移不变性。

7.6 数值稳定性：为什么实践中通常减去最大 logit?

直接计算 e^{1000} 会溢出, 但由于 softmax 平移不变, 可令 $m = \max_j z_j$:

$$p_k = \frac{e^{z_k - m}}{\sum_j e^{z_j - m}}.$$

此时最大指数为 1。类似地, 稳定的 log-sum-exp 写成

$$\text{LSE}(z) = m + \log \sum_j e^{z_j - m}.$$

现代 LLM 的词表可能有十万量级 token, 这个看似初等的数值技巧每天被调用数十亿次以上。

7.7 可分数据上的奇异现象：正确率早已 100%，权重还在长

若二分类数据线性可分, 存在 w 使所有样本满足 $y_i w^\top x_i > 0$ (这里令 $y_i \in \{-1, +1\}$)。logistic loss

$$\ell_i = \log(1 + e^{-y_i w^\top x_i})$$

可以通过不断放大 $\|w\|$ 而趋近 0, 却通常没有有限范数的最优点。

更有意思的是, 在合适条件下, 梯度下降的方向会趋近 hard-margin SVM 的最大间隔方向:

$$\frac{w_t}{\|w_t\|} \longrightarrow \frac{w_{\text{mm}}}{\|w_{\text{mm}}\|}.$$

因此优化器在没有显式 margin 项的情况下产生了 implicit bias。

为什么这件事对深度学习重要?

现代神经网络常把训练 loss 压到极低, 甚至完全插值。此时“哪个参数让训练误差最小”无法解释泛化, 因为满足条件的参数太多。更关键的问题是: 优化算法在这些解中偏好哪一类函数?

7.8 概率诚实性：Cross-entropy 是 proper scoring rule

设真实事件来自 $\text{Bernoulli}(p)$ ，你报告概率 q 。期望 log-loss 为

$$\mathcal{L}(q) = -p \log q - (1 - p) \log(1 - q).$$

对 q 求导并令其为 0：

$$-\frac{p}{q} + \frac{1-p}{1-q} = 0 \quad \Rightarrow \quad q = p.$$

因此期望意义下诚实报告真实概率最优。0-1 accuracy 做不到这一点：报告 0.51 与 0.99，只要 argmax 相同就没有区别。

7.9 Calibration：概率高不等于事实正确

若模型对所有置信度约为 0.8 的预测中，约 80% 确实正确，我们称这一组预测近似校准。temperature scaling 用

$$p_k(T) = \frac{e^{z_k/T}}{\sum_j e^{z_j/T}}$$

改变分布尖锐程度； $T > 1$ 变平， $T < 1$ 变尖， argmax 不变。

但对 LLM 必须先问“校准哪个随机变量”：token 正确？整条 sequence？答案是否事实正确？verbalized confidence？这些不是同一对象。高 token probability 并不自动等于高 factual correctness。

7.10 Logit 矩阵：从单个分类器到模型的函数结构

对一组 prompts $x_1, \dots, x_m$ 和候选 responses $y_1, \dots, y_n$ ，可以构造一个 logit/score 矩阵

$$L_{ij} = s_\theta(x_i, y_j).$$

如果 L 近似低秩，意味着大量输入输出关系可由少数潜在方向组合：

$$L \approx UV^\top, \quad U \in \mathbb{R}^{m \times r}, V \in \mathbb{R}^{n \times r}, r \ll \min(m, n).$$

这与第 2 章的 SVD、低秩逼近以及本章的 logits 正好汇合。

7.11 Research Frontier: 语言模型的 Logits 真的近似低秩吗?

Research Frontier | Sequences of Logits Reveal the Low Rank Structure of Language Models

会议身份: ICLR 2026 Oral。^a

Golowich、Liu 与 Shetty 不从隐藏层神经元出发, 而把 LLM 抽象成 sequential probabilistic model, 直接研究由不同 prompt/response 的 logits 组成的矩阵。他们报告多种现代语言模型都表现出低近似秩, 并进一步展示这种结构可以被用于生成和理论分析。

创新点不只是“做 SVD”: 真正的研究问题是选择什么可观测量作为模型的函数表征。参数空间巨大且不同架构不可直接比较; logits 却是所有语言模型最终都必须暴露的行为量。把“内部表示是否低维”改写成“可观测量函数矩阵是否低秩”, 使问题变得 architecture-agnostic。

与你刚学的数学连接: softmax 的平移自由度意味着分析 logits 时必须处理 gauge; SVD 则给出最佳低秩逼近。一个分类章节因此直接通向“如何研究 LLM 的低维函数结构”。

^aICLR 2026 Oral 日程: [Thursday 04/23 Oral Session 2B](#)。论文: [ICLR Proceedings](#)。




图 7.1 机制级实验: 由低秩潜变量生成的 prompt-response logit matrix 即使加入噪声, 奇异值谱仍出现明显拐点。真实论文的挑战在于证明这种结构不是人工构造的副产物, 并研究它能支持什么生成与学习保证。

Mini Lab | Frontier Replication 7: 从 Softmax 到 Low-Logit-Rank

运行 `labs/frontier/ch07_logit_rank.py`。**基础任务：**观察奇异值谱并用 Eckart–Young 定理计算不同 rank 的重构误差。**进阶任务：**对每一行 logits 加随机常数，验证 softmax 分布不变但原始矩阵秩可能改变；尝试先做 row-centering 再比较谱。**研究任务：**选一个可在本地运行的小语言模型，收集数十个 prompts 对固定候选 continuations 的 sequence log-probability，比较原矩阵、centered matrix 与随机矩阵的 effective rank。

From Textbook to Research | 下一步：如果边界线性不可分怎么办？

Softmax 最终仍是在某个表示 h 上做线性分类。如果原始输入中不存在好的超平面，真正关键的就不是换一个分类头，而是学习一个使任务变简单的表示。这正是神经网络的核心：feature learning。

7.12 Deep Dive: Softmax、指数族与最大熵

Categorical distribution 可以写成指数族形式

$$p(y = k | z) = \exp\{z_k - A(z)\}, \quad A(z) = \log \sum_j e^{z_j}.$$

$A(z)$ 就是 log-partition function。其梯度给出均值参数 p ，Hessian 给出充分统计量的协方差。于是“softmax 梯度”和“概率分布的局部几何”其实是同一件事。

7.13 Deep Dive: Cross-entropy、KL 与 Bayes 最优分类

若真实条件分布为 $p(y | x)$ ，模型为 $q_\theta(y | x)$ ，期望 cross-entropy 满足

$$\mathbb{E}_x H(p(\cdot | x), q_\theta(\cdot | x)) = \mathbb{E}_x H(p(\cdot | x)) + \mathbb{E}_x D_{\text{KL}}(p(\cdot | x) \| q_\theta(\cdot | x)).$$

第一项与模型无关，因此无限数据与无限容量下，最小化 cross-entropy 等价于恢复真实条件分布。

7.14 Deep Dive: 低秩 Logits 不等于低维 Hidden States

最后一层通常有 $z = Wh$ 。若 hidden state h 位于 r 维子空间，则 logits 至多有相应的低维结构；但反方向未必成立：不同 W, h 参数化可能产生相同函数矩阵。此外，softmax 还允许逐行加常数而不改变分布。因此研究“logit rank”时必须说明是否中心化、使用 raw logits 还是 log-probabilities，以及 rank 是 exact 还是 approximate。

分层训练 | 本章分层训练

- A | **计算**: 给定 logits $(3, 1, -2)$, 计算稳定 softmax 与交叉熵。
- B | **推导**: 证明 $\nabla^2 \text{LSE}(z) = \text{diag}(p) - pp^\top$ 。
- B | **证明**: 证明 binary log-loss 是 strictly proper scoring rule。
- C | **研究**: 为 logit matrix 设计三个不同的“去 gauge”方案, 并讨论它们对 singular values 的影响。

7.15 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

Softmax/logit 几何将在 第 13 章的 attention 权重、第 16 章的 sampling 与 第 18 章的策略分布中反复出现。

Worked Example | Softmax 的平移不变性

对任意常数 c ,

$$\text{softmax}(z + c\mathbf{1})_k = \frac{e^{z_k + c}}{\sum_j e^{z_j + c}} = \text{softmax}(z)_k.$$

因此 logits 只在去掉全体平移的一组等价类上可识别。数值实现中减去 $\max_j z_j$ 不会改变概率, 却能避免指数溢出。

Proof Clinic | 为什么 CE Hessian 是协方差

由命题 7.1, 单样本 logit Hessian 为

$$H = \text{diag}(p) - pp^\top.$$

对任意 v , $v^\top H v = \sum_k p_k v_k^2 - (\sum_k p_k v_k)^2 = \text{Var}_{K \sim p}(v_K) \geq 0$ 。所以 CE 对 logits 是凸的, 并且 $H\mathbf{1} = 0$ 正好对应 softmax 的平移不变方向。

Research Assignment | Logit rank 与校准联合诊断

从多个 prompt 收集 logits 矩阵, 比较 singular spectrum、temperature calibration 和 top-k accuracy。要求证明‘低秩’本身不推出‘校准’, 并构造一个 rank-1 但严重过度自信的反例。

最低交付: 1 页假设与指标声明; 可复现代码与固定 seed; 主结果图; 至少一个失败/反例; 200–400 字结论边界。**禁止**: 只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. 论文里的 low rank 是 exact rank、numerical rank 还是某个误差阈值下的 approximate rank?
2. logits 的平移不变性如何处理? 如果不处理, 会不会人为改变 rank?
3. 从 prompts 与 responses 的采样方式改变后, 低秩现象是否稳定?
4. “低秩可观测行为”能够推出哪些内部表示结论, 哪些不能?
5. 如果 low-rank structure 可用于生成, 收益来自压缩、插值还是模型间共享结构?

习题

1. 从 log-odds 线性假设推导 sigmoid。
2. 从 Bernoulli MLE 推导 binary cross-entropy, 并得到 $(p - y)x$ 梯度。
3. 推导 logistic loss 的 Hessian 并证明其凸性。
4. 证明 softmax 对 $z + c\mathbf{1}$ 不变, 并说明这对应什么参数不可辨识性。
5. 推导 log-sum-exp 的上下界与梯度。
6. 推导 softmax cross-entropy 对 logits 的梯度与 Hessian。
7. 对温度 T 求 $p_k(T)$ 的极限: $T \rightarrow 0^+$ 与 $T \rightarrow \infty$ 分别发生什么?
8. 证明在真实 Bernoulli 概率为 p 时, 期望 log-loss 在 $q = p$ 取得唯一最小值。
9. 编程画可靠性图, 并比较温度缩放前后的 ECE 与 NLL。
10. 构造一个低秩 logit matrix, 加 row-wise constant 后比较 raw rank 与 softmax 分布; 解释为什么函数等价不保证矩阵表示等价。