

第 8 章 神经网络与表示学习——从固定特征到 Feature Learning

本章目标

神经网络最重要的变化不是“参数更多”，而是**特征本身也成为可学习对象**。本章从 MLP 与 ReLU 的分段线性结构出发，给出表示能力与深度的可计算例子，再区分 expressivity、optimization 与 generalization。随后我们把网络写成 $f_{\theta}(x) = w^{\top}h_{\phi}(x)$ ，研究 representation learning、linear probe、invariance、lazy/feature-learning regime 与 superposition。最后用 NeurIPS 2025 award work 和 ICLR 2026 Oral 把表示几何直接接到 neural scaling laws。

Prerequisite Recall | 先把这些知识唤醒

- 会做矩阵乘法与链式法则。
- 知道线性层叠加仍是线性，因此需要非线性。
- 已理解“模型容量”和“训练能否找到好解”是两件事。

Visual Derivation | 先看结构，再读公式

```
graph LR; x((x)) --> W1x[W1x]; W1x --> sigma((σ(·))); sigma --> W2h[W2h]; W2h --> yhat((ŷ))
```

loss 改变的不只读出, 也可改变中间特征

Misconception Check | 本章最容易掉进去的坑

Universal Approximation 只说明“存在某组参数可以逼近”，不说明 SGD 能找到它，不说明需要多少宽度/数据，也不说明外推或鲁棒性。把表示存在性当成可训练性，是深度学习中最常见的逻辑跳步之一。

Concept Contrast | 把相邻概念主动分开

	Lazy / NTK-like	Feature learning
表示变化	小	显著
主要学习	读出层附近	特征本身
线性化解释	较有效	容易失效
研究问题	kernel behavior	representation dynamics

Checkpoint | 开始正文前的 30 秒自测

若把两层 MLP 的 ReLU 全部替换为恒等函数，深度还会增加函数类吗？**检查答案：**不会；多个线性映射的复合仍可合并成一个线性映射。

8.1 从手工特征到可学习表示

传统线性模型常写成

$$f(x) = w^\top \phi(x),$$

其中特征映射 ϕ 由人设计。神经网络把它改成

$$f_{w,\phi}(x) = w^\top h_\phi(x),$$

并用同一个训练目标同时学习表示参数 ϕ 与读出参数 w 。这就是 feature learning 的核心：模型不仅学习“在已有坐标里怎么分”，还学习“应该用什么坐标表示问题”。

8.2 MLP：函数组合与非线性

两层 MLP 为

$$h = \rho(W_1x + b_1), \quad f(x) = W_2h + b_2.$$

若 ρ 是恒等映射，则

$$W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2),$$

无论堆多少层都仍是仿射函数。因此**深度必须与非线性结合**才真正增加函数族。

常见激活包括

$$\text{ReLU}(z) = \max(0, z),$$

GELU 与 SiLU。Transformer 的 FFN/MLP block 本质上仍是对每个 token 独立应用的非线性特征变换。

8.3 ReLU 网络为什么是分段仿射函数？

固定输入区域内每个 ReLU 单元的开/关状态。对第 j 个单元，ReLU 等价于乘一个 $d_j \in \{0, 1\}$ 。整层可写成

$$h = D(Wx + b), \quad D = \text{diag}(d_1, \dots, d_m).$$

只要激活模式 D 不变，网络就是仿射映射。输入跨过某个 pre-activation 的零超平面时， D 改变，网络切换到另一块仿射区域。

命题 8.1 (一维 ReLU 网络的折线性质). 任意有限宽度、有限深度的 $ReLU$ 网络作用于 $x \in \mathbb{R}$ 时, 输出是连续分段线性函数。

这给出一个比“万能逼近”更可操作的直觉: 网络通过学习**折点的位置和每段斜率**来改变函数形状。

8.4 一个构造性逼近结论: 折线可以被 ReLU 精确表示

设连续分段线性函数的折点为 $t_1 < \dots < t_m$, 各段斜率依次变化。它可以写成

$$f(x) = a + bx + \sum_{j=1}^m c_j \text{ReLU}(x - t_j).$$

其中 c_j 正是跨过折点 t_j 后斜率的变化量。因此一隐藏层 ReLU 网络已经能精确表示任意一维折线; 若用足够细的折线逼近连续函数, 就得到 universal approximation 的一个直观构造入口。

“Universal Approximation” 不等于 “训练一定成功”

存在参数能表示目标, 不等于 SGD 容易找到它; 能在有限区间逼近, 不等于样本外泛化好; 宽度足够, 不等于参数效率高。研究神经网络必须分开三个问题: **expressivity、optimization、generalization**。

8.5 深度的价值: 不是神秘更强, 而是计算复用

考虑层级组合

$$f(x) = f_L \circ f_{L-1} \circ \dots \circ f_1(x).$$

若目标本身具有组合结构, 深网可以复用中间结果。一个浅层网络若要一次性表示所有组合, 可能需要更多单元。深度因此像程序中的子程序调用: 不是增加“魔力”, 而是改变计算图 factorization。

例 8.1 (XOR: 表示改变后, 线性不可分可以变成可分). XOR 的四个点在原始二维空间无法由单个超平面分开。但隐藏层可以先构造两个非线性区域, 再由输出层线性组合。这个例子最值得记住的不是 XOR 本身, 而是: **representation learning** 可以把困难的边界变成简单的读出。

8.6 怎样判断“表示变好了”?

给定中间表示 $h_\phi(x)$, 一种常见诊断是冻结 ϕ , 只训练一个线性 probe:

$$\min_W \sum_i \ell(W h_\phi(x_i), y_i).$$

如果简单线性读出就能恢复目标信息,说明该信息在表示中变得更线性可访问。但 linear probing 不是因果解释: probe 能读出信息,不等于原模型决策真的使用了它。

还可以研究类内/类间距离、CCA、SVCCA、CKA、effective rank、Jacobian 与 activation sparsity。所谓 representation learning 不是一个单一指标,而是一组关于几何、可读出性与不变量的问题。

8.7 Invariance 与 equivariance: 好表示不只是可分

如果任务对某个变换 g 不敏感,希望

$$h(gx) \approx h(x),$$

这是 invariance。若希望表示按可预测方式变换

$$h(gx) = \rho(g)h(x),$$

则是 equivariance。卷积利用平移 equivariance; 很多自监督学习目标则鼓励数据增强前后的表示接近。对语言模型, token permutation 一般不是不变量,因为顺序本身携带意义。

8.8 Lazy regime 与 feature-learning regime

网络在初始化 θ_0 附近做一阶展开:

$$f_\theta(x) \approx f_{\theta_0}(x) + \nabla_\theta f_{\theta_0}(x)^\top (\theta - \theta_0).$$

如果训练过程中参数移动很小、Jacobian 近似不变,模型行为接近一个固定特征/核方法,即常说的 lazy 或 NTK-like regime。若表示本身显著变化,则进入 feature-learning regime。

定义经验 tangent kernel

$$K_{ij}(\theta) = \nabla_\theta f_\theta(x_i)^\top \nabla_\theta f_\theta(x_j).$$

若 $K(\theta_t)$ 几乎不变,学习更接近固定核;若它明显演化,就说明模型正在改变“哪些样本彼此相似”的梯度几何。

8.9 Superposition: 特征比维度多时怎么办?

如果语义特征数 m 大于表示维数 d ,不可能给每个 feature 一个完全独立坐标。网络可能用许多近似正交方向把特征叠加在同一空间:

$$h \approx \sum_{j \in \mathcal{A}(x)} a_j v_j, \quad v_j \in \mathbb{R}^d, \quad m > d.$$

当每个样本只激活少数特征时，稀疏性允许许多 v_j 共存，代价是互相干扰。这就是 superposition 的几何原型。

8.10 Research Frontier I: Superposition 能解释 Scaling 吗?

Research Frontier | Superposition Yields Robust Neural Scaling

会议身份: NeurIPS 2025 Best Paper Runner-up。^a

该工作使用可控 toy model 调节 superposition 强弱，研究 loss 随表示维度增长为何会出现稳定幂律。在弱 superposition 下，数据 feature frequency 的分布会强烈影响 scaling；在强 superposition regime，下游 loss 对维度的幂律可更稳健。作者还对开源 LLM 做实证，尝试把宏观 scaling curve 与微观表示几何连接起来。

研究价值: 传统 scaling law 往往先拟合 $L(N) \approx L_\infty + aN^{-\alpha}$ ，再讨论指数。这里的问题倒过来：什么表示机制会自然产生这种幂律？这是从“经验规律”走向“机制解释”。

^aNeurIPS 2025 官方奖项: [Best Paper Awards](#).

8.11 Research Frontier II: Feature Learning Regime 中的谱如何决定 Scaling?

Research Frontier | Scaling Laws and Spectra of Shallow Neural Networks in the Feature Learning Regime

会议身份: ICLR 2026 Oral。^a

这项工作不满足于线性模型中的 scaling theory，而研究 quadratic/diagonal neural networks 的 feature-learning regime，并把 excess risk 的 scaling exponent 与 sample complexity、weight decay 以及训练后权重谱联系起来。结果出现不同 scaling regime、cross-over 与 plateau，并给出权重谱 power-law tail 与泛化之间的第一性解释。

本章连接: “网络更大所以 loss 更低”不是解释。feature learning 意味着训练本身在改变谱。于是宏观的 scaling exponent 可能是学习后表示/权重谱结构的投影。

^a论文: [ICLR Proceedings](#); Oral 列表: [ICLR 2026 Orals](#).




图 8.1 一个小 MLP 在拟合 XOR-like 数据时，不仅 cross-entropy 下降，隐藏表示中类别均值的分离度也同步提高。机制级实验的重点不是 benchmark，而是直接观察“特征空间本身在训练”。

Mini Lab | Frontier Replication 8: 测量 Feature Learning, 而不只测最终 Accuracy

运行 `labs/frontier/ch08_feature_learning.py`。基础任务：记录 hidden representation separation 与 loss 的时间轨迹。进阶任务：每隔若干步计算经验 NTK K_t 与 K_0 的 Frobenius 差，区分 lazy 与 feature-learning 程度。研究任务：改变 width、weight decay 与数据稀疏性，测 effective rank、feature overlap 和 test loss；检查是否出现稳定的幂律区间，而不是先假设一定有 scaling law。

From Textbook to Research | 表示能力之后是什么？

一旦特征也在学习，链式法则必须穿过整个表示函数 h_ϕ 。下一章不只是“教会你 backprop 公式”，而是研究一个更一般的问题：怎样在巨大计算图上，以与一次前向同阶的代价得到所有参数的梯度，并进一步用这些梯度解释样本之间的学习影响？

8.12 Deep Dive: 一维 ReLU 的 hinge basis

表达式

$$f(x) = a + bx + \sum_j c_j (x - t_j)_+$$

可以看成 spline 的 hinge basis。导数为

$$f'(x) = b + \sum_j c_j \mathbf{1}[x > t_j],$$

每跨过一个 t_j ，斜率增加 c_j 。这给出一个直接的“参数-几何”对应：bias 决定折点位置，输出权重决定斜率跳变量。

8.13 Deep Dive: 从参数梯度到 Neural Tangent Kernel

对平方损失，线性化模型

$$f_t \approx f_0 + J_0(\theta_t - \theta_0)$$

的梯度流满足训练集预测动力学

$$\dot{f}_t = -K_0(f_t - y), \quad K_0 = J_0 J_0^\top.$$

若 $K_0 = Q\Lambda Q^\top$ ，误差每个核特征方向以 $e^{-\lambda_i t}$ 衰减。你会发现这和第 6 章线性回归的谱动力学几乎同构：固定 NTK 把宽神经网络重新变成了一个线性可解析系统。

真正的 feature learning 则发生在 J_t 本身变化时。此时 K_t 不再固定，模型会动态改变自己对样本相似性的定义。

8.14 Deep Dive: Superposition 的一个容量直觉

若 m 个单位向量 $v_j \in \mathbb{R}^d$ 完全正交，最多只能有 d 个。但若只要求小内积 $|v_i^\top v_j| \leq \epsilon$ ，高维空间可以容纳远多于 d 的方向。稀疏激活让干扰项

$$\sum_{i \neq j} a_i (v_i^\top v_j)$$

在多数样本上保持可控，因此“features > dimensions”并不必然失败。

分层训练 | 本章分层训练

- A | **构造**：给定折点 $-1, 0, 2$ 与各段目标斜率，写出对应的一层 ReLU 网络。
- B | **推导**：从模型一阶 Taylor 展开推导固定 NTK 下的训练预测 ODE。
- B | **实验**：比较宽度 16、128、1024 的 MLP 在相同任务上的 NTK drift。
- C | **研究**：设计一个反事实实验区分“superposition 导致 scaling”与“feature frequency power law 导致 scaling”。

8.15 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

表示是否“学习”而非固定，是第 13 章 Transformer 表示与第 17 章 ICL 机制争论的基础。

Worked Example | 固定特征与 feature learning 的分界

两层网络 $f(x) = \frac{1}{\sqrt{m}} \sum_{j=1}^m a_j \sigma(w_j^T x)$ 。若训练期间 w_j 几乎不动，模型近似在初始化 Jacobian 提供的固定特征上做线性学习；若 w_j 产生 $O(1)$ 的有结构位移，表示本身被重组。比较两者时不能只看最终 loss，必须量化 feature drift。

Proof Clinic | ReLU 为什么能生成折线基

一维上 $\sigma(x - t) = \max(0, x - t)$ 在 t 处改变斜率。有限和

$$f(x) = a + bx + \sum_j c_j \sigma(x - t_j)$$

可以构造任意给定折点的连续分段线性函数。这里隐藏单元不是“神经元隐喻”，而是可学习的 hinge basis。深度则让这些基函数发生组合。

Research Assignment | Feature drift 与 superposition

训练一个小 MLP 同时完成稀疏多任务。记录输入层/隐藏层 CKA 或 Gram matrix、神经元 polysemanticity 与任务性能。改变 width 和 sparsity，检查 superposition 是否随容量压力系统变化。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. 论文中的 feature 如何定义？它是数据生成变量、神经元、方向还是可读出的概念？
2. strong superposition 的判据是什么？改变 basis 后结论是否稳定？
3. scaling exponent 是理论推导、拟合结果还是有限区间近似？
4. 如何用反事实实验判断谱是泛化的原因、结果还是相关指标？
5. toy model 中最可能无法迁移到真实 LLM 的假设是什么？

习题

1. 证明没有非线性激活时任意多层线性网络都可合并为一个线性层。
2. 用 ReLU hinge basis 精确表示绝对值函数 $|x|$ 与三段折线函数。
3. 解释 universal approximation、parameter efficiency 与 trainability 为什么是三个不同命题。
4. 构造 XOR 的两层 ReLU 解，并画出隐藏空间中的四个点。
5. 定义一个 linear probe 实验，并列出它不能证明的三个因果结论。
6. 区分 invariance 与 equivariance，并各给出一个视觉/语言例子。
7. 从 $f_{\theta}(x)$ 的一阶 Taylor 展开定义经验 NTK。
8. 在固定 NTK 下推导平方损失的训练误差谱动力学。
9. 用随机单位向量模拟 $m > d$ 时 pairwise inner product 的分布，研究维度 d 增大如何改变干扰。
10. 设计一个小规模 scaling 实验：至少改变模型维度、样本数和 weight decay 三个变量，并说明怎样避免把短区间直线误判为幂律。