

第 10 章 深度网络为什么能训起来——信号尺度、优化器状态与 Scaling

本章目标

“把网络堆深、把宽度放大”并不会自动带来能力。现代大模型训练依赖一整套稳定动力学：初始化要控制前向/反向方差，残差要提供近恒等通路，Normalization 要约束尺度，优化器要处理不同方向与噪声，还必须在显存中保存庞大的状态。本章从 mean-field 方差传播推导 Xavier/He 初始化，分析 residual 与 LayerNorm，再把 momentum、AdamW、optimizer-state memory 和 scaling law 连接起来。Frontier 部分进入 NeurIPS 2025 的 1000-layer networks、ICLR 2025 的 precision scaling，以及 ICLR 2026 Oral *Taming Momentum*：优化器状态本身能否被理解并压缩成低秩学习问题？

Prerequisite Recall | 先把这些知识唤醒

- 熟悉方差、独立近似与 Jacobian 链式乘积。
- 已掌握 momentum / AdamW 的基本更新。
- 能区分“激活尺度稳定”和“任务性能高”。

Misconception Check | 本章最容易掉进去的坑

LayerNorm 不是“自动解决梯度爆炸/消失”的万能稳定器，也不会让表示完全 scale-invariant。它规范某个轴上的均值/方差，但 residual、权重、 γ, β 与后续非线性仍决定整体动力学。

Concept Contrast | 把相邻概念主动分开

	Pre-Norm	Post-Norm
归一化位置	子层之前	residual 相加之后
identity 梯度通路	更直接	更受子层/Jacobian 影响
训练深网	常更稳	原始 Transformer 形式

Checkpoint | 开始正文前的 30 秒自测

为什么“参数只有 2 GB”并不意味着训练显存约 2 GB？**检查答案：**还要存梯度、优化器一/二阶状态、激活、临时 buffer；训练内存账本必须逐项算。

10.1 前向方差传播：初始化不是“随机小数”

考虑一层

$$z_j = \sum_{i=1}^{d_{\text{in}}} W_{ji} x_i.$$

若 W_{ji} 独立、零均值，与 x_i 近似独立，且 $\text{Var}(x_i) = q$ ，则

$$\text{Var}(z_j) \approx d_{\text{in}} \text{Var}(W_{ji}) q.$$

若想线性层前后方差同阶，需要

$$\text{Var}(W_{ji}) \sim \frac{1}{d_{\text{in}}}.$$

这已经解释了为什么权重方差必须随 fan-in 缩小。

10.2 Xavier 与 He 初始化

对近似对称激活，Xavier 常取

$$\text{Var}(W_{ij}) \approx \frac{2}{d_{\text{in}} + d_{\text{out}}}$$

以兼顾前向与反向尺度。

对 ReLU，若输入近似对称，约一半单元被截成 0，因此

$$\mathbb{E}[\text{ReLU}(z)^2] \approx \frac{1}{2} \mathbb{E}[z^2].$$

为了补偿这 1/2，He 初始化取

$$\text{Var}(W_{ij}) \approx \frac{2}{d_{\text{in}}}.$$

为什么“方差不爆炸”只是第一步？

方差分析只追踪二阶矩，不保证激活分布保持高斯、不保证不同神经元独立，也不保证 Jacobian 奇异值都接近 1。真正的深网稳定性需要研究整个 singular-value spectrum，而不是只看平均 norm。

10.3 Backward variance: 前向稳定还不够

若反传关系近似为

$$\delta^{(l)} = (W^{(l+1)})^\top \delta^{(l+1)} \odot \rho'(z^{(l)}),$$

则梯度方差同样受 fan-out、权重方差与激活导数影响。一个初始化若只保证 forward activation 不爆炸，却让 backward signal 每层缩小 0.8 倍，100 层后仍会几乎消失。

10.4 Residual: 把“学习整个映射”改为“学习增量”

Residual block 写成

$$h_{l+1} = h_l + \alpha F_l(h_l).$$

其 Jacobian 为

$$J_l = I + \alpha J_{F_l}.$$

相比纯 feed-forward 的长乘积，恒等项提供短路径。系数 α 也非常重要：若每层 residual update 都是 $O(1)$ ，深度增加时状态仍可能爆炸。很多深网参数化实际上在回答同一个问题：**随着深度/宽度增长，每层应该贡献多大的增量？**

10.5 Pre-Norm 与 Post-Norm: 归一化位置改变梯度通路

LayerNorm 定义

$$\mu = \frac{1}{d} \sum_{i=1}^d x_i, \quad \sigma^2 = \frac{1}{d} \sum_i (x_i - \mu)^2,$$

$$\text{LN}(x) = \gamma \odot \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta.$$

Transformer block 可粗略写成两种形式：

$$\text{Post-Norm: } h_{l+1} = \text{LN}(h_l + F_l(h_l)),$$

$$\text{Pre-Norm: } h_{l+1} = h_l + F_l(\text{LN}(h_l)).$$

Pre-Norm 的 residual 主干更直接接近恒等映射，通常更容易训练很深网络；Post-Norm 则会让每个残差和都经过 norm Jacobian。这里没有“永远更优”的单一句子，关键是分析信号与梯度路径。

10.6 LayerNorm 做了什么、没有做什么

对固定 γ, β , LayerNorm 对加上常数向量 $c\mathbf{1}$ 是精确不变的。若先忽略数值稳定项 ϵ , 它对正比例缩放 ax ($a > 0$) 也精确不变; 但真实实现含 $\epsilon > 0$ 时, scale invariance 只是当 $a^2\sigma^2 \gg \epsilon$ 时的近似, $a < 0$ 还会翻转标准化方向。LayerNorm 也不会自动白化跨样本协方差, 更不会让所有 Jacobian 奇异值等于 1。把“normalization”理解成“所有数值问题被解决”会掩盖很多真实训练机制。

10.7 Momentum: 优化器也有自己的状态动力学

Momentum 维护指数移动平均

$$m_t = \beta m_{t-1} + (1 - \beta)g_t.$$

展开:

$$m_t = (1 - \beta) \sum_{k=0}^t \beta^k g_{t-k}$$

(忽略初始项)。因此 momentum 是一个一阶低通滤波器: 最近梯度权重大, 旧梯度指数衰减。

若梯度长期沿相近方向, EMA 会积累一致信号; 若某方向正负交替, 会被部分抵消。这使 momentum 同时具有“加速”与“平滑噪声”的解释。

10.8 AdamW: 一阶矩、二阶矩与解耦衰减

Adam 维护

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1)g_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2)g_t^2,$$

并做逐坐标缩放。AdamW 进一步把 weight decay 与 adaptive gradient 解耦:

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}}.$$

优化器状态可以比参数本身更贵

若参数用 bf16 保存 2 bytes, 但 Adam 的一阶矩、二阶矩及 master weights 使用 fp32, 训练时每个参数的状态内存可能远超推理时的权重内存。大模型优化算法因此不仅比较 convergence curve, 也必须比较 **bytes per parameter, communication, matrix kernels** 与吞吐。

10.9 EMA 的另一个视角：它是在在线拟合什么？

对一串梯度矩阵 G_t ，EMA

$$M_t = \beta M_{t-1} + (1 - \beta) G_t$$

可以看成对近期梯度的加权统计。如果梯度历史主要落在一个低维子空间，那么 M_t 可能近似低秩：

$$M_t \approx U_t S_t V_t^\top, \quad r \ll \min(m, n).$$

这马上提出一个系统问题：为什么要为一个低内在维度的状态支付完整 mn 内存？

10.10 Scaling law：经验预测必须与机制区分

常见经验式例如

$$L(N) = L_\infty + aN^{-\alpha},$$

或同时依赖数据量 D 、计算量 C 。scaling law 的价值是预算规划与外推；但拟合直线并不是机制解释。指数 α 可能随数据分布、架构、optimizer、precision、训练 recipe 改变。

因此研究 scaling 至少有三层问题：

1. **描述层**：在当前区间是否确实近似 power law？
2. **预测层**：从小模型拟合能否外推大模型？
3. **机制层**：是什么数据谱、表示几何或优化动力学产生这个指数？

10.11 Research Frontier I: 1000 层网络提醒我们“深度上限”常来自训练配方

Research Frontier | 1000 Layer Networks for Self-Supervised RL: Scaling Depth Can Enable New Goal-Reaching Capabilities

会议身份：NeurIPS 2025 Best Paper。^a

该工作在 self-supervised / goal-conditioned RL 中把网络深度推到 1024 层，并报告随着深度扩展出现显著性能与行为提升。论文的重要信号不是“以后所有模型都应该 1000 层”，而是：某领域长期使用 2-5 层网络形成的经验边界，可能主要来自**优化**、**batch size**、**normalization** 与**训练 recipe**，而非任务本身不需要深模型。**本章问题**：深度为什么过去不可训练？哪些稳定化设计改变了 effective depth？“网络更深”与“真正使用了更深计算”又该如何区分？

^aNeurIPS 2025 官方奖项：Best Paper Awards.

10.12 Research Frontier II: Precision 本身也进入 Scaling Law

Research Frontier | Scaling Laws for Precision

会议身份：ICLR 2025 Oral。

这项工作系统研究低精度训练与 post-training quantization，提出 precision-aware scaling 的经验模型，并通过大量预训练实验分析 bit-width、模型规模、数据量之间的耦合。

研究启示：模型“规模”不能只用参数个数 N 表示。硬件上每个参数用多少 bit、累加使用什么精度、量化误差如何随数据和参数增长，都可能改变 compute-optimal 方案。Scaling law 因此连接算法、统计与系统。

10.13 Research Frontier III: Taming Momentum——把优化器状态重新写成低秩学习问题

Research Frontier | Taming Momentum: Rethinking Optimizer States Through Low-Rank Approximation

会议身份：ICLR 2026 Oral。^a

Wang 等把 Adam/Muon 中 EMA momentum 重新解释为一种 online gradient flow / linear regressor 学习过程，并据此提出 LoRA-Pre：不用完整矩阵保存优化器状态，而是在紧凑低秩子空间中表示 momentum。论文在 60M 到 1B Llama-family 预训练以及更大模型 fine-tuning 中验证 rank efficiency 与性能。

创新点：它没有把 low-rank 当作“事后 SVD 压缩技巧”，而是先改变对 optimizer state 的数学解释，再从该解释导出算法。研究者真正做的是

EMA state

 $\longrightarrow$ online learning object $\longrightarrow$ low-rank parameterization.

这正是教材希望训练的研究路径：从熟悉公式中重新发现可被优化的结构。

^a论文：ICLR Proceedings；Oral 列表：ICLR 2026 Orals.




图 10.1 机制级实验：当梯度历史主要位于低维相关子空间时，EMA momentum 的奇异值能量会集中，低秩近似以更少状态逼近完整矩阵。真实 LoRA-Pre 的关键远比截断 SVD 更复杂，本图只复现“为何低秩状态值得研究”的必要机制。

Mini Lab | Frontier Replication 10: Optimizer State 也是可研究的表示

运行 `labs/frontier/ch10_lowrank_momentum.py`。基础任务：改变 latent gradient rank 与噪声，画 rank-reconstruction-error 曲线。进阶任务：把完整 momentum 与每步 rank- r 截断 momentum 接到一个矩阵二次优化问题，比较 convergence 与 state memory。研究任务：在 tiny Transformer 上记录若干层梯度 EMA 的 singular spectrum，比较 embedding、attention projection、MLP 矩阵的 effective rank 是否相同；再判断低秩性是否随训练阶段变化。

From Textbook to Research | 本篇之后：为什么序列需要新的结构？

到这里，我们已经有概率目标、可学习表示、backprop 和稳定训练机制。MLP 却仍没有一个自然方式表达“第 37 个 token 应该根据第 2、11、36 个 token 动态取信息”。下一篇将把输入从固定向量升级为随机序列，并从条件概率一路推导出 Attention 与 Transformer。

10.14 Deep Dive: Residual Network 作为离散动力系统

写成

$$h_{l+1} - h_l = \alpha F_l(h_l).$$

若把层索引视为离散时间，这类似 Euler discretization:

$$\frac{h(t + \Delta t) - h(t)}{\Delta t} = F(h(t)).$$

当 α 太大时，离散系统可能数值不稳定；当 α 随深度缩放时，可获得更平滑的连续深度极限。这个类比并不意味着每个 ResNet 都严格是 ODE，但它提供了研究“深度增加时每层应该多大”的数学语言。

10.15 Deep Dive: LayerNorm 的不变量

忽略 ϵ, γ, β , 令

$$\tilde{x} = \frac{x - \mu(x)\mathbf{1}}{\sigma(x)}.$$

对 $a > 0$ 、任意 b , 有

$$\widetilde{(ax + b\mathbf{1})} = \tilde{x}.$$

因此 LayerNorm 对整体正比例缩放与常数平移不变。但对一般旋转、逐坐标缩放并不不变。理解这些不变量比“它让数值稳定”更精确。

10.16 Deep Dive: Momentum 是频域滤波器

EMA 对离散梯度序列的传递函数可写成

$$H(z) = \frac{1 - \beta}{1 - \beta z^{-1}}.$$

β 越接近 1, 时间平均窗口越长, 高频梯度振荡被更强抑制, 但响应新方向也更慢。优化器超参数因此可以被理解为对训练信号频率的偏好。

10.17 Deep Dive: 低秩状态的内存账本

一个 $m \times n$ momentum 用 fp32 需要 $4mn$ bytes。若表示成 $USV^\top$, 粗略状态量为

$$r(m + n) + r$$

个浮点数。忽略 r 项, 压缩比约

$$\frac{r(m + n)}{mn}.$$

当 $m = n = d$ 时约为 $2r/d$ 。例如 $d = 4096, r = 128$ 时约 6.25%。但真正算法还必须计入更新低秩因子、正交化、通信与 kernel efficiency 的代价, 不能只比较参数个数。

分层训练 | 本章分层训练

- A | 推导：**在独立零均值假设下重新推导 He variance。
- B | 分析：**证明 LayerNorm 对 $ax + b\mathbf{1}$ ($a > 0$) 的标准化结果不变。
- B | 系统：**估算 7B 参数模型在 bf16 weights + fp32 Adam states 下的理论状态内存数量级。
- C | 研究：**记录不同层 momentum 的 singular value spectrum, 检验 “optimizer state low-rank” 是否是普遍现象还是 layer-dependent 现象。

10.18 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

尺度控制与 optimizer state 决定 第 15 章 scaling law 的可实现性, 也决定 第 22 章长轨迹训练的资源上限。

Worked Example | 方差传播不是初始化口诀

若 $y_j = \sum_{i=1}^d W_{ji}x_i$, 且各项独立、零均值, $\text{Var}(x_i) = q$, $\text{Var}(W_{ji}) = \sigma_w^2$, 则

$$\text{Var}(y_j) = d\sigma_w^2 q.$$

要保持尺度约为 q , 需要 $\sigma_w^2 \sim 1/d$; 再根据激活函数损失的二阶矩修正常数, 就得到 Xavier/He 类原则。它本质是 signal propagation matching。

Proof Clinic | 残差为什么改变深度动力学

普通复合 $h_{l+1} = F_l(h_l)$ 的 Jacobian 是 $\prod_l J_{F_l}$; 残差块 $h_{l+1} = h_l + F_l(h_l)$ 的 Jacobian 变成 $\prod_l (I + J_{F_l})$ 。当 J_{F_l} 较小时, 后者更接近单位映射的扰动, 梯度传播不再完全依赖一串任意矩阵乘积。

Research Assignment | Optimizer state / depth scaling 账本

选 tiny Transformer, 比较 SGD、AdamW 和低秩 momentum: 记录参数、梯度、optimizer state、activation memory 四类显存; 固定 wall-clock 而非 step 数比较收敛。扩 depth 时同时报告 residual scale 与 gradient norm profile。

最低交付：1 页假设与指标声明; 可复现代码与固定 seed; 主结果图; 至少一个失败/反例; 200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. 1000-layer 工作中, 深度扩展与 batch size、normalization、objective 的 ablation 是否足以区分因果因素?
2. precision-aware scaling 中的 “effective parameter count” 是理论量还是经验拟合量? 外推边界在哪里?
3. Taming Momentum 对 EMA 的 online-regression 解释在哪些假设下成立?
4. optimizer state 的低秩性是梯度数据本身造成、EMA 造成, 还是模型矩阵结构造成?
5. 一个节省状态内存的优化器若增加大量矩阵乘法, 怎样公平比较实际训练时间、吞吐与能耗?

习题

1. 推导线性层前向方差公式, 并给出保持方差同阶的权重方差数量级。
2. 在高斯对称输入近似下推导 ReLU 的 He initialization。
3. 分析一个 L 层纯线性随机网络的 activation variance 随 L 的变化。
4. 推导两层 residual chain 的 Jacobian, 并指出其中所有不同路径项。
5. 证明简化 LayerNorm 对整体正缩放与平移不变; 说明 $a < 0$ 时发生什么。
6. 展开 momentum EMA, 计算 $\beta = 0.9, 0.99$ 时梯度权重下降到初始的 $1/e$ 大约需要多少步。
7. 说明 Adam 中 L2 penalty 与 AdamW decoupled weight decay 为什么不等价。
8. 对 4096×4096 参数矩阵, 比较 full fp32 momentum 与 rank 64/128/256 因子表示的理论存储量。
9. 编程模拟 100 层 MLP 的 activation/gradient variance, 比较 naive、He、residual、LayerNorm 四种配置。
10. 拟合一个 synthetic power law, 再故意加入 plateau/crossover; 说明只看 log-log 直线为什么容易得出错误的 scaling 结论。