

第 11 章 语言的概率模型——从链式法则、熵率到 Next-Token Prediction


本章目标

“预测下一个 token”不是一个工程口号，而是对序列联合分布的一种严格参数化。本章从随机序列 $X_{1:T}$ 出发，证明链式分解，推导序列最大似然与 token-level cross-entropy 的等价关系，再用条件熵与条件互信息回答一个更接近现代 LLM 的问题：上下文多一个 token，到底提供了多少可预测信息？最后进入 ICLR 2026 Oral 关于 context-length intrinsic entropy 与 coverage principle 的工作，并把自回归建模与 diffusion language modeling 的争论提前建立起来。

Prerequisite Recall | 先把这些知识唤醒

- 会使用概率链式法则与条件熵。
- 会把 cross-entropy 写成 token-level NLL。
- 记住“联合分布的分解恒等式”和“模型选择哪种计算结构”不是同一件事。

Visual Derivation | 先看结构，再读公式



链式法则的关键不是“画一条链”，而是第 t 项条件在所有已观察历史上；Transformer 只是实现这个条件分布的一种可扩展方式。

Misconception Check | 本章最容易掉进去的坑

$p(x_{1:T}) = \prod_t p(x_t | x_{<t})$ 是概率恒等式，但“必须左到右生成”不是恒等式。模型架构、训练目标和采样顺序是额外设计选择。

Concept Contrast 把相邻概念主动分开		
	Probability factorization	Generation algorithm
性质	数学恒等/建模选择	计算过程
例子	AR chain rule	greedy, sampling, diffusion order
能否改变	因变量顺序可选	可以大量设计

Checkpoint | 开始正文前的 30 秒自测

增加 context 为什么不能保证每个具体样本的 loss 都下降？**检查答案：**条件熵的单调性是对真实联合分布的期望结论；有限模型、有限训练与单个样本都可能偏离。

11.1 语言模型首先是一个联合分布

设词表为 $\mathcal{V}$ ，一段 token 序列为

$$x_{1:T} = (x_1, x_2, \dots, x_T), \quad x_t \in \mathcal{V}.$$

概率语言模型希望给完整序列分配概率

$$p_\theta(x_{1:T}).$$

这比“给下一个 token 打分”更基本：采样、困惑度、压缩、生成和 Bayes 推断都依赖这个联合分布。

链式法则不是 Transformer 假设

由条件概率

$$p(x_1, x_2) = p(x_1)p(x_2 \mid x_1),$$

对更长序列反复应用

$$p(x_{1:T}) = p(x_{1:T-1})p(x_T \mid x_{<T})$$

即可归纳得到

$$p(x_{1:T}) = \prod_{t=1}^T p(x_t \mid x_{<t}).$$

因此 autoregressive factorization 对任意离散联合分布都成立。真正的建模假设不是“能否分解”，而是：我们选择怎样的函数族来近似每一个条件分布，并选择怎样的顺序执行生成。

11.2 最大似然为什么变成逐 token Cross-Entropy

数据集包含 N 个序列 $x_{1:T_i}^{(i)}$ 。最大似然为

$$\theta^* = \arg \max_{\theta} \sum_{i=1}^N \log p_{\theta}(x_{1:T_i}^{(i)}).$$

代入链式分解,

$$\theta^* = \arg \max_{\theta} \sum_i \sum_{t=1}^{T_i} \log p_{\theta}(x_t^{(i)} | x_{<t}^{(i)}).$$

于是负对数似然

$$L(\theta) = - \sum_i \sum_t \log p_{\theta}(x_t^{(i)} | x_{<t}^{(i)})$$

正是训练 LLM 时最常见的 token loss。若目标 token 的 one-hot 分布为 q_t , 模型分布为 p_{θ} , 则每一步

$$-\log p_{\theta}(x_t | x_{<t}) = H(q_t, p_{\theta}).$$

因此第 4 章的信息论不是旁支：现代语言模型训练目标就是它的直接应用。

11.3 从经验 Cross-Entropy 到 KL：模型究竟在逼近什么？

设真实数据分布为 p^* , 模型为 p_{θ} 。总体 NLL 可写成

$$\mathbb{E}_{x \sim p^*}[-\log p_{\theta}(x)] = H(p^*) + D_{\text{KL}}(p^* \| p_{\theta}).$$

由于 $H(p^*)$ 与 θ 无关, 理想无限数据下最大似然就是最小化

$$D_{\text{KL}}(p^* \| p_{\theta}).$$

但现实训练只看有限样本、有限 context、有限模型容量和有限优化步骤。于是“cross-entropy 下降”与“真实任务能力提升”之间仍隔着表示能力、coverage、数据质量与 evaluation distribution。

11.4 n-gram：把无限历史截断成有限 Markov 假设

n -gram 假设

$$p(x_t | x_{<t}) \approx p(x_t | x_{t-n+1:t-1}).$$

MLE 只是计数：

$$\hat{p}(w | c) = \frac{N(c, w)}{N(c)}.$$

其优点是透明，缺点是状态数随上下文指数增长。若词表大小 V ，长度 k 的离散 context 理论上有 V^k 种。

平滑不是“把概率修得好看”

未见过的 (c, w) 在纯 MLE 下概率为 0，一旦测试序列出现它，NLL 变成无穷。Laplace/Dirichlet 平滑相当于加入先验伪计数：

$$\hat{p}_\alpha(w | c) = \frac{N(c, w) + \alpha}{N(c) + \alpha V}.$$

它展示了语言建模中的一个长期主题：**有限数据下，必须用共享结构或先验把概率质量分给没有直接见过的事件**。神经网络将把“共享”从计数层面升级到连续表示空间。

11.5 RNN：把历史压缩成状态

RNN 用递归状态

$$h_t = f_\theta(h_{t-1}, x_t), \quad p(x_{t+1} | x_{\leq t}) = \text{softmax}(Wh_t + b)$$

把可变长历史压进固定维度 h_t 。这避免了显式 V^k 表格，却引入新的瓶颈：所有历史信息必须经过同一条递归通道，前向不能在时间维完全并行，反向梯度还包含 Jacobian 长乘积

$$\frac{\partial h_T}{\partial h_t} = \prod_{j=t+1}^T \frac{\partial h_j}{\partial h_{j-1}}.$$

Attention 将在第 13 章改变这一信息路由方式。

11.6 条件熵：更长 context 真的有信息吗？

定义长度 k 的上下文条件熵

$$H_k = H(X_t | X_{t-k:t-1}).$$

对这里的离散 token 随机变量，conditioning cannot increase Shannon entropy，因此

$$H_{k+1} \leq H_k.$$

差值

$$H_k - H_{k+1} = I(X_t; X_{t-k-1} | X_{t-k:t-1})$$

恰好是“再向前多看一个 token”提供的条件互信息。

证明思路 | 为什么 $H_{k+1} \leq H_k$?

令 $A = X_t, B = X_{t-k:t-1}, C = X_{t-k-1}$ 。由条件互信息非负

$$I(A; C | B) = H(A | B) - H(A | B, C) \geq 0.$$

因此加入额外 context 后不确定性不会增加。注意这是对**真实分布的 Bayes 最优不确定性**而言；有限模型可能因为 distractor、优化失败或位置外推而在更长 context 上表现更差。




图 11.1 机制级实验：一个真正依赖 $t-3$ 的随机过程，在 context 长度达到 3 时条件熵突然下降；再增加无关历史几乎不再提供信息。长 context 的价值不是“长度本身”，而是新增条件互信息。

11.7 熵率：无限序列每一步还剩多少不可预测性？

对平稳随机过程，可研究

$$h = \lim_{T \rightarrow \infty} \frac{1}{T} H(X_{1:T}).$$

利用 chain rule,

$$H(X_{1:T}) = \sum_{t=1}^T H(X_t | X_{<t}).$$

在合适条件下， h 可理解为看完无限长过去以后，每个新符号仍残留的平均不可预测性。语言模型越来越强时，追逐的是“可预测结构”；随机性、信息缺失、多解性与世界本身的不确定性则构成不可消除的部分。

11.8 Perplexity: 指数化 Cross-Entropy, 但单位非常重要

若平均 NLL 使用自然对数,

$$\text{PPL} = \exp \left(-\frac{1}{M} \sum_{t=1}^M \log p_{\theta}(x_t | x_{<t}) \right).$$

直觉上它像“平均有效分支数”，但必须谨慎：tokenizer 改变后， M 和一个 token 所代表的信息量同时改变。因此不同 tokenization 下直接比较 PPL 可能没有意义。第 12 章会把 bits-per-byte / bits-per-character 作为更接近共同单位的比较方式。

11.9 Teacher Forcing、Free Running 与分布偏移

训练时第 t 步使用真实前缀

$$x_{<t}^{\text{data}},$$

而生成时条件逐步包含模型自己的采样

$$\hat{x}_{<t}.$$

这常被称为 exposure bias，但要避免一个误解：最大似然本身并没有“忘记训练联合分布”。若模型能精确学到所有条件分布，祖先采样会恢复正确联合分布。真正的问题来自有限模型误差、有限训练覆盖与进入低概率前缀后的误差累积。

11.10 Token Loss 与 Sequence Utility 为什么可能分离？

一个推理答案可能只有某个关键分叉 token 决定最终路径；一篇长文本的局部流畅度也可能与事实正确性冲突。因此

$$\text{lower token NLL} \not\Rightarrow \text{higher task utility on every distribution.}$$

这并不否定 NLL，而是提醒我们：预训练 objective、post-training objective 和部署 metric 处在不同层级。

11.11 Research Frontier I: Intrinsic Entropy 把 context scaling 写回信息论

Research Frontier | Intrinsic Entropy of Context Length Scaling in LLMs

会议身份: ICLR 2026 Oral。^a

这项工作尝试用“intrinsic entropy”解释 context length 对 language modeling 的影响，并在自然语言和合成数据上检验理论推论。一个关键研究姿势是：不要只画“context 越长 loss 越低”的经验曲线，而要问**额外 context 理论上还能消除多少条件不确定性，以及有限数据是否足以学会利用它。**

本章的 H_k 与

$$H_k - H_{k+1} = I(X_t; X_{t-k-1} \mid X_{t-k:t-1})$$

提供最小数学原型。真实 LLM 中还必须加入 model capacity、optimization 与 finite-sample estimation error，因此“信息存在”不等于“模型会利用”。

^aICLR 2026 Oral 官方列表: [ICLR 2026 Orals](#).

11.12 Research Frontier II: Coverage Principle——为什么相近 NLL 可能有不同后训练潜力?

Research Frontier | The Coverage Principle: How Pre-Training Enables Post-Training

会议身份：ICLR 2026 Oral。^a

该工作从 coverage 角度研究预训练与后训练/Best-of- N 的关系：对于后续选择或强化方法而言，关键不仅是平均 cross-entropy，而是预训练分布是否已经给“高质量回答区域”放置了足够概率质量。

若高质量集合为 A ，一个极简量是

$$C_{\theta}(A | x) = \sum_{y \in A} p_{\theta}(y | x).$$

Best-of- N 至少采到一个 A 中答案的概率为

$$1 - (1 - C_{\theta})^N.$$

这立刻说明：两个平均 NLL 接近的模型，只要在关键高质量集合上的 coverage 不同，test-time scaling 的上限就可能很不同。**前训练不只是在压低 loss，也在塑造后训练可访问的概率支撑。**

^a官方 Oral 页面同上。

11.13 Research Frontier III：自回归顺序是恒等式，但生成顺序是设计选择

Research Frontier | The Flexibility Trap: Rethinking the Value of Arbitrary Order in Diffusion Language Models

会议身份：ICML 2026 Outstanding Paper。^a

Diffusion language model 允许不同于固定 left-to-right 的生成次序。该工作提出一个反直觉观察：arbitrary-order 的自由并不自动转化成推理优势；在一些 reasoning 场景中，模型可能绕过高不确定但决定解题分叉的 token，从而损害 solution diversity。这与本章形成一个重要区分：

$$p(x_{1:T}) \text{ 可按链式法则分解}$$

是概率恒等式；

$$\text{模型必须按什么顺序、什么并行策略生成}$$

则是算法和归纳偏置问题。第 17 章会正式比较 AR 与离散 diffusion。

^aICML 2026 官方奖项：ICML 2026 Awards.

Mini Lab | Frontier Replication 11: 把“上下文价值”画成条件熵曲线

运行 `labs/frontier/ch11_context_entropy.py`。脚本构造一个真实依赖 $t-3$ 的二元随机过程并估计 H_k 。**基础任务：**验证 $k=3$ 附近 entropy 明显下降。**进阶任务：**把依赖距离改成随机变量，观察信息增益怎样摊到多个 k 。**研究任务：**加入有限样本后比较 plug-in entropy estimate 的偏差，并构造“真实信息增加但有限模型 test NLL 反而上升”的例子，区分 Bayes information 与 learnability。

From Textbook to Research | 从“知道要预测什么”到“怎样表示上下文”

本章已经确定目标：学习 $p_\theta(x_t | x_{<t})$ 。下一章先解决最基础却经常被忽略的问题：字符、汉字、词、代码和数字必须先被离散成 token，再映到连续空间。Tokenizer 决定序列长度和统计单位，Embedding 决定模型能用怎样的几何共享统计强度。

11.14 Deep Dive: Prefix Training 是共享参数的多任务学习

一条长度 T 的序列产生 T 个预测问题：

$$\emptyset \rightarrow x_1, \quad x_1 \rightarrow x_2, \quad \dots, \quad x_{<T} \rightarrow x_T.$$

它们共享同一个 θ 。因此预训练并非“每篇文档一个样本”，而是海量 prefix-conditioned tasks 的联合训练。不同长度、主题与格式的 prefix 会对同一参数产生梯度叠加，这也是 in-context behavior 可能在纯 next-token objective 中出现的背景之一。

11.15 Deep Dive: Sequence KL 可以分解成条件 KL

对真实分布 p 与模型 q ，链式法则给出

$$D_{\text{KL}}(p(x_{1:T}) \| q(x_{1:T})) = \sum_{t=1}^T \mathbb{E}_{x_{<t} \sim p} D_{\text{KL}}(p(x_t | x_{<t}) \| q(x_t | x_{<t})).$$

这说明 token-level conditional modeling error 的期望和正是 joint-distribution KL。证明方法是把

$$\log \frac{p(x_{1:T})}{q(x_{1:T})}$$

用两个链式分解展开成逐步 log-ratio，再交换求和与期望。

证明思路 | 这对 exposure bias 有什么启示？

训练条件前缀确实来自 p ，而生成前缀来自 q 。但 joint KL 的分解表明，只要 q 在 p 的典型前缀上学得足够好，整个联合分布也会逼近。现实困难在于有限数据不能

覆盖所有有意义前缀，且 reverse direction $D_{\text{KL}}(q||p)$ 的行为可能不同。研究“生成时模型会去哪里”不能只看训练 NLL 一个数。

11.16 Deep Dive: Cross-Entropy 改善多少才值得?

若两个模型平均 NLL 相差 Δ nats/token，则长度 T 的同一序列似然比平均呈指数尺度

$$\frac{p_2(x_{1:T})}{p_1(x_{1:T})} \approx e^{T\Delta}$$

(这里只是把平均 log-prob 差指数化的量级直觉，并非所有序列都相同)。因此 0.01 nats/token 看似很小，在长序列 joint likelihood 上可能积累成显著差异；但 downstream accuracy 仍未必按此指数增长。

分层训练 | 本章分层训练

A | 计算：给定四个真实 token 概率 0.8, 0.5, 0.1, 0.9，计算总 NLL、平均 NLL 与 PPL。

A | 证明：用归纳法证明联合概率链式分解。

B | 推导：证明 sequence KL 的 conditional decomposition。

B | 信息论：证明 $H_{k+1} \leq H_k$ ，并把差值写成条件互信息。

C | 研究：构造两个模型，使它们整体 NLL 接近，但在一个“高质量答案集合” A 上 coverage 差异巨大；比较 Best-of- N 成功率。

11.17 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

序列概率分解直接进入 第 15 章预训练、第 16 章生成和 第 18 章 sequence policy。

Worked Example | 链式法则如何把语言变成可训练目标

任意联合分布都可写成

$$p(x_{1:T}) = \prod_{t=1}^T p(x_t | x_{<t}).$$

取负对数得到序列 NLL

$$-\log p(x_{1:T}) = \sum_t -\log p(x_t | x_{<t}).$$

因此 next-token loss 不是把语言“近似成分类”这么简单，而是对联合分布链式分解后得到的精确极大似然目标；模型近似发生在条件分布族，而非分解恒等式。

Proof Clinic | 多一段 context 的信息价值

新增 context C 对下一个 token X 的理想 NLL 改善为

$$H(X|H) - H(X|H, C) = I(X; C|H) \geq 0.$$

所以“context 更长是否有用”的信息论上限由条件互信息刻画；实际模型达不到这个上限还会受到 retrieval、capacity 和 optimization 限制。这为 Ch19 的 Value of Information 埋下伏笔。

Research Assignment | Context entropy scaling

构造不同可预测距离的数据源, 逐渐增加 context length, 估计 empirical conditional entropy 与模型 NLL。要求把‘数据中可用信息’和‘模型实际利用的信息’画成两条曲线。

最低交付: 1 页假设与指标声明; 可复现代码与固定 seed; 主结果图; 至少一个失败/反例; 200–400 字结论边界。**禁止:** 只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. 一篇长上下文论文报告“context 越长性能越好”时, 是否区分了真实新增信息、模型利用能力和有限数据误差?
2. Intrinsic Entropy 的理论量怎样从可观测数据估计? 估计器偏差会不会被误当成 scaling law?
3. Coverage Principle 中的“高质量集合”如何定义? 若 reward model 本身有偏, coverage 是否仍有意义?
4. token-average NLL 是否掩盖少数高不确定“forking tokens”的重要性?
5. diffusion LM 的 arbitrary order 是模型表达能力、训练算法还是 decoding policy 的优势? 论文是否把三者分开?

习题

1. 展开五个 token 的完整链式分解, 并给出两种不同变量顺序的分解。
2. 一个词表大小为 3 的 bigram corpus 已给出计数表, 分别计算 MLE 与 $\alpha = 1$ Laplace smoothing 概率。
3. 证明 $\mathbb{E}_{p^*}[-\log p_\theta] = H(p^*) + D_{\text{KL}}(p^*||p_\theta)$ 。

4. 推导 sequence KL 的逐条件 KL 分解。
5. 证明 conditioning reduces entropy, 并说明为什么有限模型的测试 loss 却可能随 context 变长而变差。
6. 若高质量集合 coverage 为 0.03, 计算 $N = 1, 8, 32, 128$ 时 Best-of- N 至少命中一次的概率。
7. 讨论 PPL 为什么不能跨 tokenizer 直接比较; 给出 bits-per-byte 的定义建议。
8. 构造一个二阶 Markov chain, 使 $H(X_t | X_{t-1})$ 与 $H(X_t | X_{t-2:t-1})$ 差异明显。
9. 编程估计不同样本量下 plug-in conditional entropy 的偏差。
10. 设计一个 sequence-level reward 与 token NLL 冲突的例子, 并解释这对 post-training objective 有什么启示。