

第 12 章 Tokenization 与 Embedding

——离散符号怎样变成可学习的几何

本章目标

LLM 并不直接读取“文字”，它读取 token id；也不直接在离散 id 上做语义运算，而是先把 id 映射成连续向量。本章把 tokenizer 看成一个**可变长度编码器**，把 embedding 看成一个**从离散基到低维连续空间的线性映射**。我们将推导 BPE 的合并逻辑、比较 tokenizer 下 loss 的共同单位、证明 one-hot 与 lookup 的等价性、分析 weight tying 对 logits 几何的约束，并讨论 anisotropy、subspace 与 superposition。Frontier 部分进入 ACL 2025 对 tokenizer evaluation 的重新审视以及 Outstanding Paper 对“符号结构如何形成语言归纳偏置”的研究。

Prerequisite Recall | 先把这些知识唤醒

- 会把 one-hot 向量乘 embedding matrix。
- 熟悉熵/码长与序列长度。
- 记住 tokenizer 是模型输入接口的一部分，不是无关紧要的预处理。

Misconception Check | 本章最容易掉进去的坑

Embedding 中 cosine 相近不自动等于“语义相同”。向量相似度受到训练目标、各向异性、层位置、频率与 superposition 影响；静态 embedding 结论也不能直接搬到 contextual hidden state。

Concept Contrast | 把相邻概念主动分开

	Tokenizer compression	Downstream utility
目标	更短序列/更少 bits	更好任务性能
一定同向?	否	否
典型失败	专名被过度切分	压缩好但任务边界差

Checkpoint | 开始正文前的 30 秒自测

为什么两个 tokenizer 的 token-level perplexity 不能直接比较？**检查答案：**一个“token”代表的信息量不同；至少要统一到 byte/character 等可比较单位。

12.1 Tokenizer 决定模型真正看到的序列

令原始字符串为 $s \in \Sigma^*$, tokenizer 是映射

$$\tau: \Sigma^* \rightarrow \mathcal{V}^*,$$

输出 token 序列

$$\tau(s) = (z_1, \dots, z_T).$$

因此 context window “128k tokens” 不是固定字符数，更不是固定词数。对不同语言、代码、数字和特殊格式， T 可以差很多。

12.2 字符、词、子词与 byte：没有免费的粒度

- **字符/byte**：词表小、几乎无 OOV，但序列更长，长依赖计算更贵。
- **词**：序列短，但词表巨大、稀有词和形态变化严重。
- **子词**：用可复用片段折中词表与长度，是当前 LLM 常见方案。
- **动态/无 tokenizer 方案**：尝试让边界本身适应数据，但会把复杂度转移到模型或编码过程。

核心 trade-off 可以粗略写成

$$\text{vocabulary size} \leftrightarrow \text{sequence length} \leftrightarrow \text{sharing granularity}.$$

12.3 BPE：用频繁局部结构压缩序列

一种简化 BPE 从字符级符号开始，反复统计相邻 pair 的频率，合并最高频 pair：

$$(a, b) \mapsto ab.$$

若语料中 **th** 高频，它可能先被合并；之后 **the** 又可能由 **th+e** 形成。BPE 本质上在构造一套数据驱动的可变长度字典。

BPE 为什么和“共享统计强度”有关？

完全词级表示把 **learn**, **learning**, **learner** 当三个独立符号，参数共享弱；字符级又把局部模式拆得过细。若 tokenizer 得到 **learn+ing**, **learn+er**，则多个词可共享 **learn** 的 embedding 与上下文统计。Tokenizer 因此不仅影响 compression，也改变哪些事件被模型视为同一个可重用单位。

12.4 不同 tokenizer 下, Perplexity 为什么不公平?

假设同一个字符串, tokenizer A 产生 10 tokens, B 产生 20 tokens。即使两个模型对整串字符串给出的概率相同, 平均 per-token NLL 也会不同。因此更共同的单位可以是

$$\text{BPB} = -\frac{\log_2 p(s)}{\# \text{bytes}(s)}$$

或特定场景下的 bits-per-character。它们仍有编码细节, 但至少不把“一个 token 是多大”当成相同单位。

12.5 Tokenization 也是一种资源分配

在固定 token budget 下, 一个语言平均每个词需要更多 tokens, 就意味着:

1. 同样 context window 能覆盖的原始文本更短;
2. 同样训练 token 数对应的原始字符/语义事件更少;
3. 推理计费与时延可能更高;
4. 数字、代码和形态丰富语言可能形成更长 dependency chain。

因此 tokenizer 的“效率”具有系统与公平性后果, 而不仅是预处理细节。

12.6 Embedding Lookup 与 one-hot 线性层完全等价

词表大小 V , embedding 维度 d , 令

$$E \in \mathbb{R}^{V \times d}.$$

token id i 的 one-hot 向量为 $e_i \in \mathbb{R}^V$, 则

$$e_i^\top E = E_{i,:}$$

所谓 embedding lookup 只是利用输入 one-hot 的稀疏性, 直接取矩阵第 i 行, 而不真的构造 V 维向量。

证明思路 | Embedding 的梯度为什么只更新被访问的行?

若损失依赖 $h = e_i^\top E$, 则

$$\frac{\partial L}{\partial E} = e_i \left(\frac{\partial L}{\partial h} \right)^\top.$$

由于 e_i 只有第 i 维为 1, 单个 lookup 的直接梯度只作用在 E 的第 i 行。一个 token 的表示因此由所有出现该 token 的 context 梯度长期累积塑造。

12.7 Embedding 是低维参数化，不等于天然“语义空间”

若 $d \ll V$ ，模型把 V 个离散基映到 d 维空间。相似 context 的 token 往往会收到相似梯度，从而形成可复用几何；但不能反过来断言“每个欧氏方向都有稳定的人类语义”。Embedding geometry 受频率、norm、训练目标、层位置与后续线性变换共同影响。

12.8 输出 logits 与 Weight Tying：词汇几何怎样进入概率？

若 hidden state 为 $h \in \mathbb{R}^d$ ，输出 logits 通常为

$$z = W_{\text{out}}h + b, \quad W_{\text{out}} \in \mathbb{R}^{V \times d}.$$

若采用 weight tying，令

$$W_{\text{out}} = E,$$

则 token i 的 logit 是

$$z_i = E_i^\top h + b_i.$$

这时输入 embedding 行既决定“读入 token i 时注入什么向量”，也决定“hidden state 与 token i 的输出兼容度”。

Dot Product 不是 Cosine

若不做归一化，

$$E_i^\top h = \|E_i\| \|h\| \cos \theta_i.$$

因此输出概率同时受方向和向量 norm 影响。直接用 cosine nearest-neighbor 分析 embedding，只看到了 logit 几何的一部分。

12.9 各向异性：高维表示并不一定“均匀铺满球面”

定义 token embedding 均值

$$\mu = \frac{1}{V} \sum_{i=1}^V E_i.$$

若很多向量共享强公共方向，随机 token 间 cosine 可能整体偏正，最近邻也会被频率/公共成分支配。常见诊断包括：

- centered cosine：先用 $E_i - \mu$ ；

- covariance spectrum: 看少数主成分是否占据大量方差;
- layer-wise comparison: 输入 embedding 与 contextual hidden state 不应混为一谈。

12.10 Contextual Representation: 同一个 token 不再只有一个向量

输入层中 token i 对应固定 E_i , 但经过 Transformer 后, 第 l 层位置 t 的 hidden state

$$h_t^{(l)}$$

依赖整个可见上下文。同一个“bank”在金融与河岸语境中会形成不同 contextual representation。因此“词向量”只是入口; 真正的 LLM 表示研究更关注 feature、subspace、dictionary、circuit 与动态路由。

12.11 Superposition: 表示特征数为什么可以超过维度?

如果潜在特征数 m 远大于 hidden dimension d , 一特征一坐标显然放不下。若特征激活足够稀疏, 可以把多个特征编码在近似不交方向中:

$$h \approx \sum_{j \in \mathcal{A}} a_j v_j, \quad |\mathcal{A}| \ll m.$$

这会引入干扰, 但换来“特征容量”超过坐标维度。第 8 章已经从 feature learning 角度讨论过 superposition; 在本章它再次提醒: embedding dimension 不等于模型可表示概念数。

12.12 Research Frontier I: Tokenizer 不能只用压缩率评价

Research Frontier | Beyond Text Compression: Evaluating Tokenizers Across Scales

会议身份: ACL 2025 Main Conference Long Paper。^a

该工作系统比较 tokenizer, 并指出单纯 text compression 并不足以稳定预测下游表现; 其研究包括利用较小模型预测 tokenizer 对更大模型的影响, 并提出受 Zipf law 启发的 intrinsic metrics。论文报告英语任务上的 tokenizer 差异相对小, 而 multilingual 设置中差异更稳定。

这里最值得学习的不是某个具体指标, 而是**评价对象的改变**:

tokenizer quality $\neq$ compression ratio only.

一个 tokenizer 同时定义统计单位、序列长度、长尾分配、跨语言共享和模型训练难度。研究者应问：哪个 proxy 真能预测我们关心的 downstream quantity?

^aACL Anthology: [Beyond Text Compression](#).




图 12.1 机制级实验：BPE merges 在训练域上快速缩短序列，但对形态/符号分布偏移的数据帮助很小。一个 tokenizer 的“平均压缩率”可能掩盖强烈 domain dependence。

12.13 Research Frontier II: 符号结构本身可以给模型施加归纳偏置

Research Frontier | Between Circuits and Chomsky: Pre-pretraining on Formal Languages Imparts Linguistic Biases

会议身份：ACL 2025 Outstanding Paper。^a

该工作研究在自然语言之前先用 formal languages 做 pre-pretraining。作者关注的不是“形式语言和英语词义是否相似”，而是它们是否包含合适的 **dependency structure**，并且这些结构是否落在模型架构可学习的计算范围内。论文报告，具有相关层级依赖的 formal-language pre-pretraining 能改善后续自然语言 loss 与 linguistic generalization，并给出 attention heads 迁移的机制证据。

它对本章的启示是：离散符号本身没有语义并不意味着“怎样切分、怎样排列、怎样暴露结构”无关紧要。模型的归纳偏置来自

symbolization × data dependency × architecture.

^aACL 2025 官方奖项：Awards；论文：ACL Anthology.

Mini Lab | Frontier Replication 12: BPE 的收益是否跨分布稳定?

运行 `labs/frontier/ch12_tokenizer_scaling.py`。脚本只用标准 Python 实现一个最小 BPE，并比较训练域与形态/符号偏移域的 token-per-character 曲线。
基础任务：解释为何 merges 对 in-domain 压缩更有效。**进阶任务：**混入中文、代码、数字，改变训练语料比例，观察“共享词表”资源如何被分配。**研究任务：**同时记录压缩率与一个小语言模型的 held-out BPB，寻找二者排序不一致的 tokenizer，复现“compression proxy 不是全部”的机制。

From Textbook to Research | 有了坐标，还缺少“读取谁”的机制

Embedding 把 token 放进连续空间，却仍然只完成每个位置的局部表示。若当前位置需要从 10,000 个历史位置中找出与自己最相关的信息，固定卷积窗口或单一路径递归都很受限。下一章将把第 2 章的点积、第 7 章的 softmax 和本章的向量表示组合成一个数据依赖的可微检索器：Attention。

12.14 Deep Dive: Tokenizer 是一种可变长度编码

如果 tokenizer 可逆，那么 token 序列必须足以恢复原字符串。对频繁模式分配更长的词表条目，本质上是在用更短的 token 序列描述常见片段。它与经典编码的相似处在于“常见结构应该更省表示”；不同处在于 token id 最终还会进入一个神经网络，编码长度并不是唯一目标。

12.15 Deep Dive: Weight Tying 会施加什么低秩约束?

考虑一批 hidden states 组成矩阵 $H \in \mathbb{R}^{n \times d}$ ，输出 embedding $E \in \mathbb{R}^{V \times d}$ 。忽略 bias 时 logits 矩阵

$$Z = HE^\top$$

满足

$$\text{rank}(Z) \leq d.$$

Softmax 之后概率矩阵不再是简单线性低秩，但 pre-softmax logits 的共享低维因子结构是真实存在的。这与第 7 章 ICLR 2026 low-logit-rank Frontier 形成呼应：低维 hidden interface 会在可观测输出函数上留下结构痕迹。

12.16 Deep Dive: Cosine 最近邻为什么会被公共方向欺骗?

设

$$E_i = \mu + \epsilon_i,$$

且 $\|\mu\|$ 很大。则两个无关 token

$$E_i^\top E_j = \|\mu\|^2 + \mu^\top (\epsilon_i + \epsilon_j) + \epsilon_i^\top \epsilon_j$$

会共享一个大的 $\|\mu\|^2$ 基线。于是 raw cosine 的“高相似”可能部分来自公共均值，而非 token-specific feature。中心化或去除 top principal components 是诊断方法，但也可删掉真实信号，不能机械使用。

分层训练 | 本章分层训练

A | 证明：证明 one-hot 线性层与 embedding lookup 等价。

A | 计算：给定 $V = 50,000, d = 4096$ ，计算 untied/tied input-output embedding 的参数量差。

B | 信息论：构造同一字符串的两种 tokenization，说明 per-token PPL 排名可能与 bits-per-character 排名不一致。

B | 线代：证明 $Z = HE^\top$ 的 rank 不超过 d 。

C | 研究：选择两种 tokenizer，比较 compression、multilingual fragmentation、数字切分和 downstream BPB，检查是否存在单一 intrinsic metric 可以稳定预测全部结果。

12.17 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

Tokenization 决定 第 15 章的 effective data 口径；embedding 几何则连接 第 13 章 attention 与 第 19 章 retrieval。

Worked Example | Tokenizer 改变的不是只有序列长度

若一句话在 tokenizer A 下为 8 token、B 下为 12 token，同样的 per-token NLL 不能直接比较。更稳妥的是按 byte 或 character 归一化，例如 bits-per-byte：

$$\text{BPB} = \frac{-\log_2 p(x)}{\#\text{bytes}(x)}.$$

Tokenizer 同时决定词表参数、序列长度、形态切分和跨语言公平性，因此它是模型假设的一部分。

Proof Clinic | Weight tying 的线性代数

若输入 embedding 为 $E \in \mathbb{R}^{V \times d}$, 输出 logits 用 $z = Eh$ (忽略 bias), 则每个 token 的输入向量同时充当输出分类器法向量。参数从两个 $V \times d$ 矩阵降为一个, 但也施加了表示与解码几何共享的归纳偏置。

Research Assignment | Tokenizer 跨域压力测试

在新闻、代码、数学、至少一种非英语文本上比较两种 tokenizer: 报告 fertility、BPB、序列长度分位数和 embedding 参数占比。禁止只报告平均 token 数。

最低交付: 1 页假设与指标声明; 可复现代码与固定 seed; 主结果图; 至少一个失败/反例; 200–400 字结论边界。**禁止:** 只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. tokenizer 论文报告“更高效”时, 效率单位是 tokens、bytes、FLOPs、wall-clock 还是 downstream quality / compute?
2. intrinsic tokenizer metric 与大模型下游表现的相关性是否跨语言、跨模型规模成立?
3. 一个 multilingual tokenizer 的词表容量是否被高资源语言占用? 论文如何量化这种分配?
4. embedding nearest-neighbor 结论是否对 centering、normalization、layer 和 context 稳健?
5. formal-language pre-pretraining 的收益来自 token statistics、dependency structure、额外训练 compute, 还是可迁移 circuit? ablation 是否足以区分?

习题

1. 手工对 low lower lowest 做 5 次简化 BPE merge, 并写出每一步 pair count。
2. 证明 embedding lookup 等价于 one-hot 乘矩阵, 并推导单个 token 对 E 的梯度稀疏结构。
3. 给定两个 tokenizer 对同一字符串的 token 数与总 log-prob, 分别计算 per-token PPL 与 bits-per-character。
4. 若 $W_{\text{out}} = E$, 解释 token embedding norm 如何影响输出 logit。
5. 证明 logits batch $Z = HE^T$ 的 rank bound, 并讨论加入 bias 后秩最多增加多少。

6. 构造一个有强公共方向的 synthetic embedding, 比较 raw cosine 与 centered cosine nearest neighbors。
7. 解释 contextual representation 与静态 input embedding 的区别; 给出 polysemy 的例子。
8. 用 PCA 检查 embedding anisotropy, 并报告前 10 个主成分解释方差。
9. 修改 Frontier Lab, 让训练语料中 90% 为一种语言, 分析另一种语言的 token fragmentation。
10. 提出一个比 compression ratio 更可能预测 tokenizer downstream quality 的指标, 并说明其潜在失败模式。