

第 13 章 Attention——从核回归到可微分内容寻址


本章目标

Attention 不是一句“模型关注重要信息”，而是一个精确的动态算子：query 与 key 产生兼容度，softmax 把兼容度变成概率权重，再对 value 做条件加权。本章从最近邻和 kernel smoothing 推到 scaled dot-product attention，推导 $1/\sqrt{d_k}$ 、softmax Jacobian、causal mask 与复杂度，分析 multi-head、MQA/GQA、低秩 score 结构与 attention sink。Frontier 部分进入 NeurIPS 2025 Best Paper 的 Gated Attention 与 ACL 2025 Best Paper 的 Native Sparse Attention：标准 Attention 公式在 2025 仍然可以被一个 gate 或硬件感知稀疏结构重新设计。

Prerequisite Recall | 先把这些知识唤醒

- 熟悉 softmax、矩阵乘法与 rank。
- 知道 convex combination 与 convex hull。
- 能区分“权重大小”和“因果重要性”。

Visual Derivation | 先看结构，再读公式



Misconception Check | 本章最容易掉进去的坑

Attention weight 大并不等于该 token 对最终输出因果影响大。Value 内容、output projection、残差路径、其他 heads 与后续 MLP 都可能改变影响；attention map 首先是路由权重。

Concept Contrast | 把相邻概念主动分开

	Retrieval view	Causal explanation
问题	“从哪里读?”	“删掉/干预后结果变多少?”
对象	A_{ij}	intervention / gradient / patching
是否等价	一般不等价; 高 attention 只是解释证据的一部分	

Checkpoint | 开始正文前的 30 秒自测

固定 Q, K 后, Attention 对 V 是线性的; 那整个 Attention 对输入 X 为什么仍非线性? 检查答案: Q, K, V 都依赖 X , 且 $A(X)$ 经过二次 score 与 softmax。

13.1 从硬检索到软检索

给定 query q 、keys $k_1, \dots, k_T$ 和 values $v_1, \dots, v_T$, 硬最近邻检索为

$$j^* = \arg \max_j q^\top k_j, \quad o = v_{j^*}.$$

它的问题是 j^* 对 score 的微小变化可以跳变, 难以用梯度连续学习“应该读几个位置、各读多少”。于是用 Gibbs 权重软化:

$$a_j = \frac{\exp(s_j/\tau)}{\sum_l \exp(s_l/\tau)}, \quad o = \sum_j a_j v_j.$$

当温度 $\tau \rightarrow 0$ 时趋近 hard max; τ 大时权重更平坦。

13.2 Attention 与核回归的关系

Nadaraya–Watson kernel regression 写成

$$\hat{y}(q) = \frac{\sum_j K(q, k_j) y_j}{\sum_l K(q, k_l)}.$$

若令

$$K(q, k) = \exp(q^\top k / \tau),$$

便得到 softmax attention 的基本形状。不同之处是现代 Attention 中 q, k, v 都由可学习投影产生, 因此模型同时学习“用什么度量检索”和“检索后读出什么内容”。

13.3 Q、K、V：同一个 token 的三个角色

设输入矩阵

$$X \in \mathbb{R}^{T \times d_{\text{model}}}.$$

线性投影为

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V,$$

其中 $Q, K \in \mathbb{R}^{T \times d_k}$, $V \in \mathbb{R}^{T \times d_v}$ 。于是

$$S = QK^\top \in \mathbb{R}^{T \times T}$$

表示每个 query 对每个 key 的兼容度。

若强迫 $Q = K = V = X$ ，匹配空间和内容空间被耦合。分开投影允许“某个 token 用一种 feature 决定它在找什么，用另一种 feature 决定它携带什么信息”。

13.4 缩放因子：为什么使用 $1/\sqrt{d_k}$?

假设 q_i, k_i 独立、零均值、方差为 1，则

$$q^\top k = \sum_{i=1}^{d_k} q_i k_i.$$

独立近似下

$$\text{Var}(q^\top k) = \sum_i \text{Var}(q_i k_i) \approx d_k.$$

因此 score 的标准差约为 $\sqrt{d_k}$ 。若直接送进 softmax，维度增大时 logits spread 变大，分布更容易饱和；缩放后

$$\frac{q^\top k}{\sqrt{d_k}}$$

把典型方差拉回 $O(1)$ 。

1/√d_k 不是神奇常数

上述推导依赖初始化阶段近似独立、单位方差等假设。训练后的 Q, K 可能高度相关、norm 也会改变。缩放的主要作用是提供一个合理的初始数值尺度，不意味着训练全过程 score 方差严格等于 1。

13.5 Softmax 的 Jacobian 揭示“竞争”与饱和

令 $a = \text{softmax}(s)$ ，则

$$\frac{\partial a_i}{\partial s_j} = a_i(\delta_{ij} - a_j).$$

矩阵形式

$$J_{\text{softmax}} = \text{Diag}(a) - aa^\top.$$

因此提高一个 score 不只提升对应权重，也会通过归一化压低其他位置。当某个 $a_i \approx 1$ 时，多数导数会变小，score competition 进入近饱和状态。

13.6 Scaled Dot-Product Attention

最终得到

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V.$$

设

$$A(Q, K) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right),$$

则 $O = AV$ 。

固定 Q/K 时：Attention 对 V 是线性的

一旦 A 固定，

$$V \mapsto AV$$

是普通线性映射。Attention 的输入依赖性来自 A 本身由输入生成：模型先根据当前数据构造一个路由矩阵，再用它搬运 value。这比“加权平均”更接近其计算本质。

13.7 Convex Hull：单个 head 的加权和有哪些硬约束？

每一行 softmax 权重满足

$$a_j \geq 0, \quad \sum_j a_j = 1.$$

因此在输出投影前，单个 query 的

$$o = \sum_j a_j v_j$$

位于 values 的 convex hull 中。它不能仅靠这一步制造超出 $\{v_j\}$ 仿射包络的新方向。后续 output projection、多个 heads、residual 与 MLP 会打破这个单步几何限制。

13.8 Score Matrix 的低秩与 Softmax 非线性

在 softmax 前

$$S = QK^\top$$

满足

$$\text{rank}(S) \leq d_k.$$

若 $T \gg d_k$ ，一个 head 的原始 pairwise score matrix 是低秩因子化的。softmax 是逐行非线性，会改变线性 rank，但“关系先通过低维 query/key 通道生成”仍是结构约束。NeurIPS 2025 的 Gated Attention 正把“低秩 mapping 后增加非线性”作为其机制解释的一部分。

13.9 Causal Mask：把概率分解写进计算图

Decoder-only LM 第 t 个位置不能读取未来 $j > t$ 。可定义 mask

$$M_{tj} = \begin{cases} 0, & j \leq t, \\ -\infty, & j > t. \end{cases}$$

然后

$$A = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right).$$

由于 $e^{-\infty} = 0$ ，未来权重严格为 0。于是第 11 章的因果分解不再只是概率公式，而被硬编码进网络可见性。

13.10 Multi-Head Attention：不是“重复做很多次”这么简单

对第 h 个 head,

$$O_h = \text{Attn}(XW_Q^{(h)}, XW_K^{(h)}, XW_V^{(h)}).$$

拼接后

$$\text{MHA}(X) = \text{Concat}(O_1, \dots, O_H)W_O.$$

不同 heads 可以学习不同匹配子空间；但“一个 head 一种人类可命名功能”不是定理。head redundancy、distributed circuits 与后续 output mixing 都会让解释更复杂。

13.11 标准 Attention 的计算与内存账本

构造 $QK^\top$ 的乘法量级为

$$O(T^2 d_k),$$

score/attention matrix 的朴素存储为 $O(T^2)$ 。当 T 从 4k 增到 64k， T^2 增长 256 倍。这就是 long-context attention 的核心系统压力。

但算法复杂度不等于 wall-clock。FlashAttention 类方法不改变 exact attention 的数学结果，而通过 tiling 与重计算减少 HBM 读写。由此产生一个现代算法课题：**FLOPs、内存容量、memory bandwidth 与 arithmetic intensity 必须一起分析。**

13.12 MQA / GQA：通过共享压缩 KV Cache

Multi-Head Attention 通常每个 query head 都有独立 K/V。Multi-Query Attention 让多个 query heads 共享一组 K/V；Grouped-Query Attention 则在两者之间折中。它们主要减少推理时 KV cache：若 KV heads 从 H 降到 H_{kv} ，缓存规模近似按

$$\frac{H_{kv}}{H}$$

缩小，而 query expressivity 仍保留多个 heads。

13.13 Attention Sink：高权重不一定等于高语义重要性

长序列模型中，一些位置可能持续获得异常高 attention mass。若把 attention map 直接解释为“模型认为它最重要”，就会把数值路由现象误当成语义解释。sink 可能与 softmax normalization、位置机制、key/query 几何和 residual dynamics 共同相关。

13.14 Research Frontier I：一个 sigmoid gate 为什么还能改进 2025 的 Attention？

Research Frontier | Gated Attention for Large Language Models: Non-linearity, Sparsity, and Attention-Sink-Free

会议身份：NeurIPS 2025 Best Paper。^a

该工作系统比较多种 gating-augmented softmax attention，核心推荐是在 scaled dot-product attention 输出后加入 head-specific sigmoid gate。简化写成

$$\tilde{O}_h = g_h(x) \odot O_h, \quad g_h(x) = \sigma(W_g h).$$

官方奖项说明强调，该设计在大规模 dense/MoE 实验中改善性能和训练稳定性，并与缓解 attention sink、massive activation 和长上下文外推相关。

数学上值得追问两点：第一，原始单 head 对 V 在固定 A 下是线性的，而 query-dependent gate 在输出端再加入乘性非线性；第二，gate 允许某个 head 在不同 query 上独立“少说话”，而 softmax 内部始终要把总权重归一到 1。

^aNeurIPS 2025 官方奖项：Best Paper Awards.




图 13.1 机制级实验：人为制造一个 sink key 后，attention mass 几乎全部流向该位置；一个 query-dependent output gate 可以抑制整个 sink-dominated head 的输出。真实 Gated Attention 的结论来自大规模训练，本图只展示“归一化后再门控”增加了什么自由度。

13.15 Research Frontier II: Sparse Attention 不能只写一个 $O(Tk)$ 就结束

Research Frontier | Native Sparse Attention: Hardware-Aligned and Natively Trainable Sparse Attention

会议身份：ACL 2025 Best Paper。^a

NSA 采用动态层级稀疏策略，把 coarse-grained token compression、fine-grained token selection 与 local structure 组合起来，并从训练阶段原生使用 sparse attention。论文特别强调 hardware-aligned design 与 arithmetic intensity，而不是只给理论 sparsity。

它训练一种非常重要的研究判断：

asymptotic complexity $\neq$ hardware efficiency.

一个只计算少量 entries 的稀疏算法，如果索引不规则、访存碎片化、kernel utilization 低，仍可能输给高度优化的 dense kernel。现代 Attention 创新往往同时是统计建模问题 + 算法问题 + 系统问题。

^aACL 2025 官方奖项：Awards；论文：ACL Anthology.

Mini Lab | Frontier Replication 13: 制造 Attention Sink, 再观察 Gate 的自由度

运行 `labs/frontier/ch13_gated_attention.py`。基础任务: 给第 0 个 key 增加 score bias, 画其平均 attention mass。进阶任务: 比较 gate 放在 score 前、softmax 后 head output、value 上三种情况的 Jacobian。研究任务: 加入 top- k sparse attention, 比较“保留质量、FLOPs proxy、实际 NumPy/PyTorch wall-clock”, 亲自验证理论 sparsity 与真实速度可以不一致。

From Textbook to Research | Attention 还不是 Transformer

到这里我们只有一种内容驱动的动态路由算子。不带位置机制、也不带因果/结构 mask 的 self-attention 对 token 置换是等变的, 因此单靠内容不能识别绝对顺序。需要注意: causal mask 本身已经是一种顺序结构, 会打破一般置换对称性, 所以严格结论不是“显式 positional encoding 逻辑上必不可少”, 而是序列模型必须通过 mask、位置特征、相对位置机制或其他方式打破不希望保留的对称性。下一章会在这个更准确的命题下组装 Decoder Transformer。

13.16 Deep Dive: Attention 对输入的非线性来自哪里?

若 Q, K, V 都来自 X ,

$$O(X) = A(X)V(X),$$

其中

$$A(X) = \text{softmax}\left(\frac{XW_QW_K^\top X^\top}{\sqrt{d_k}}\right).$$

即使 $V(X)$ 是线性的, $A(X)$ 含有二次型和 softmax, 因此整体高度非线性。把 Attention 称为“加权平均”没有错, 但会隐藏最关键的事实: 权重本身是由输入生成的函数。

13.17 Deep Dive: Softmax Jacobian 是一个协方差矩阵

$$J = \text{Diag}(a) - aa^\top$$

恰好是 one-hot categorical variable 在概率 a 下的 covariance matrix, 因此 $J \succeq 0$ 且

$$J\mathbf{1} = 0.$$

后一式反映 softmax 对所有 logits 同加常数不变:

$$\text{softmax}(s + c\mathbf{1}) = \text{softmax}(s).$$

这也说明 score 只有相对差异有意义。

13.18 Deep Dive: 为什么 Sparse Attention 仍可能错过关键 token?

设 full attention 中一个关键远程 token 权重虽不大, 但它携带唯一决定答案的 value。若 sparse selector 只根据 coarse proxy 过滤它, 后续精细 attention 再强也无法恢复信息。因此 sparse attention 的核心不是“少算”, 而是用低成本 selector 尽量保留任务相关支持集。这与检索/RAG 的 recall-precision trade-off 十分类似。

13.19 Deep Dive: Causal Attention 的有效计算不是所有 T^2 entries

理论上 causal mask 只允许下三角区域, score 数约为

$$\frac{T(T+1)}{2}.$$

渐近仍是 $O(T^2)$, 常数约减半。训练时所有 query 通常并行; 自回归解码时每一步只新增一个 query, 但需要与已有 T keys 比较, 因此单步 attention 为 $O(Td)$, 生成 T 步累计仍呈二次增长 (忽略其他层与 speculative/parallel decoding)。

分层训练 | 本章分层训练

- A | **推导**: 在 iid 零均值单位方差假设下推导 $\text{Var}(q^\top k) = d_k$ 。
- A | **证明**: 证明单 head 输出在 values 的 convex hull 中。
- B | **微分**: 推导 softmax Jacobian, 并证明 $J\mathbf{1} = 0$ 。
- B | **线代**: 证明 $\text{rank}(QK^\top) \leq d_k$ 。
- C | **系统**: 实现 full/top- k /block sparse 三种 attention, 分别记录 theoretical FLOPs、实际时间和峰值内存, 解释三种排序为什么可能不一致。

13.20 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

Attention 是第 14 章 Transformer 的可微分寻址核心, 并在第 17 章 ICL 中承担“从上下文计算”的候选机制。

Worked Example | Attention 先看成核回归

单 query q 对 keys k_i 的权重

$$\alpha_i = \frac{\exp(q^T k_i / \sqrt{d})}{\sum_j \exp(q^T k_j / \sqrt{d})}, \quad o = \sum_i \alpha_i v_i.$$

它与 Nadaraya–Watson 核回归结构相同：先用相似度形成数据依赖权重，再对 value 做加权平均。不同之处是 query/key/value 都由网络共同学习，核本身不是固定的。

Proof Clinic | 为什么除以 $\sqrt{d}$

若 q_i, k_i 独立、零均值、单位方差，则 $q^T k = \sum_i q_i k_i$ 的方差约为 d 。不缩放时，维度增大会让 logits 标准差增至 $\sqrt{d}$ ，softmax 更容易饱和；除以 $\sqrt{d}$ 把 score 重新保持在 $O(1)$ 尺度。这个论证依赖独立近似，却给出非常清楚的尺度设计理由。

Research Assignment | Gate / sparse attention 机制对照

在相同 synthetic retrieval task 上比较 dense、top-k sparse 与 output-gated attention。记录 accuracy、attention entropy、sink mass、FLOPs proxy；再构造一个稀疏机制会失败的任务。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. Gated Attention 的收益来自新增参数量、非线性、稀疏门控、训练稳定性还是某几项组合？论文 ablation 如何区分？
2. attention sink 使用什么定量定义？高 attention mass 是否一定意味着 harmful sink？
3. NSA 的 sparsity pattern 是静态还是动态？selector 本身的计算和访存代价是否计入？
4. sparse attention 的 benchmark 是否同时报告 prefill、decode、forward、backward？
5. 理论 $O(T^2)$ 的 dense attention 在 Flash-style IO optimization 下可能击败怎样的 sparse baseline？公平比较需要控制哪些 kernel 条件？

习题

1. 给定三个二维 key/value 与一个 query, 手算 scaled dot-product attention 完整输出。
2. 推导 $1/\sqrt{d_k}$ 的方差缩放; 若 q_i, k_i 方差分别为 σ_q^2, σ_k^2 应如何修改量级?
3. 推导 softmax Jacobian, 并解释 one-hot 极限附近为什么梯度容易变小。
4. 证明 attention output 是 values 的凸组合; 给出加入 output projection 后不再满足该性质的例子。
5. 证明 pre-softmax score matrix rank 不超过 d_k , 并说明 softmax 后为何不能直接沿用该 rank bound。
6. 写出 causal mask 的矩阵形式, 计算长度 T 时合法 score entries 数量。
7. 计算 MHA、MQA、GQA 在给定 H, H_{kv}, d_h, L, T 下的 KV cache 比例。
8. 比较 output gate、score gate 与 value gate 的梯度路径。
9. 实现 top- k sparse attention, 构造一个被 selector 丢掉的关键远程 token 使任务失败。
10. 设计一套 full attention 与 sparse attention 的公平系统 benchmark, 至少同时报告 FLOPs proxy、HBM traffic proxy、latency 和 task quality。