

第 14 章 Transformer——位置、残差与可扩展序列计算的完整组装


本章目标

Attention 只解决“内容如何动态互相读取”。Transformer 还必须回答：顺序从哪里来？多层如何稳定叠加？每个位置如何做非线性计算？自回归推理怎样避免重复计算？本章从 permutation equivariance 定理出发说明为什么纯 content-only attention 需要额外的顺序/对称性破缺机制,推导 sinusoidal/RoPE 的相对位置结构,组装 Pre-Norm Decoder Block, 计算 MLP/Attention 参数与 KV cache, 再区分 expressivity、succinctness、length generalization 与 computational universality。Frontier 部分进入 ICLR 2026 Outstanding Paper *Transformers are Inherently Succinct* 与 Oral *Quantitative Bounds for Length Generalization in Transformers*。

Prerequisite Recall | 先把这些知识唤醒

- 已能从第 13 章写出 causal multi-head attention。
- 熟悉残差与 LayerNorm（第 10 章）。
- 会读旋转矩阵、相对位移与计算复杂度。

Visual Derivation | 先看结构，再读公式



读 Decoder block 时先追踪 residual stream, 再把 Attention/MLP 看作往这条主干上写入的增量。

Misconception Check | 本章最容易掉进去的坑

“Transformer = Attention”会漏掉至少三件决定训练和表达的结构: residual stream、MLP/FFN、normalization/position mechanism。Attention 负责动态通信, 不承担全部非线性计算。

Concept Contrast | 把相邻概念主动分开

	Attention	MLP	Residual stream
主要角色	token 间通信	token 内变换	跨层累积/旁路
数据依赖路由	是	否（逐位置）	不是算子本身

Checkpoint | 开始正文前的 30 秒自测

KV cache 为什么能减少 autoregressive decode 的重复计算，却不能把历史读取成本消成常数？**检查答案：**旧 K/V 不再重复投影，但新 query 仍需与越来越多历史 keys/values 交互。

14.1 没有位置的 Self-Attention 不知道“第几个”

设置置换矩阵 $P \in \mathbb{R}^{T \times T}$ ，它只是重排 token 顺序。若没有 positional information，输入变成 PX 。因为

$$Q' = PXW_Q = PQ, \quad K' = PK, \quad V' = PV,$$

score 为

$$Q'K'^\top = PQK^\top P^\top.$$

逐行 softmax 与同一置换相容，因此

$$\text{Attn}(PX) = P \text{Attn}(X).$$

这叫 permutation equivariance：输入怎么重排，输出就跟着同样重排，但模型不能仅凭内容知道哪个 token 在第 3 位、哪个在第 30 位。

证明思路 | 为什么这不是说 Transformer “不关心顺序”？

真正的 Transformer 会加入位置机制，并且 causal mask 本身也破坏完全置换对称性。上述定理只针对**无位置、无位置相关 mask 的 self-attention 核心算子**。它的价值是精确定位：序列顺序不是从 $QK^\top$ 自动长出来的，必须通过额外结构注入。

14.2 绝对位置：最直接的做法

给每个位置一个向量 p_t ，输入

$$h_t^{(0)} = E(x_t) + p_t.$$

若 p_t 为可学习表，训练范围内灵活，但超出已训练最大位置时没有天然定义。固定 sinusoidal position encoding 用多频率正弦/余弦：

$$p_t^{(2i)} = \sin(t/\lambda_i), \quad p_t^{(2i+1)} = \cos(t/\lambda_i).$$

它可延伸到任意 t ，但“数学上可计算”不等于模型训练后会在任意长度泛化。

14.3 为什么正弦编码天然携带相对位移？

二维频率对写成

$$r(t) = \begin{bmatrix} \cos(\omega t) \\ \sin(\omega t) \end{bmatrix}.$$

则

$$r(t)^\top r(s) = \cos(\omega(t - s)).$$

因此两个位置向量的内积只依赖相对差 $t - s$ 。多频率组合相当于用不同尺度的周期基表示相对距离。

14.4 RoPE: 不是把位置向量相加, 而是旋转 Query/Key

对每个二维子空间, 定义旋转矩阵

$$R_t(\omega) = \begin{bmatrix} \cos(\omega t) & -\sin(\omega t) \\ \sin(\omega t) & \cos(\omega t) \end{bmatrix}.$$

RoPE 对 query/key 做

$$q'_t = R_t q_t, \quad k'_s = R_s k_s.$$

注意

$$R_t^\top R_s = R_{s-t},$$

因此

$$(q'_t)^\top k'_s = q_t^\top R_{s-t} k_s,$$

score 中自然出现相对位置 $s - t$ 。




图 14.1 机制级验证：对同一相对位移，RoPE 二维旋转内积在整体平移位置后保持一致。脚本还数值验证无位置 self-attention 的 permutation equivariance。

14.5 RoPE 为什么仍然会遇到长度外推问题？

“score 依赖相对位移”并不意味着任意长 context 都自动可靠。可能的困难至少包括：

1. 训练中从未见过的大相对距离对应新的相位组合；
2. 高频维度旋转过快，长距离出现 aliasing / phase mismatch；
3. attention score/norm 与 softmax 分布随长度改变；
4. 任务本身需要的算法在短长度上未被唯一识别。

因此 length extrapolation 是**位置表示** + **学习到的算法** + **数据覆盖** + **数值尺度**共同问题。

14.6 一个现代 Decoder Block

以 Pre-Norm 为例，

$$u_l = h_l + \text{MHA}(\text{Norm}(h_l)),$$

$$h_{l+1} = u_l + \text{MLP}(\text{Norm}(u_l)).$$

MLP 常写成

$$\text{MLP}(x) = W_2 \phi(W_1 x + b_1) + b_2,$$

也可使用 gated MLP/SwiGLU 等变体。Attention 负责 token mixing, MLP 主要做 channel/feature mixing; residual stream 让二者把增量写回共享状态。

14.7 Residual Stream: 多层共享的一条通信带

写成

$$h_{l+1} = h_l + \Delta_l(h_l).$$

这意味着每层不是从零重建表示，而是在已有状态上写增量。从机制解释角度，可把 attention 看作跨位置读写，把 MLP 看作当前位置 feature transform。这个解释不是唯一分解，但对追踪 circuit 很有用。

14.8 Normalization: 稳定尺度但不会替代结构学习

Transformer 中常见 LayerNorm / RMSNorm。以 RMSNorm 为例，

$$\text{RMSNorm}(x) = \gamma \odot \frac{x}{\sqrt{\frac{1}{d} \sum_i x_i^2 + \epsilon}}.$$

它不减均值，只归一化 RMS。Normalization 主要控制层间尺度与优化动力学；它不会自动让所有 features 正交、不会解决 long-context reasoning，也不会替代良好初始化与学习率设计。

14.9 参数量: Attention 与 MLP 谁更贵?

忽略 bias，标准 MHA 的四个投影 W_Q, W_K, W_V, W_O 大约有

$$4d_{\text{model}}^2$$

参数。若 MLP hidden width 为 d_{ff} ，两层矩阵约

$$2d_{\text{model}}d_{ff}.$$

当 $d_{ff} \approx 4d_{\text{model}}$ 时，MLP 参数约 $8d^2$ ，常比 Attention projection 参数更多。**Attention** 的长序列昂贵主要来自 activation/compute 的 T^2 ，不一定来自参数量。

14.10 训练 FLOPs 与推理 FLOPs 的瓶颈不同

训练时对整段序列并行，attention score 计算近似 $O(T^2d)$ ；MLP 近似 $O(Tdd_{ff})$ 。短序列大模型中 MLP/linear FLOPs 可以主导，超长序列时 T^2 项变得突出。

自回归解码时一次只生成一个新 token。过去 token 的 hidden states 不需要全部重跑，但每层仍需读取历史 K/V。

14.11 KV Cache：省掉重复投影，不省掉历史读取

对第 t 步，新 query q_t 只需与缓存

$$K_{1:t}, V_{1:t}$$

计算 attention。若有 L 层、 H_{kv} 个 KV heads、head dim d_h 、每元素 b bytes，则单 batch 的 cache 近似

$$2LTH_{kv}d_hb \text{ bytes.}$$

因此长 context decode 往往受到 memory bandwidth 限制。GQA/MQA 通过降低 H_{kv} 直接压缩缓存。

一个数量级估算

若 $L = 32, T = 128,000, H_{kv} = 8, d_h = 128, b = 2$ (bf16)，则

$$2 \times 32 \times 128000 \times 8 \times 128 \times 2$$

约为 16 GiB 量级的 KV 数据（未计 batch、allocator、其他状态）。这解释了为什么“模型权重装得下”不等于“长上下文推理装得下”。

14.12 从 Expressivity 到 Succinctness：会表示还不够

Expressivity(表达能力)问：某个函数/语言能不能由这个架构表示？**Succinctness(简洁表示能力)**进一步问：表示同一个对象需要多大的模型？

两个架构都可能是 universal approximator，但一个需要指数规模，另一个只需要多项式规模。对实际学习而言，参数效率和描述长度差异可能比单纯“能不能表示”更有解释力。

14.13 Length Generalization：训练短序列，为何测试长序列会失败？

设模型只在 $T \leq T_{\text{train}}$ 上训练，却要求在

$$T \gg T_{\text{train}}$$

保持算法。失败可能来自两类根源：

1. **表示外推失败**：位置编码/attention 数值超出训练范围；
2. **算法识别失败**：短数据与多个规则都一致，优化器学到的是 shortcut，而不是可递推/可扩展算法。

因此 length generalization 本质上与 identifiability 有关：短样本是否足够约束模型内部行为，使长序列上的延伸几乎唯一？

14.14 Research Frontier I: Transformer 的优势可能是“更短的描述”

Research Frontier | Transformers are Inherently Succinct

会议身份：ICLR 2026 Outstanding Paper。^a

该理论工作提出用 succinctness 衡量 Transformer 表示 concept 的能力，并证明某些 formal languages 相比有限自动机、线性时序逻辑等标准表示可以被 Transformer 更简洁地编码。官方奖项委员会特别强调了这种“用表示简洁性理解 Transformer 能力”的概念视角。

这把常见问题

Transformer 能不能表示这个函数？

升级为

表示它需要多少参数、多少层、多少描述长度？

同时论文也揭示一个反面：表示过于 succinct 可能使 verification 变得计算上困难。能力与可验证性未必同步增长。

^aICLR 2026 官方奖项：Outstanding Papers.

14.15 Research Frontier II: Length Generalization 可以被定量而不是只画外推曲线

Research Frontier | Quantitative Bounds for Length Generalization in Transformers

会议身份：ICLR 2026 Oral。^a

该工作研究“训练长度至少要多大，才能保证更长长度上的行为”。其理论框架区分不同误差控制、softmax/有限精度 attention、单层/双层等情形，并把核心直觉写成一种 simulation 条件：如果长序列内部行为能由训练中见过的较短行为充分模拟，那么 length generalization 才有机会被保证。

对研究者的启示是：不要只报告

$$\text{train length} = 4k, \quad \text{test length} = 32k$$

然后给一个 accuracy。更重要的问题是：训练长度覆盖了哪些内部模式？需要多少种局部/全局配置才能确定长序列算法？

^aICLR 2026 Oral 官方列表: [ICLR 2026 Orals](#).

14.16 Research Frontier III: 长上下文不是一个单一问题

Research Frontier | 从 Context Entropy 到 Position Extrapolation

2026 的 Oral/Poster 中同时出现 context intrinsic entropy、length-generalization bounds、long-context memory agent, 以及对 RoPE complex phase 的扩展研究。这些工作共同说明“支持 1M context”至少包含四个不同命题:

1. **表示:** 位置机制能否数值上扩展到该长度?
2. **计算:** Attention/KV memory 是否负担得起?
3. **学习:** 训练数据是否包含足够长程依赖让模型学会使用?
4. **任务:** 更远的 context 是否真的含有 conditional information?

把四者混成一个 benchmark 分数, 很容易误判研究进展。

Mini Lab | Frontier Replication 14: 先验证 Transformer 的三个结构事实

运行 `labs/frontier/ch14_position_kvcache.py`。基础任务: 数值验证无位置 self-attention 的 permutation equivariance; 加入固定绝对位置后该对称性被打破。进阶任务: 验证二维 RoPE 内积对全局位置平移不变, 只依赖相对 offset。研究任务: 把 ω 扩展成多频率并扫描超长 offset, 观察不同频率的相位重复; 再训练一个短长度 copy/associative-recall toy Transformer, 比较 absolute、RoPE 与 relative-bias 的 length extrapolation。

From Textbook to Research | 我们终于“造出”了 LLM 的骨架

第 11 章给出了条件概率目标, 第 12 章把符号变成向量, 第 13 章构造动态内容寻址, 本章加入位置、非线性、残差、归一化和缓存, 得到可大规模训练的 decoder Transformer。下一篇不再问“架构是什么”, 而开始问: 给这个架构多少数据和计算, 它究竟学到了什么? 规模、生成、后训练与推理能力如何出现?

14.17 Deep Dive: Permutation Equivariance 的矩阵证明

无位置 self-attention

$$F(X) = \text{softmax}(XW_QW_K^\top X^\top / \sqrt{d_k})XW_V.$$

对置换矩阵 P , 有

$$S(PX) = PS(X)P^\top.$$

因为对行列做同一置换只会相应重排每一行 softmax 的 entries,

$$\text{softmax}(PSP^\top) = P\text{softmax}(S)P^\top.$$

于是

$$F(PX) = PF(X).$$

这是一条非常适合“先证明再设计”的结论：对无 mask、无位置输入的 content-only self-attention, 顺序不可辨识由对称性直接推出。对 causal decoder 则不能据此宣称“显式位置编码逻辑上必需”，因为 causal mask 本身已打破一般置换对称性；更准确的设计原则是必须提供足以区分任务相关顺序的对称性破缺机制。

14.18 Deep Dive: RoPE 的复数写法

二维向量 (x_1, x_2) 可写成复数 $z = x_1 + ix_2$ 。位置 t 的旋转就是

$$z \mapsto ze^{i\omega t}.$$

query 与 key 的复内积相位差包含

$$e^{i\omega(s-t)}.$$

标准实现最后映射回实值 attention score。这个视角能更直接看到“绝对相位相消，保留相对相位”的结构，也解释为什么 2026 仍有工作继续研究被使用或丢弃的复相位信息。

14.19 Deep Dive: KV Cache 的时间-内存交换

没有 cache 时, 第 t 步若重新计算所有前缀 K/V, 会重复做大量线性投影。缓存把历史 K/V 的计算从“每步重做”换成“存下来反复读取”。因此它是典型 time-memory trade-off:

$$\text{less repeated FLOPs} \leftrightarrow \text{more persistent memory} + \text{bandwidth}.$$

上下文很长时, 解码瓶颈可能从矩阵算力转向 KV 数据搬运。KV 量化、GQA/MQA、paged cache 与稀疏读取都在优化这个账本的不同项。

14.20 Deep Dive: Expressivity、Learnability、Generalization 是三件事

一个架构存在参数能实现某算法，不代表 SGD 会从给定数据找到它；SGD 能在训练长度找到它，也不代表会外推到更长长度。应区分：

$$\boxed{\text{representable}} \Rightarrow ? \boxed{\text{learnable}} \Rightarrow ? \boxed{\text{length-generalizable}}.$$

三个箭头都不是逻辑必然。很多 Transformer 理论争论混乱，正是因为不同论文回答的是不同层级问题。

14.21 Deep Dive: 一个 Block 的粗略参数账本

令 $d = d_{\text{model}}, d_{ff} = \gamma d$ 。标准 Attention projections 约 $4d^2$ ，两层 MLP 约

$$2dd_{ff} = 2\gamma d^2.$$

若 $\gamma = 4$ ，则每 block 主要矩阵参数约

$$12d^2.$$

L 层即约 $12Ld^2$ ，再加 embeddings、norm 与输出层。这条粗略公式帮助我们从“7B/70B”反推宽度、深度和矩阵规模，但实际 gated MLP、GQA、MoE 会改变常数。

分层训练 | 本章分层训练

- A | **证明**：完整证明无位置 self-attention 的 permutation equivariance。
- A | **推导**：证明 $R_t^\top R_s = R_{s-t}$ ，并推导 RoPE score 的相对位置形式。
- B | **系统**：计算给定 L, T, H_{kv}, d_h, b 的 KV cache，比较 MHA/GQA/MQA。
- B | **结构**：给定 d, d_{ff}, L, V ，估算 decoder-only Transformer 参数量并指出 embeddings 是否主导。
- C | **研究**：设计一个在训练长度上存在多个等价 shortcut、但在长长度上只有算法规则正确的 synthetic task，用它研究 length-generalization 的 identifiability。

14.22 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

完整 Transformer 是第 15 章–第 18 章所有 LLM 理论的函数类载体。

Worked Example | 无位置 self-attention 的置换等变性

令 P 为 token 维度上的置换矩阵, $Q = XW_Q$ 等。对 PX , 有 $Q' = PQ, K' = PK, V' = PV$, 从而

$$Q'K'^T = P(QK^T)P^T.$$

逐行 softmax 与置换相容, 故 $\text{Attn}(PX) = P \text{Attn}(X)$ 。因此架构若要区分顺序, 必须引入位置相关结构; 这不是“经验上位置编码更好”, 而是对称性要求。

Proof Clinic | KV cache 的复杂度账本

自回归生成第 t 个 token 时, 若重新计算所有历史 K, V , 会重复做前缀投影; cache 后只新增当前 token 的 K_t, V_t , 历史直接复用。注意 attention 对历史 keys 的打分仍随 t 增长, 所以 cache 消除的是投影重算, 不把标准 attention magically 变成常数复杂度。

Research Assignment | 位置机制与长度外推

训练 tiny decoder 于长度 L , 分别使用 absolute position、RoPE 与无位置 baseline, 测试 $L, 2L, 4L$ 。除 accuracy 外报告 attention distance profile, 并验证 permutation equivariance 的数值误差。

最低交付: 1 页假设与指标声明; 可复现代码与固定 seed; 主结果图; 至少一个失败/反例; 200–400 字结论边界。**禁止:** 只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. Transformer succinctness 的比较对象是什么表示类? 参数/bit complexity 的度量是否与实际网络规模一致?
2. 一个 Turing-completeness / universality 结果是否意味着有限深度、有限精度、可训练模型能完成该任务?
3. length-generalization theorem 的 training-length bound 依赖哪些精度、层数、误差范数和数据分布假设?
4. RoPE 扩展方法提升长上下文 benchmark 时, 是因为位置表示更好、重新缩放 attention、更长微调数据, 还是几者组合?
5. 报告“支持 N tokens”时, 是否同时测了可寻址性、retrieval、reasoning、generation quality、KV memory 和实际 latency?

习题

1. 用置换矩阵证明无位置 self-attention 的 permutation equivariance。
2. 证明二维 sinusoidal position pair 的内积只依赖位置差。
3. 推导 RoPE 的 $R_t^\top R_s = R_{s-t}$ ，并解释为什么这形成 relative-position score。
4. 写出一个 Pre-Norm decoder block 的完整张量形状，包含 batch、sequence、heads 和 head dimension。
5. 估算 $d = 4096, d_{ff} = 11008$ 时 attention projections 与 MLP 参数量。
6. 对 $L = 40, H_{kv} = 8, d_h = 128, T = 64k$ ，分别计算 bf16 KV cache；若改成 MQA，理论上缩小多少？
7. 解释为什么 KV cache 减少重复 FLOPs，却可能把解码变成 memory-bandwidth-bound。
8. 分别给出 expressivity、succinctness、learnability、length generalization 的例子，说明它们不能互相替代。
9. 修改 Frontier Lab，构造多频率 RoPE 并寻找远距离相位近似重复的位置。
10. 设计一个训练长度 16、测试长度 128 的算法任务，提出至少三种失败原因，并说明实验如何区分“位置外推失败”和“学到 shortcut”。