

第 15 章 LLM 预训练与 Scaling——从交叉熵到计算最优与 Coverage

本章目标

前四篇已经回答了“Transformer 怎样表示和计算”。从这一章开始，我们把它变成真正的大语言模型。预训练并不是简单地把 next-token loss 在更多 GPU 上重复：当参数量 N 、训练 token 数 D 、数值精度、数据混合和计算预算同时进入设计空间时，**训练目标、资源分配与最终能力之间不再由单一 loss 决定**。本章从交叉熵出发，推导 compute-optimal scaling，讨论数据质量、去重与 memorization，并用 coverage 把预训练与后训练、Best-of- N 和 RL 连接起来。

Prerequisite Recall | 先把这些知识唤醒

- 熟悉 cross-entropy/NLL 与 token-level likelihood。
- 会做幂律、log-log 变换和约束优化。
- 记住经验拟合曲线不等于机制定律。

Misconception Check | 本章最容易掉进去的坑

“模型越大一定越好”忽略固定 compute 下的机会成本。参数、数据 token、precision、数据质量和训练步数共享预算；Scaling law 真正研究的是**预算约束下如何分配资源**。

Concept Contrast | 把相邻概念主动分开

	Descriptive scaling	Compute-optimal scaling
问题	loss 随规模怎样变	固定预算怎么配 N, D
结论形式	拟合指数	约束优化后的分配律
风险	外推失效	依赖拟合 ansatz

Checkpoint | 开始正文前的 30 秒自测

若只把参数量 N 增大而数据 D 不变，为什么不能从单变量 scaling 曲线断言性能会一直按同一指数改善？**检查答案：**你已离开原拟合的数据/计算配比，data-limited、memorization 与优化瓶颈都可能改变 regime。

15.1 预训练仍然是最大似然，但“分布”本身成为设计变量

给定 token 序列 $x_{1:T}$ ，decoder-only LLM 使用

$$p_{\theta}(x_{1:T}) = \prod_{t=1}^T p_{\theta}(x_t | x_{<t})$$

并最小化 token-level negative log-likelihood

$$L(\theta) = -\frac{1}{\sum_i T_i} \sum_i \sum_{t=1}^{T_i} \log p_{\theta}(x_t^{(i)} | x_{<t}^{(i)}).$$

如果对数底为 2，它可以写成 bits per token；若使用自然对数，则常报告 nats/token。Perplexity 是

$$\text{PPL} = \exp(L).$$

它可以理解为模型在每一步面对的“等效候选分支数”，但不要将 PPL 当作下游能力的充分统计量。

现代预训练真正变化的是经验分布。若数据来自 K 个来源 $D_1, \dots, D_K$ ，采样权重为 α_k ，则

$$L(\theta; \alpha) = \sum_{k=1}^K \alpha_k \mathbb{E}_{x \sim D_k} [-\log p_{\theta}(x)], \quad \sum_k \alpha_k = 1.$$

因此“网页 60%、代码 20%、数学 10%……”并不是工程备注，而是在定义目标函数。

数据混合为什么直接改变梯度？

交换梯度与期望后，

$$\nabla_{\theta} L = \sum_k \alpha_k \mathbb{E}_{x \sim D_k} [-\nabla_{\theta} \log p_{\theta}(x)].$$

把某一来源的采样权重翻倍，就会在期望意义上放大这一来源对参数更新的贡献。数据策展因此与 loss weighting、本质上属于同一类控制手段。

15.2 从“模型更大”到三变量资源问题

对 dense Transformer，一个常用的量级估算是：训练 FLOPs 与参数数 N 和训练 token 数 D 近似满足

$$C \approx \kappa ND,$$

其中 κ 吸收 forward/backward、架构细节和实现常数。这个公式不是精确计费器，但足以揭示核心矛盾：固定计算 C 下，参数更多意味着每个参数看到的 token 更少。

经验 scaling law 常使用类似

$$L(N, D) = L_{\infty} + AN^{-\alpha} + BD^{-\beta}$$

的形式，其中 L_{∞} 表示不可约部分， $\alpha, \beta > 0$ 是经验指数。关键不是背诵某一组指数，而是理解：**模型受参数瓶颈与数据瓶颈共同限制**。

固定计算下的 compute-optimal allocation

把 $D = C/(\kappa N)$ 代入上式并忽略 L_{∞} ：

$$f(N) = AN^{-\alpha} + B \left(\frac{C}{\kappa N} \right)^{-\beta} = AN^{-\alpha} + B\kappa^{\beta} C^{-\beta} N^{\beta}.$$

令导数为零，得到

$$\alpha AN^{-\alpha-1} = \beta B\kappa^{\beta} C^{-\beta} N^{\beta-1}.$$

所以

$$N^* \propto C^{\frac{\beta}{\alpha+\beta}}, \quad D^* \propto C^{\frac{\alpha}{\alpha+\beta}}.$$

Scaling law 在这里的价值不是“预测未来”，而是把资源选择变成可估计、可证伪的优化问题。

不要把经验幂律写成自然定律

Scaling exponent 会随数据管线、模型族、训练配方、tokenizer、精度和评价区间变化。把在一个尺度区间拟合出的直线外推几个数量级，是一个额外假设，而不是定理。严谨实验至少应报告拟合范围、残差、置信区间与 held-out scale。

15.3 “有效 token” 比原始 token 数更接近学习问题

如果数据完全重复， D 增加并不会提供同等数量的新信息。若第 j 个文档出现 m_j 次，其经验权重被隐式放大为 m_j 。去重会改变三件事：训练成本、样本频率、梯度分布。

同样，数据质量也不能只用“过滤比例”描述。一个有用的抽象是把原始 token 数 D 映射成任务相关的有效 token 数

$$D_{\text{eff}} = \sum_{i=1}^D q_i,$$

其中 $q_i \in [0, 1]$ 表示 token 对目标知识或能力的边际信息价值。真实 q_i 并不可直接观测，但这个记号提醒我们：**同样一万亿 token 可以对应完全不同的学习信号**。

15.4 精度也是 scaling 变量

参数量与 token 数之外，低精度训练/推理改变单位算力的成本和可表示数值范围。若量化误差让一个参数携带的“有效自由度”下降，就可以把精度 P 看成第三个 scaling 变量：

$$L = L(N, D, P).$$

这会产生反直觉 trade-off：同一硬件预算下，较低精度允许更大的模型，但每个参数更噪；训练数据越来越多时，后训练量化造成的损失也可能不再是常数项。

Research Frontier | Scaling Laws for Precision

会议身份：ICLR 2025 Oral。论文构造 precision-aware scaling laws，提出低精度训练可用“effective parameter count”理解，并研究 post-training quantization 的误差如何随训练数据规模变化。

教材连接：经典 scaling 只把 N, D, C 放进资源方程；这项工作提醒我们，数值表示本身也是模型容量的一部分。

官方入口：[ICLR 2025 Oral program](#)

15.5 Memorization 与 Generalization 不是二选一

对有限训练集，模型当然可能保留与具体样本有关的信息；但“它记住了某条字符串”和“它学到了生成这类字符串的规律”是两个不同命题。

可以用信息论语言构造一个示意性分解。设随机训练集为 S ，再随机选取其中一个样本 Z ，学习算法（包括初始化等随机性）的输出为 W 。在这些随机变量定义清楚时， $I(W; Z | S \setminus Z)$ 可描述“给定其余样本后，模型状态额外携带了多少关于该样本的信息”。它不是 memorization 的唯一或普适定义；对真实数据分布结构的学习也可能同时提升未见样本 likelihood。真正困难的是把 sample-specific information 与可泛化结构在具体实验中操作性地分离。

Research Frontier | How much can language models memorize?

会议身份：ICML 2026 Outstanding Paper Honorable Mention。论文从信息量角度区分 intended memorization/generalization 与 unintended memorization，并通过大量 GPT-style 模型估计容量；官方奖项介绍特别强调其理论分解，并报告论文对 GPT-style 模型给出约 3.6 bits/parameter 的容量估计。

为什么重要：这不是“3.6 是永恒常数”，而是一种研究范式：先给 memorization 可操作定义，再讨论容量随参数和数据怎样 scaling。

官方来源：[ICML 2026 Awards](#)

15.6 从平均 NLL 到 Coverage: 预训练究竟为后训练准备了什么?

设一个 prompt 为 x , 存在高质量回答集合 $G(x)$ 。定义基础模型的 coverage

$$c_{\theta}(x) = \mathbb{P}_{y \sim \pi_{\theta}(\cdot|x)}[y \in G(x)] = \sum_{y \in G(x)} \pi_{\theta}(y|x).$$

这和平均交叉熵不同: 模型可以在大量普通 token 上获得很低 loss, 却仍对某个任务的正确轨迹分配几乎零概率。

如果独立采样 N 次且 verifier 完美, 至少得到一个高质量回答的概率为

$$1 - (1 - c_{\theta}(x))^N.$$

于是得到一个清楚的基线结论: 在“固定策略 + 独立采样 + 完美 verifier”的 Best-of- N 模型里, test-time scaling 的成功上限直接受 base-model coverage 控制。真实系统还会受到候选相关性、verifier 误差、搜索改变分布以及计算预算的共同影响。

Research Frontier | The Coverage Principle: How Pre-Training Enables Post-Training

会议身份: ICLR 2026 Oral。该工作指出 cross-entropy 可能并不很好预测 downstream post-training 表现, 提出 coverage 来刻画基础模型在高质量回答集合上的概率质量, 并证明/分析 coverage 对 Best-of- N 、post-training 成功的重要性。

本书主线: 第 15 章的预训练、第 16 章的 test-time compute 和第 18 章的 RL/DPO 因此可以用同一个对象连接: 模型原本有没有给好轨迹足够的概率质量?

官方入口: [ICLR 2026 Oral program](#)




图 15.1 机制级实验: 左图由二项幂律 loss 与固定计算约束推导 compute-optimal 参数/数据分配; 右图故意构造 coverage 与平均 NLL 不同步的训练轨迹, 提醒学生两种指标回答不同问题。

15.7 能力评测最危险的混杂：训练任务本身进入训练分布

benchmark contamination 通常指测试样本直接泄漏；但还有更微妙的问题：模型没有看到测试实例，却在预训练或数据合成阶段大量看到与 benchmark 高度同构的任务。

Research Frontier | Training on the Test Task Confounds Evaluation and Emergence

会议身份：ICLR 2025 Oral。论文区分了“training on test data”和“training on the test task”：后者未必是不当行为，却会混淆模型家族比较和 emergent capability 结论。作者还展示，一些看似突然出现的 emergence 会随着 task-relevant training 增强而逐渐消失。

科研训练：能力曲线不是只有 x 轴的“模型规模”。数据分布也是隐藏自变量。

论文入口：[ICLR Proceedings](#)

Mini Lab | Frontier Lab 15: Scaling + Coverage

运行 `labs/frontier/ch15_scaling_coverage.py`。第一部分从 $L_\infty + AN^{-\alpha} + BD^{-\beta}$ 与 $C = ND$ 数值验证最优 allocation exponent；第二部分构造平均 NLL 缓慢改善、coverage 快速提升的异质任务。升级实验：训练 4–8 个 tiny Transformer，真实拟合 α, β ，并用 held-out scale 检验外推。

From Textbook to Research | 预训练的目标应该只是更低 cross-entropy 吗？

如果后训练、Best-of- N 和 RL 都需要基础模型先“覆盖”好轨迹，那么未来预训练目标可能不仅优化平均 token loss，还会显式考虑稀有高价值轨迹、数据多样性与可探索性。问题随之变成：**怎样提高 coverage，而不只是让分布变平？怎样区分真正的能力覆盖与无意义的随机多样性？**

15.8 Deep Dive: Scaling law 是约束优化，不是曲线崇拜

最常见误解是看到 log-log 直线就把它当作“智能的物理定律”。真正可复用的方法论有三步：先选可操作的资源变量，再提出低维经验模型，最后用未参与拟合的尺度检验外推。

15.8.1 从拉格朗日乘子重新看 compute-optimal

直接最小化

$$AN^{-\alpha} + BD^{-\beta}$$

并施加 $ND = C$ 。拉格朗日函数

$$\mathcal{J} = AN^{-\alpha} + BD^{-\beta} + \lambda(ND - C).$$

一阶条件给出

$$\alpha AN^{-\alpha} = \beta BD^{-\beta}.$$

因此在最优点，参数瓶颈项与数据瓶颈项并非简单“相等”，而是按 exponent 加权平衡。这个关系比具体的数值指数更值得记住。

15.8.2 为什么小尺度拟合可能误导？

假设真实 loss 有三项

$$L = L_{\infty} + AN^{-\alpha} + BD^{-\beta} + G(N, D),$$

其中 G 在小尺度来自优化不稳定，在大尺度来自数据质量饱和。若拟合区间恰好避开 G ，幂律表现会很好；一旦外推进入 G 主导区域，预测就会系统失真。因此 scaling 实验必须问：*residual* 是否随机？是否随 *scale* 呈结构？

15.9 Deep Dive: Coverage 是集合概率，不是单个答案概率

很多 reasoning task 有多个正确解。若只跟踪一个 reference answer 的概率 $\pi(y^*|x)$ ，会把同样正确的替代轨迹视为错误。Coverage 使用集合

$$G(x) = \{y : R(x, y) = 1\}$$

并计算

$$c(x) = \sum_{y \in G(x)} \pi(y|x).$$

这把问题从“模仿一个答案”改成“在整个可接受集合上分配概率质量”。

15.9.1 Coverage 与 entropy 的关系并不单调

增加 entropy 可能提升探索，也可能只是把质量分给大量垃圾回答。一个分布可以 entropy 很高而 $c(x)$ 极低；也可以 entropy 较低但把质量集中在多个好答案上。因而“提高多样性”不是“提高有效覆盖”的同义词。

15.9.2 手算：同 NLL，不同 Coverage

设 vocabulary 只有三个完整响应 $\{g, b_1, b_2\}$ ，其中只有 g 是正确。模型 A 分布为 $(0.20, 0.40, 0.40)$ ；模型 B 为 $(0.40, 0.59, 0.01)$ 。如果训练 reference 恰好是 b_1 ，A 对 reference 的 NLL 更低，但在真正任务 reward 下 B 的 coverage 更高。这个 toy example 提醒我们：训练 surrogate 与最终 utility 不一定排序一致。

15.10 Deep Dive：把数据质量写成重要性加权

如果理想目标分布为 $p^*(x)$ ，实际抓取分布为 $q(x)$ ，理论上

$$\mathbb{E}_{p^*}[\ell(x)] = \mathbb{E}_q \left[\frac{p^*(x)}{q(x)} \ell(x) \right].$$

现实中我们不知道 p^*/q ，数据过滤器、质量分类器和域重采样本质上是在近似这个比率。问题随即变成经典 importance sampling 的问题：权重过尖会导致方差巨大；过滤过强会损失覆盖。

研究者应问什么？

如果一个新的数据过滤方法让 validation loss 下降 0.01，但下游 reasoning coverage 下降，它是否真的“改进了预训练”？反过来，如果平均 loss 略差、稀有能力 coverage 却显著增加，应该怎样重新定义 compute-optimal？这正是把教材公式推向研究问题的方式。

15.11 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

预训练决定 base policy/support；第 16 章改变采样计算，第 18 章再重新分配这些概率质量。

Worked Example | Compute-optimal scaling 手推一次

设 excess loss $AN^{-\alpha} + BD^{-\beta}$ ，计算约束 $C = kND$ 。代入 $D = C/(kN)$ 后对 N 求导，可得平衡条件

$$\alpha AN^{-\alpha} = \beta BD^{-\beta},$$

因此

$$N^* \propto C^{\beta/(\alpha+\beta)}, \quad D^* \propto C^{\alpha/(\alpha+\beta)}.$$

重要的是指数来自两种资源的边际回报平衡，而不是“模型和数据都按平方根涨”的固定规律。

Proof Clinic | Coverage 与平均 loss 是不同对象

若正确 reasoning trajectory 在 base model 下概率仅 10^{-6} ，平均 token NLL 可能看起来不差，但 Best-of- N 至少采到一次它的概率约为 $1 - (1 - 10^{-6})^N$ 。要达到 50% 需要 $N \approx 6.9 \times 10^5$ 。因此平均 loss、support 与可通过采样覆盖到的能力不能混为一谈。

Research Assignment | Scaling fit 不确定性报告

用至少三个 model size 和三个 data budget 拟合 power law；必须给 bootstrap/拟合区间，并用 held-out scale 检查外推。再把 token quality 或重复率加入 effective data 变量，比较结论是否稳定。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. scaling paper 的横轴究竟是参数、active parameters、FLOPs、token，还是 wall-clock？
2. 幂律拟合是否有 held-out scale？指数的不确定性是否报告？
3. 数据质量变化时，作者仍把 token 数当作可直接比较的 D 吗？
4. memorization 的操作定义是 extraction、membership、mutual information，还是别的量？
5. coverage 的“good set”由谁定义？verifier error 会不会把垃圾轨迹计入？
6. benchmark 是否存在 training-on-test-task 混杂？
7. 低精度带来的收益是算法收益、硬件吞吐收益还是二者共同？

分层习题

分层训练 | Level A | 概念与计算

1. 若某领域数据采样权重从 0.1 改为 0.2，写出经验风险与期望梯度的变化。
2. 已知 token NLL 为 2.3 nats，计算 perplexity。
3. 对 $c = 0.1$ ，计算 Best-of-1, 8, 32 在完美 verifier 下至少命中一次的概率。
4. 解释“去重减少数据量”和“去重改变训练分布”的差别。

分层训练 | Level B | 推导

1. 完整推导 N^*, D^* 的 compute-optimal scaling 指数, 并讨论 $\alpha = \beta$ 的特殊情形。
2. 若计算约束变成 $C \propto N^\gamma D$, 重新推导最优指数。
3. 给出两个模型: A 的平均 NLL 更低但 coverage 更低, B 相反。构造一个最小离散分布实例。
4. 证明独立采样下至少一次成功概率为 $1 - (1 - c)^N$, 并求为了达到目标成功率 q 所需的最小 N 。

分层训练 | Level C | 研究设计

1. 设计一个实验区分 benchmark contamination、training on test task 与真正的 out-of-distribution generalization。
2. 如果低精度相当于降低 effective parameter count, 你会怎样扩展 $L(N, D)$ 的 scaling ansatz?
3. 设计 coverage 的可估计 proxy, 并分析 verifier false positive 会造成什么偏差。
4. 阅读一篇 scaling paper, 检查其外推结论是否有 held-out scale 支持, 而不是只看 R^2 。