

第 16 章 LLM 解码与测试时计算——搜索、验证与计算分配

本章目标

预训练得到的是一个条件分布 $\pi_\theta(y|x)$ ，而用户最终看到的是一次具体决策。解码因此不是“模型之后的工程尾巴”，而是把概率变成效用的算法层。本章从 temperature、top- k /top- p 推到 sequence search、Best-of- N 、verifier、speculative decoding 与 compute-optimal inference，并解释为什么“思考更久”不等于“无条件更正确”。

Prerequisite Recall | 先把这些知识唤醒

- 会从 logits 得到 softmax 概率。
- 理解 sequence probability 是 token 条件概率乘积。
- 熟悉预算约束与基本 order statistics。

Visual Derivation | 先看结构，再读公式

```
graph TD; BOS((BOS)) --- A((A)); BOS --- B((B)); A --- C((C)); A --- E((E)); B --- E --- F((F));
```

token greedy：每层局部选边

sequence search：比较整条路径

verifier：给完整/中间路径打分

Misconception Check | 本章最容易掉进去的坑

Greedy 每步选最大 token 不等于得到全局最高概率序列。局部最优 token 可能把后续带入低概率分支；sequence-level MAP 是另一种组合搜索问题。

Concept Contrast | 把相邻概念主动分开

	Sampling	Search	Verification
作用	产生候选	分配扩展预算	选择/打分候选
主要误差	support/多样性	搜索不足	verifier 偏差/噪声

Checkpoint | 开始正文前的 30 秒自测

Best-of- N 的候选越多为什么可能反而被 noisy verifier 选差？**检查答案：**候选极值和评分噪声都被放大，会出现 optimizer's curse； N 增大不保证真实 utility 单调改善。

16.1 Temperature 是对 logit gap 的统一缩放

给 logits z_i ，温度为 $T > 0$ 时

$$p_i(T) = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}.$$

任意两 token 的 odds ratio 为

$$\frac{p_i(T)}{p_j(T)} = \exp\left(\frac{z_i - z_j}{T}\right).$$

所以 temperature 不改变 logit 排序，只改变差距被放大的程度。 $T \rightarrow 0$ 时趋于 argmax； $T \rightarrow \infty$ 时趋于均匀分布（在有限词表上）。

Temperature 对期望 logit 的导数

记 $\tau = 1/T$ ， $p_i(\tau) = e^{\tau z_i}/Z$ 。则

$$\frac{\partial \log Z}{\partial \tau} = \mathbb{E}_p[z], \quad \frac{\partial^2 \log Z}{\partial \tau^2} = \text{Var}_p(z) \geq 0.$$

因此 inverse temperature 增大时，分布会系统性偏向高 logit；partition function 的曲率正是 logit 方差。这和统计物理中的 Gibbs distribution 是同一个数学结构。

16.2 Truncation sampling：先改变支持集，再重新归一化

Top- k 保留概率最高的 k 个 token；top- p (nucleus) 选择最小集合 S 使

$$\sum_{i \in S} p_i \geq p_0.$$

二者的差异在于 top- k 固定候选数量，而 top- p 随分布尖锐度自适应候选数量。高 entropy 步骤可能保留更多 token，低 entropy 步骤则只保留少数。

任何 truncation 都会引入新分布

$$\tilde{p}_i = \frac{p_i \mathbf{1}(i \in S)}{\sum_{j \in S} p_j}.$$

所以它不是“从原模型更聪明地采样”，而是在明确修改模型分布。

Research Frontier | Turning Up the Heat: Min-p Sampling for Creative and Coherent LLM Outputs

会议身份: ICLR 2025 Oral。该工作研究高温下 top- p 等方法的质量-多样性矛盾, 并提出相对最大概率设置阈值的 min- p sampling。

教材连接: sampling rule 的核心是如何根据局部分布形状定义支持集, 而不是记忆一个固定超参数。

官方入口: [ICLR 2025 Oral program](#)

16.3 Token-level greedy 不等于 sequence-level MAP

我们真正想最大化的是

$$y_{1:T}^* = \arg \max_{y_{1:T}} \sum_{t=1}^T \log p(y_t | y_{<t}, x).$$

Greedy 在每一步选择当前最大项, 只对局部目标最优。前面一旦选择概率略高但后续很差的前缀, 就可能输给第一步概率略低、后续几乎确定的路径。

Beam search 用宽度 B 保存多个前缀, 是有限宽度的图搜索。它仍不保证全局最优, 而且 raw log-prob 通常偏好短序列, 需要 length normalization 或 task utility 修正。

16.4 Decoder 本质上是 Bayes decision rule

模型给分布 $p(y|x)$, 系统真正关心 utility $u(y, x)$ 。最理想的决策应是

$$\delta^*(x) = \arg \max_a \mathbb{E}_{Y \sim p(\cdot|x)}[u(a, Y, x)].$$

0-1 loss 下它退化为 MAP; 创意写作、多答案数学题、风险敏感任务则未必如此。于是“最佳 decoder”没有脱离任务效用的统一答案。

16.5 Best-of- N : test-time scaling 的最小数学模型

设一次采样命中正确集合的概率为 p 。如果 verifier 完美, N 次独立采样后至少一个正确的概率为

$$S_N = 1 - (1 - p)^N.$$

边际收益

$$S_{N+1} - S_N = p(1 - p)^N$$

指数衰减。在独立同分布采样且单样本成功率固定的模型里, 这给出严格的“边际收益递减”基线; 相关采样、搜索或随预算改变的策略不受这条简单公式直接支配。

更一般地，若每个候选的真实质量 $Q \in [0, 1]$ 、候选 i.i.d. 且完美 verifier 选择最大者，则

$$\mathbb{P}(Q_{\max} \leq q) = F(q)^N,$$

从 tail-integral identity 得

$$\mathbb{E}[Q_{\max}] = \int_0^1 \mathbb{P}(Q_{\max} > q) dq = \int_0^1 (1 - F(q)^N) dq.$$

若 Q 支持不在 $[0, 1]$ ，积分上下限与负值修正必须相应改变。Best-of- N 的收益由质量分布尾部决定，而不只由均值决定。

16.6 Verifier 不是免费的 oracle

若 verifier score $V(y)$ 与真实质量不完全一致，采样更多会给“被 verifier 误判为高分”的候选更多机会。极端情况下，optimizer’s curse 会使选择后的 verifier score 上升而真实质量下降。

Test-time compute 的三种瓶颈

1. **Coverage bottleneck**: 基础模型根本采不到好轨迹;
2. **Verifier bottleneck**: 能采到，但不会识别;
3. **Allocation bottleneck**: 预算没有分给最需要额外计算的问题。

把三者都叫“reasoning 不够”会阻碍研究定位。

16.7 Compute-optimal inference: 不同题目不应使用同样预算

设第 i 个 prompt 使用 n_i 次采样后成功率为 $S_i(n_i)$ ，总预算为

$$\sum_i n_i \leq B.$$

最优分配问题是

$$\max_{n_1, \dots, n_m} \sum_i S_i(n_i) \quad \text{s.t.} \quad \sum_i n_i \leq B.$$

若 S_i 具有递减边际收益，直觉上应把下一单位计算分给当前 marginal gain 最大的题，而不是所有题都固定采样 32 次。

Research Frontier | Scaling LLM Test-Time Compute Optimally Can be More Effective than Scaling Parameters for Reasoning

会议身份：ICLR 2025 Oral。论文比较基于 process reward model 的搜索与测试时分布自适应，强调最优策略依赖题目难度；compute-optimal allocation 相比固定 Best-of- N 可显著提高效率，并在部分 FLOPs-matched 设置中让较小模型利用测试时计算超过更大的模型。

教材连接：inference scaling 不是“统一加长 CoT”，而是一个受难度与 verifier 质量约束的资源分配问题。

论文入口：[ICLR Proceedings](#)




图 16.1 机制级实验：Best-of- N 的收益随 N 递减；对不同难度 prompt 做边际收益分配可优于统一预算。右图展示 verifier 有噪声时，更多候选并不会像完美 verifier 那样持续接近 100%。

16.8 Sequential scaling 与 Parallel scaling

所谓“多想一会儿”至少有两种完全不同的计算图：

1. **Sequential：**一条 trajectory 更长，允许 self-revision、tool call、reflection；
2. **Parallel：**同时采多个短 trajectory，再 vote 或 verify。

Sequential 的优势是后续 token 可条件于已有推理；风险是错误自我修正、冗余与 drift。Parallel 的优势是保持多样解分支；代价是需要聚合器/验证器。

Research Frontier | Revisiting the Test-Time Scaling of o1-like Models

ACL 2025 长文对多种 o1-like 模型研究发现，更长 CoT 并不一致地带来更高正确率，错误回答往往伴随更多无效 self-revision；论文比较 sequential 与 parallel scaling，并提出结合长度特征的选择策略。

研究启示：“token 更多”只是计算量指标，不是有效推理步骤指标。

论文入口：[ACL Anthology](#)

16.9 Speculative decoding: 加速而不必改变目标分布

系统优化还有另一条路线：不是花更多测试时计算提升答案，而是用更便宜的 draft model 提议 token，再由 target model 校验。

在单步 rejection-sampling 视角，draft $q(x)$ 提议 x ，以

$$a(x) = \min\left(1, \frac{p(x)}{q(x)}\right)$$

接受；拒绝时再从适当 residual distribution 采样。经过正确构造后，最终样本仍来自目标 p 。这与普通“用小模型近似大模型”非常不同：算法可以提速，同时保持目标分布精确性。

Research Frontier | Faster Cascades via Speculative Decoding

会议身份：ICLR 2025 Outstanding Paper Honorable Mention。它代表一个重要研究习惯：讨论推理效率时，应明确算法究竟是近似目标分布，还是保留目标分布但减少昂贵模型调用。

奖项来源：ICLR 2025 Awards

16.10 Frontier: 生成顺序也可以被重新设计

自回归并非唯一生成机制。ICML 2024 Best Paper *Discrete Diffusion Modeling by Estimating the Ratios of the Data Distribution* 为离散 diffusion 构造 score/ratio 学习方法；ICML 2026 Outstanding Paper *The Flexibility Trap* 又指出 arbitrary-order generation 的“自由”在推理问题上可能成为坏 inductive bias：confidence-first 可能避开高不确定但决定解分叉的 token。

这个案例很适合训练研究品味：架构自由度不是天然优势；自由度必须与任务结构匹配。

Mini Lab | Frontier Lab 16: Test-Time Compute Allocation

运行 `labs/frontier/ch16_testtime_compute.py`。实验构造不同单次成功率的 prompt，比较统一 Best-of- N 与按 marginal gain 自适应分配；再加入 noisy verifier，观察“采更多”何时被验证误差限制。升级版可接一个 0.5B–1.5B 开源模型与可自动校验的算术任务。

From Textbook to Research | “Reasoning model” 到底 scale 的是什么？

可能是基础模型 coverage、更长 sequential computation、更强 verifier、并行 search、RL 后概率重排，或这些因素的组合。一个好的实验必须把这些轴拆开，并在等 FLOPs、等采样数、等 base model 的条件下比较。否则“模型会思考”很容易变成无法证伪的叙述。

16.11 Deep Dive: Best-of-N 作为次序统计

设完整响应的 utility U 具有累积分布 $F(u)$ 。 N 个独立样本的最大值满足

$$F_{\max}(u) = F(u)^N.$$

如果 $U \in [0, 1]$, 则

$$\mathbb{E}[U_{\max}] = \int_0^1 (1 - F(u)^N) du.$$

这说明 test-time scaling 快慢由上尾决定。两个模型平均 utility 一样, 但尾部更厚的模型可能更适合 Best-of- N 。

16.11.1 Coverage 与 Best-of- N 的统一

若 utility 只有二值 $U \in \{0, 1\}$, 且 $\mathbb{P}(U = 1) = c$, 上式恰好退化为

$$\mathbb{E}[U_{\max}] = 1 - (1 - c)^N.$$

因此第 15 章 coverage 不是抽象概念, 而是第 16 章 inference scaling 曲线的起点。

16.12 Deep Dive: 验证器噪声与赢家诅咒

设 verifier 观测

$$V_i = Q_i + \epsilon_i,$$

其中 Q_i 是真实质量, ϵ_i 是噪声。系统选

$$i^* = \arg \max_i V_i.$$

随着候选数增加, 最大 V_i 越来越可能包含一个极端正噪声。即便 Q 分布不变, 条件期望

$$\mathbb{E}[\epsilon_{i^*}] > 0$$

并会随搜索强度增加。这是 reward hacking、judge overoptimization 与经典 winner's curse 的共同数学骨架。

16.13 Deep Dive: Search 与 Policy Improvement

Best-of- N 可以看成用 base policy π_0 产生候选, 再经 verifier 形成改进分布 π_{search} 。如果之后对这些高质量样本做 SFT, 就在尝试把昂贵的 test-time search **amortize** 回模型参数。第 18 章的 self-improvement / sharpening 正是这个想法的训练版:

$$\text{sample/search} \rightarrow \text{select} \rightarrow \text{update policy}.$$

16.13.1 手算：什么时候该停止继续采样？

若一次额外 sample 成本为 c ，成功价值为 V ，当前已采 N 次仍未成功，额外一次采样的期望增益约为

$$Vp(1-p)^N - c.$$

当它小于零时，继续采样在该简单模型下不再经济。真实系统会让 p 随 search state 改变，但这个式子已经展示“计算最优”必须包含机会成本。

研究者应问什么？

当一个 test-time scaling 方法声称“随着 token 变长性能提升”，应马上追问：总 FLOPs 是否相等？parallel baseline 是否调优？verifier 成本是否计入？模型是否只是因为 sampling temperature 改变而覆盖了更多答案？把这些变量拆开，才能从产品现象进入科学结论。

16.14 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

Test-time search 会在第 19 章 agentic retrieval 与第 21 章 planning 中从 token sampling 升级为环境动作搜索。

Worked Example | Best-of- N 的收益和 verifier 的错误分开算

若独立样本成功率为 p ，oracle verifier 下 Best-of- N 成功率是 $1 - (1 - p)^N$ 。但 noisy verifier 选择最大 score 时， N 越大也给噪声更多“赢得极值”的机会。于是 candidate quality 改善与 selection error 是两个竞争的 order-statistics 过程；不能只凭更大的 N 推断最终正确率必升。

Proof Clinic | Temperature 改变的是 odds

temperature T 下 $p_i \propto e^{z_i/T}$ ，故两个 token 的 odds 满足

$$\frac{p_i}{p_j} = \exp\left(\frac{z_i - z_j}{T}\right).$$

$T > 1$ 把 log-odds 缩小， $T < 1$ 放大。它不“增加知识”，只是重新塑造现有 logit 差异。这个区分对 reasoning sampling 和 RLVR 都很关键。

Research Assignment | Verifier budget allocation

给不同难度问题估计 success-vs-budget 曲线 $S_i(n)$ ，在总预算下比较均匀分配、难度启发式与基于边际收益的 allocation。加入 verifier noise 后重复实验。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. 论文的 test-time compute 用 token、FLOPs、model calls 还是 wall-clock 衡量？
2. sequential 与 parallel baseline 是否在相同预算下比较？
3. verifier 是 oracle、learned reward model 还是 LLM-as-judge？其误差是否计入？
4. Best-of- N 的收益来自 coverage、candidate diversity 还是 verifier 更强？
5. search 是否改变目标模型分布？speculative decoding 是否保持 exactness？
6. 长 CoT 的提升是否仍在控制题目难度后成立？
7. 解码超参数是否针对每个 benchmark 单独调过？

分层习题

分层训练 | Level A | 概念与计算

1. 证明 temperature 不改变 logits 的排序。
2. 构造 greedy 不是 sequence MAP 的两步反例。
3. $p = 0.08$ 时，求 Best-of-16 至少一次成功概率。
4. 比较 top- k 与 top- p 在尖锐分布和接近均匀分布下的支持集大小。

分层训练 | Level B | 推导

1. 推导 $S_{N+1} - S_N = p(1 - p)^N$ 并证明边际收益递减。
2. 对 $Q \sim \text{Uniform}(0, 1)$ ，求 N 个候选最大质量的期望。
3. 设 verifier 对正确/错误候选分别有 true-positive/false-positive rate，分析 Best-of- N 选择错误的概率如何随 N 变化。
4. 证明 rejection sampling 的接受部分质量为 $\min(p(x), q(x))$ 。

分层训练 | Level C | 研究设计

1. 设计一个 FLOPs-matched 实验比较“大模型一次采样”和“小模型多次采样+verifier”。
2. 设计指标区分“有效 self-correction”和“只是生成更长文本”。
3. 如果 prompt 难度不可直接观测，怎样在线估计每题的 compute allocation？
4. 选择一个非 AR 生成方法，明确指出它改变了训练目标、采样顺序还是两者都改变。