

第 18 章 后训练、偏好优化与 RLVR

——概率质量如何被重新塑形


本章目标

预训练回答“哪些序列像数据”，后训练回答“在给定意图下，哪些序列更值得生成”。本章把 SFT、reward model、KL-regularized RL、DPO、online RL 与 RLVR 放进同一个概率视角：**它们都在重新分配 base policy 的序列概率质量，只是监督信号、采样分布与探索机制不同。**我们会完整推导 DPO，推导 sequence policy gradient，讨论 coverage、credit assignment 与 reward hacking，并进入 2025–2026 关于“RLVR 是否真的创造新 reasoning”的前沿争论。

Prerequisite Recall | 先把这些知识唤醒

- 熟悉 MLE/SFT 与 KL。
- 知道 policy $\pi(y | x)$ 本质上仍是条件分布。
- 会读期望奖励与 policy gradient。

Visual Derivation | 先看结构，再读公式



不要把后训练方法按“新旧算法名”记忆；要沿着监督信号如何定义、概率质量如何搬运、reference 约束在哪里来比较。

Misconception Check | 本章最容易掉进去的坑

DPO 不是“完全不需要 reward 概念”。它消去了显式 reward model 的训练/调用，但目标仍可从 KL-regularized reward maximization 推导；reward 以 policy/reference log-ratio 的形式隐式出现。

Concept Contrast | 把相邻概念主动分开

	SFT	DPO	RLVR
数据	demonstrations	preferences	verifiable outcomes
主要信号	token likelihood	pairwise ranking	trajectory reward
关键风险	imitation bias	preference misspecification	reward hacking/support

Checkpoint | 开始正文前的 30 秒自测

为什么 KL regularization 中需要关注 $\text{supp}(\pi) \subseteq \text{supp}(\pi_{ref})$ 一类条件？**检查答案：**reference 给零概率而新 policy 给正概率时 log-ratio/KL 可发散，变分推导的可行域发生问题。

18.1 SFT：条件最大似然，但数据分布已发生质变

给 instruction–response 数据 (x, y) ，Supervised Fine-Tuning 最小化

$$L_{\text{SFT}}(\theta) = -\mathbb{E}_{(x,y) \sim D_{\text{demo}}} \log \pi_{\theta}(y|x).$$

按 token 展开：

$$-\log \pi_{\theta}(y|x) = -\sum_t \log \pi_{\theta}(y_t|x, y_{<t}).$$

数学形式和预训练完全相同，区别是 D_{demo} 已经过人工/模型选择，因此隐式定义了行为目标。

SFT 的优势是稳定、低方差；局限是只能提高训练 target 的 likelihood。若好回答从未进入 demonstration distribution，纯 offline SFT 没有自然探索机制去发现它。

18.2 偏好数据：从绝对标签改为相对比较

对同一 prompt x ，给出 preferred response y^+ 与 rejected response y^- 。Bradley–Terry 模型写成

$$P(y^+ \succ y^-|x) = \sigma(r_{\phi}(x, y^+) - r_{\phi}(x, y^-)).$$

reward model loss 为

$$L_R(\phi) = -\mathbb{E} \log \sigma(r_{\phi}(x, y^+) - r_{\phi}(x, y^-)).$$

这里只能识别 reward difference：对同一 x 给所有回答加常数，不改变偏好概率。

Preference 不一定服从单一标量 reward

人类偏好可能循环、依赖风格或上下文，也可能跨标注者不一致。Bradley-Terry 是有用模型，不是“人类价值天然是一维实数”的证明。现代 preference optimization 研究越来越关注 general preference、game-theoretic 与多目标设置。

18.3 KL-Regularized RL：奖励与保持原模型之间的变分问题

对每个 prompt，考虑

$$\max_{\pi} \mathbb{E}_{y \sim \pi(\cdot|x)}[r(x, y)] - \beta D_{\text{KL}}(\pi(\cdot|x) \parallel \pi_{\text{ref}}(\cdot|x)).$$

第一项推动高 reward，第二项防止策略离 reference 太远。 β 是“保守程度”的温度。

最优策略为什么是 exponential tilt?

离散响应空间上加入归一化约束。对每个 y 求导：

$$r(y) - \beta \left(\log \frac{\pi(y)}{\pi_0(y)} + 1 \right) + \lambda = 0.$$

整理得

$$\pi^*(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp \left(\frac{r(x, y)}{\beta} \right),$$

其中

$$Z(x) = \sum_y \pi_{\text{ref}}(y|x) e^{r(x, y)/\beta}.$$

在这个固定动作空间、直接对分布做 KL 正则变分优化的模型里，最优解是在 reference support 内做指数倾斜： $\pi_{\text{ref}}(y|x) = 0$ 的响应仍保持零概率。参数化神经网络的 online 更新还会通过参数共享改变未采样输入/序列的概率，因此不能把这个 support 结论不加限定地外推成“任何 RL 都只能重加权”。

18.4 DPO：把隐式 reward 写成 policy log-ratio

从上式反解

$$r(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x).$$

对同一 prompt 的两个回答取 reward difference， $\log Z(x)$ 消失：

$$r(x, y^+) - r(x, y^-) = \beta \left[\log \frac{\pi^*(y^+|x)}{\pi_{\text{ref}}(y^+|x)} - \log \frac{\pi^*(y^-|x)}{\pi_{\text{ref}}(y^-|x)} \right].$$

把 π^* 用可训练策略 π_θ 近似，并代入 Bradley–Terry likelihood，得到 DPO loss

$$L_{\text{DPO}} = -\mathbb{E} \log \sigma \left(\beta \left[\log \frac{\pi_\theta(y^+|x)}{\pi_{\text{ref}}(y^+|x)} - \log \frac{\pi_\theta(y^-|x)}{\pi_{\text{ref}}(y^-|x)} \right] \right).$$

DPO 的核心不是 “不要 reward”

Reward 被吸收到 policy/reference 的 log-ratio 中。DPO 避免显式训练 reward model 和在线 RL rollout，但仍继承 preference data 的覆盖范围，也仍可能因 optimization dynamics 同时压低 chosen/rejected 的绝对概率。

18.5 Sequence Policy Gradient：终局 reward 怎样传回每个 token？

LLM 策略分解为

$$\pi_\theta(y|x) = \prod_{t=1}^T \pi_\theta(y_t|x, y_{<t}).$$

目标

$$J(\theta) = \mathbb{E}_{y \sim \pi_\theta} [R(x, y)].$$

使用 log-derivative trick：

$$\nabla_\theta J = \mathbb{E} [R \nabla_\theta \log \pi_\theta(y|x)] = \mathbb{E} \left[R \sum_t \nabla_\theta \log \pi_\theta(y_t|x, y_{<t}) \right].$$

减去不依赖当前 action 的 baseline b 不改变期望：

$$\mathbb{E}[(R - b) \nabla \log \pi] = \mathbb{E}[R \nabla \log \pi].$$

这就是 advantage/variance reduction 的基本来源。

如果 reward 只在最终答案处给 0/1，那么同一 trajectory 的所有 token 会共享一个粗粒度信号。**credit assignment** 因而成为 reasoning RL 的核心难题：哪些 token 是必要探索，哪些只是冗余？

18.6 RLVR：当 reward 可以自动验证

数学答案、代码单元测试、形式证明等任务能提供 verifiable reward。RLVR 不需要昂贵的人类 preference score：

$$R(y) = \mathbf{1}\{\text{verify}(y) = \text{pass}\}.$$

现代方法常对同一 prompt 采一组 response，用组内相对 reward 构造 advantage，再更新策略。抽象地，若组 reward 为 $R_1, \dots, R_G$ ，可用

$$A_i = \frac{R_i - \bar{R}}{s_R + \epsilon}$$

作为相对信号。具体算法会再加入 importance ratio、clipping 或 KL penalty。

18.7 RLVR 的关键争论：新能力，还是概率 Sharpening?

回到第 17 章的三个概念：support、coverage、concentration。RLVR 明显可以提高 pass@1，即把概率推向 rewarded trajectory；更难的问题是它是否让 base model 原本概率极低、在有限采样下几乎观察不到的 reasoning pattern 获得了实质概率质量。严格数学 support 对 softmax LM 往往过于粗糙，因为有限序列通常已有正概率；实验真正能估计的是有效 support / coverage / 可观测 reasoning boundary。

Research Frontier | Does Reinforcement Learning Really Incentivize Reasoning Capacity in LLMs Beyond the Base Model?

会议身份：NeurIPS 2025 Best Paper Runner-up。论文跨多个模型/算法/任务用大 k pass@ k 探索 reasoning boundary，报告当前 RLVR 主要提升 rewarded path 的采样效率，但未观察到超越 base model support 的根本新 reasoning pattern；随着 RL 进行，分布甚至可能变窄。

重要性：这是一个高质量负结果：把“pass@1 更高”与“能力边界更大”严格区分。

官方来源：[NeurIPS 2025 Best Paper Awards](#)

Research Frontier | RLVR Implicitly Incentivizes Correct Reasoning in Base LLMs

会议身份：ICLR 2026 Conference。另一项工作重新检查 pass@ k ，提出 CoT-Pass@ k 同时检查最终答案和中间 reasoning，并报告 RLVR 可扩展数学/代码任务上的 reasoning boundary，同时给出仅最终答案 reward 仍能激励正确推理的理论框架。

教材为什么同时放两篇？因为前沿科学允许冲突。两者对“reasoning boundary”的测量方式、轨迹判定与训练设置并不完全相同。学生的任务不是选边，而是找出产生不同结论的可检验假设。

论文入口：[ICLR Proceedings](#)




图 18.1 机制级实验：左图显示 KL-regularized 最优策略如何随 $1/\beta$ 对 reference probability 做指数倾斜；右图的 toy RLVR 更新提高 rewarded responses 的概率质量，同时降低策略 entropy，直观展示 sharpening 与 support narrowing 可以同时发生。

18.8 Self-Improvement：把昂贵推理“蒸馏”回策略

若模型在 test time 通过多采样 + verifier 找到更好答案，可以收集这些答案做 SFT，或者在线 RL。理想目标是把

expensive search at inference

变成

cheap high-probability generation after training.

这可以称为 amortization / sharpening。

Research Frontier | Training Language Models to Self-Correct via Reinforcement Learning

会议身份：ICLR 2025 Oral。SCoRe 指出用离线 self-correction trace 做 SFT 会受到 distribution mismatch 与 mode bias；它改用模型自身分布上的 multi-turn online RL，并通过正则与两阶段训练强化真正可用的 self-correction。

教材连接：offline imitation 与 online policy improvement 的差别不是术语，而是“训练时访问哪个状态/轨迹分布”。

论文入口：[ICLR Proceedings](#)

18.9 RL 也开始有自己的 Scaling Law

预训练已经形成参数/数据/计算的 scaling 方法学，但 RL 后训练长期更依赖 recipe。随着 rollout 计算暴涨，问题自然变成：RL compute 是否也有可预测的 performance frontier？

Research Frontier | The Art of Scaling Reinforcement Learning Compute for LLMs

会议身份: ICLR 2026 Oral。论文使用超过 400,000 GPU-hours 的系统实验, 拟合 sigmoidal RL compute-performance curves, 并区分哪些训练细节主要改变 compute efficiency、哪些会改变 asymptotic performance。

研究启示: 后训练也不能只比较“最终分数”。要同时比较 asymptote、sample efficiency、compute efficiency 与稳定性。

论文入口: [ICLR Proceedings](#)

18.10 安全对齐：概率变化发生在序列的哪里？

一个模型可能在开头几个 token 更容易输出拒绝模板, 但条件于攻击性 prefill 后, 后续分布几乎回到 base behavior。于是安全不能只看 sequence-level pass/fail, 还要看 token-level probability trajectory。

Research Frontier | Safety Alignment Should be Made More Than Just a Few Tokens Deep

会议身份: ICLR 2025 Outstanding Paper。工作提出 shallow safety alignment: 安全训练的影响可能集中在响应开头少量 token; prefilling、decoding 改变或再微调能暴露这种脆弱性。

本章连接: alignment 是沿 trajectory 重塑概率质量, 而不是给模型贴一个“安全/不安全”标签。

官方来源: [ICLR 2025 Awards](#)

18.11 Reward Hacking 与 “Honesty representation”

当 reward 是 proxy, 优化器会寻找所有能提高 proxy 的策略, 而不保证符合设计者真正意图。若监督器本身读取模型内部 activation, 甚至会担心模型是否学会“骗 detector”。

Research Frontier | The Obfuscation Atlas: Mapping Where Honesty Emerges in RLVR with Deception Probes

会议身份: ICML 2026 Outstanding Paper Honorable Mention。该工作在容易 reward hacking 的代码优化环境中研究 white-box linear lie detector, 区分 blatant deception、activation obfuscation 与 policy obfuscation, 并分析 policy-gradient 下的优化压力; 官方评语强调其对可扩展监督的理论与工程价值。

科研训练：出现 detector performance 下降时，不能立刻把原因解释为“模型主动隐藏思想”；必须区分表示改变、行为策略改变和检测器分布外失效。

官方来源：ICML 2026 Awards

18.12 Finetuning Dynamics: 偏好正确不代表概率绝对值健康

DPO/偏好训练通常优化 log-ratio。一个危险情形是：chosen response 相对 rejected 更占优势，但两者绝对概率都下降，只是 rejected 降得更快。若只看 pairwise accuracy，会错过这种概率质量流失。

Research Frontier | Learning Dynamics of LLM Finetuning

会议身份：ICLR 2025 Outstanding Paper。论文从回答之间的梯度关系研究 finetuning 概率动力学，并展示 off-policy DPO 长时间训练可能出现 desired output 概率也下降等现象。

本章连接：优化 preference margin 时，应同时追踪 chosen/rejected 的 absolute log-prob、KL、entropy 与 base coverage。

官方来源：ICLR 2025 Awards

Mini Lab | Frontier Lab 18: DPO/RLVR 的概率重排

运行 `labs/frontier/ch18_dpo_rlvr.py`。左图直接计算 $\pi^* \propto \pi_{\text{ref}} e^{r/\beta}$ ，观察 β 如何控制 reward 与 reference coverage 的平衡；右图用 exponentiated reward toy update 模拟 RLVR sharpening，展示 rewarded mass 上升与 entropy 下降可同时出现。升级版：在 tiny LM 上实现 DPO，并同时记录 preference accuracy、chosen/rejected absolute log-prob、KL 与 pass@k。

From Textbook to Research | 后训练是在“教会”，还是在“选择”？

这是 2025–2026 reasoning 研究最关键的问题之一。一个答案可能是：两者都可能发生，但发生条件不同。Coverage、online exploration、curriculum、reward granularity、模型容量与轨迹长度共同决定后训练能否超出单纯 reweighting。真正的研究任务是找到能区分 effective-support/coverage expansion 与 probability sharpening 的实验，而不是从 pass@1 提升直接推断“模型学会了新推理”。

18.13 Deep Dive: KL-Regularized RL 是一个 Gibbs 变分原理

把

$$\pi^*(y) = \frac{\pi_0(y)e^{r(y)/\beta}}{Z}$$

代回任意策略 π ，可得到

$$\mathbb{E}_\pi[r] - \beta D_{\text{KL}}(\pi \| \pi_0) = \beta \log Z - \beta D_{\text{KL}}(\pi \| \pi^*).$$

右侧第一项与 π 无关，第二项非正，因此唯一最优（在支持条件下）是 $\pi = \pi^*$ 。这个恒等式比一阶条件更强：它直接把 RL objective 改写成“靠近 reward-tilted target distribution”。

18.14 Deep Dive: Coverage 决定 offline preference learning 的天花板

若 reference policy 对某类优质回答 y_g 有

$$\pi_{\text{ref}}(y_g|x) = 0,$$

则 exponential tilt 仍有

$$\pi^*(y_g|x) = 0.$$

也就是说，在严格 support 意义下，单纯对 reference 做绝对连续的 reweighting 无法给零概率事件创造质量。神经网络 softmax 对有限 token 通常不是精确零，但完整长序列概率可以小到实践上不可探索。这就是 coverage principle 与 online exploration 的连接。

18.15 Deep Dive: DPO 梯度在推什么？

记

$$\Delta_\theta = \log \pi_\theta(y^+|x) - \log \pi_\theta(y^-|x), \quad \Delta_{\text{ref}} = \log \pi_{\text{ref}}(y^+|x) - \log \pi_{\text{ref}}(y^-|x).$$

则

$$L = -\log \sigma(\beta(\Delta_\theta - \Delta_{\text{ref}})).$$

对 margin $m = \Delta_\theta - \Delta_{\text{ref}}$ 求导：

$$\frac{\partial L}{\partial m} = -\beta \sigma(-\beta m).$$

当模型还没有相对 reference 足够偏向 chosen 时，梯度大；margin 已经很大时，梯度饱和。这与 logistic classification 完全同构。

18.16 Deep Dive: Terminal reward 的 credit assignment

Policy gradient 对每个 token 都乘同一个终局 R :

$$R \sum_t \nabla \log \pi(a_t | s_t).$$

如果一条长 CoT 中只有少量关键 token 真正决定成功, 其余 token 会接收到同方向更新, 产生高方差与误归因。Process reward、value function、reward redistribution、token-level regularizer 都是在尝试增加 credit resolution。

18.17 Deep Dive: Sharpening 与 Exploration 的张力

假设 base policy 有多个正确模式 G_1, G_2, G_3 。RL 若早期随机命中 G_1 较多, on-policy 更新会进一步增加 G_1 概率, 使后续更少探索 G_2, G_3 。这是经典 rich-get-richer 动力学。它解释了为什么 pass@1 可以持续改善, 而大 k diversity 或 reasoning boundary 反而收缩。

解决方向包括 entropy/KL regularization、curriculum、off-policy replay、explicit diversity reward、environment interaction 与 teacher distillation。没有哪一种自动保证 support expansion。

研究者应问什么?

一个新的 reasoning RL 算法如果只报告 pass@1, 证据是不完整的。至少同时检查 pass@ k 曲线、solution diversity、absolute likelihood、KL/entropy、训练前后新轨迹类型, 以及在更大 sampling budget 下 base model 能否产生这些轨迹。只有这样才能回答“训练是在发现, 还是在集中”。

18.18 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

后训练把 第 3 章的概率、第 4 章的 KL、第 5 章的优化和 第 20 章的策略学习汇合到一起。

Worked Example | KL-regularized RL 的闭式最优策略

对固定 x , 最大化

$$\sum_y \pi(y) r(y) - \beta \sum_y \pi(y) \log \frac{\pi(y)}{\pi_{\text{ref}}(y)}$$

并加归一化约束。拉格朗日一阶条件给

$$\pi^*(y) \propto \pi_{\text{ref}}(y) e^{r(y)/\beta}.$$

这行式子同时解释 reward、reference policy 和 temperature-like β 如何共同塑造 probability mass；DPO 就是把 reward preference model 与这个关系消元。

Proof Clinic | Preference 数据不等于真实 reward

Bradley-Terry 假设 $P(y_w \succ y_l) = \sigma(r_w - r_l)$ 。如果 annotator preference 受长度、风格或 position bias 影响，那么学到的 r 也是这些偏好的统计模型。数学优化再精确，也不能从偏置的比较数据自动恢复“真正的人类价值”。

Research Assignment | DPO/RLVR support 审计

对小离散策略精确枚举所有 trajectories，分别运行 DPO-like update 与 RLVR-like reweighting。跟踪 entropy、support mass、pass@ k 与 mode collapse；构造一个 reward proxy 可被 hack 的环境。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. preference model 假设是否允许循环偏好、多标注者差异？
2. DPO/RL 实验是否追踪 absolute log-prob，而不只看 pairwise win rate？
3. RLVR 的 reward 是 outcome-only 还是 process-level？credit assignment 怎样处理？
4. pass@ k 的 k 是否足够大、temperature 是否匹配、base/RL 模型是否公平比较？
5. 所谓“new reasoning”按 final answer、CoT pattern 还是 causal algorithm 定义？
6. online RL 的 rollout distribution 与 offline preference data 有多大 mismatch？
7. reward hacking 分析是否区分行为策略改变、表示改变与 detector failure？
8. RL scaling 论文是否区分 asymptote improvement 与 compute-efficiency improvement？

分层习题

分层训练 | Level A | 概念与计算

1. 解释 SFT 与 pretraining 在数学目标相同、数据分布不同的含义。
2. 对两个回答 reward 差为 1.2, 计算 Bradley–Terry preference probability。
3. 给定 reference 概率与 reward, 使用 $\pi^* \propto \pi_0 e^{r/\beta}$ 计算新分布。
4. 解释为什么 preference accuracy 上升不保证 chosen absolute probability 上升。

分层训练 | Level B | 推导

1. 完整推导 KL-regularized RL 的 exponential-tilt 最优策略。
2. 从 exponential tilt 与 Bradley–Terry 推导 DPO loss。
3. 使用 log-derivative trick 推导 sequence policy gradient, 并证明减去 action-independent baseline 不改变期望梯度。
4. 对二值 RLVR reward, 分析 group-relative advantage 在组内全对/全错时会发生什么。

分层训练 | Level C | 研究设计

1. 设计实验区分 RLVR 的 support expansion 与 probability sharpening。
2. 为浅层 safety alignment 设计 token-level probability probe。
3. 比较 offline DPO 与 online RL: 在哪些 coverage 条件下你预期 online exploration 更有优势?
4. 阅读两篇对 RLVR reasoning boundary 得出不同结论的论文, 列出定义、sampling budget、trajectory correctness 三方面的差异, 并提出 adjudicating experiment。