

第 19 章 RAG、Agentic Search 与外部证据——从“查到资料”到主动获取信息

本章问题

参数模型把世界压进权重，长上下文把证据放进窗口，RAG 则允许系统在推理时主动向外部世界取证。真正困难的问题不是“检索 top- k 文档”，而是：**什么信息值得获取、什么时候停止获取、怎样把检索结果转化为后续决策优势？**本章把静态 RAG 推向 agentic retrieval，并为下一章的 POMDP 与信息动作建立数学桥梁。

- Prerequisite Recall | 先把这些知识唤醒**
- 熟悉 embedding 相似度、Bayes/latent variable 与 test-time compute。
 - 能区分“检索相关文档”与“文档真的改变最终决策”。
 - 会计算 entropy / expected utility。

Misconception Check | 本章最容易掉进去的坑

RAG 的 retrieval recall 高，不等于最终回答一定更好。无关或冲突证据会污染生成；真正任务价值取决于检索结果是否改变 posterior/decision，而不仅是“黄金文档是否进入 top- k ”。

Concept Contrast 把相邻概念主动分开		
	Relevance score	Value of Information
问题	文档像不像 query?	看到它后决策改善多少?
依赖生成/任务?	可不依赖	必须依赖
Agent 化	排序	选择下一次信息动作

Checkpoint | 开始正文前的 30 秒自测

为什么 EIG 大的信息不一定有大的 task utility? **检查答案：**它可能大量减少与当前决策无关的不确定性；信息价值必须相对于 utility 定义。

19.1 检索不是字符串搜索，而是一个排序学习问题

给定查询 x 与文档 z ，双塔检索器产生

$$q = f_\phi(x), \quad d = g_\psi(z), \quad s(x, z) = q^\top d.$$

最常见的对比目标可以写成

$$L_{\text{ret}} = -\log \frac{\exp(s(q, d^+)/\tau)}{\exp(s(q, d^+)/\tau) + \sum_{j=1}^m \exp(s(q, d_j^-)/\tau)}.$$

它与第 7 章的 softmax 分类完全同构：检索训练就是把“正确文档”当作一个巨大类别空间中的正确类别。

命题 19.1 (对比损失的相似度梯度). 记正样本 softmax 概率为 p_+ ，负样本概率为 p_j ，则

$$\frac{\partial L}{\partial s_+} = \frac{p_+ - 1}{\tau}, \quad \frac{\partial L}{\partial s_j} = \frac{p_j}{\tau}.$$

因此 *hard negative* 的梯度大，而几乎不可能被误判的 *easy negative* 梯度趋近于零。

证明. 直接对 log-softmax 求导即可。这说明“负样本如何采”不是实现细节，而是在定义检索器究竟学什么判别边界。□

19.2 RAG 是带潜变量的条件生成

令 z 表示外部证据，最自然的概率分解为

$$p(y | x) = \sum_z p_\eta(z | x) p_\theta(y | x, z).$$

真实文档库巨大，系统通常只保留集合 $\mathcal{T}_k(x)$ ：

$$p(y | x) \approx \sum_{z \in \mathcal{T}_k(x)} \tilde{p}_\eta(z | x) p_\theta(y | x, z).$$

这立刻给出三个不同的失败源：**retrieval failure**（证据没进入集合）、**ranking/calibration failure**（证据权重不合理）、**utilization failure**（证据已给到模型但没有被正确使用）。

端到端成功率为什么不能只看 Recall@k?

把“目标证据被检到”记作事件 R ，“答案正确”记作 C ，则

$$P(C) = P(C | R)P(R) + P(C | \neg R)P(\neg R).$$

若没有证据几乎答不对，第二项很小，于是

$$P(C) \approx \underbrace{P(R)}_{\text{retrieval recall}} \underbrace{P(C | R)}_{\text{context utilization}}.$$

增大 k 可以提高第一项，却可能因干扰、位置偏置和冲突证据降低第二项。因此“更多文档”并不保证更好的 RAG。

19.3 证据的价值应由“改变决策多少”来定义

静态检索只问“文档像不像 query”。Agentic retrieval 更重要的问题是：**获得这条信息后，最优动作会不会改变？**

设当前信息历史为 h ，最终决策 a 的效用为 $U(a, \omega)$ ， ω 是未知世界状态。没有额外信息时的 Bayes 最优价值为

$$V(h) = \max_a \mathbb{E}[U(a, \omega) | h].$$

若可以执行查询 q 并观察结果 o ，则信息价值为

$$\text{VOI}(q | h) = \mathbb{E}_{o \sim p(o|h, q)}[V(h, q, o)] - V(h) - c(q).$$

这就是 **Value of Information (信息价值)**。它比 embedding similarity 更接近 Agent 的目标：一个与 query 很相似的文档可能完全不改变决策；一个表面不相似的“桥接事实”却可能让后续搜索空间骤然缩小。

定理 19.1 (完美信息的期望价值非负). 若信息获取没有成本，且观察后允许忽略信息，则完美信息的期望价值满足

$$\text{EVPI} \geq 0.$$

证明. 观察世界状态 ω 后可以选择逐状态最优动作，因此

$$\mathbb{E}_\omega \max_a U(a, \omega) \geq \max_a \mathbb{E}_\omega U(a, \omega),$$

因为左侧允许动作依赖于 ω ，右侧要求在看到 ω 前固定同一个动作。两者之差即完美信息价值。□

19.4 从 entropy reduction 到 expected utility

如果目标只是识别隐藏变量 Z ，可以用期望信息增益

$$\text{EIG}(q) = H(Z | h) - \mathbb{E}_o H(Z | h, q, o) = I(Z; O | h, q).$$

但信息量大不等于任务价值大。若某个变量高度不确定却与最终决策无关，降低它的 entropy 没有意义。因此研究级 Agent 必须区分：

$$\text{uncertainty reduction} \neq \text{decision improvement.}$$

这也是 Bayesian experimental design、active learning 与 agentic search 的共同数学核心。

19.5 Multi-hop Retrieval: 查询本身成为策略

固定 RAG 的检索分布是 $p(z | x)$ ；多跳搜索中，第 t 次 query 可以依赖前面的证据：

$$q_t \sim \pi_\theta(q_t | x, z_{1:t-1}), \quad z_t \sim p_{\text{search}}(z_t | q_t).$$

整个检索轨迹

$$\tau = (q_1, z_1, q_2, z_2, \dots, q_T, z_T)$$

已经是序贯决策对象。系统必须决定：继续检索、换一种 query、验证冲突证据，还是停止并回答。

为什么“先搜桥接实体，再搜答案”比一次 top- k 更像 Agent？

假设问题问“A 的导师的出生城市”。初始 query 里没有导师姓名。一次检索必须直接跨过两个关系；多跳系统可以先得到“A 的导师是 B”，再把 B 写进第二个 query。第一次检索的主要价值不是直接回答，而是**改变第二次动作的条件分布**。

19.6 停止规则：检索也是 Test-Time Compute Allocation

每次搜索有成本 c_t 。理想停止条件不是“已经搜了 k 篇”，而是边际价值小于边际成本：

$$\mathbb{E}[V(h_{t+1}) - V(h_t) | h_t] \leq c_t.$$

这与第 16 章的 test-time compute allocation 完全统一。采样更多 reasoning traces、调用 verifier、搜索网页、读取文件，本质上都在问：下一单位计算能带来多少预期决策收益？

Research Frontier | Inference Scaling for Long-Context Retrieval Augmented Generation

会议身份：ICLR 2025 Oral。工作研究 RAG 的 inference compute 如何在检索文档数、in-context learning、迭代 prompting 等策略间分配，并用 computation allocation model 预测预算下的配置。它把 RAG 从固定 pipeline 改写成资源分配问题。

教材连接：本章的 $VOI - c$ 视角解释了为什么最优策略不会简单地“把 k 开大”。

官方来源：[ICLR Proceedings](#)

Research Frontier | LoongRL: Plan-Retrieve-Reason-Recheck 可以被 RL 学出来吗？

会议身份：ICLR 2026 Oral。LoongRL 用 KeyChain 合成长上下文高难任务，论文报告 RL 训练诱导出 plan-retrieve-reason-recheck 模式，并从 16K 训练长度外推到更长任务。

研究意义：“检索”和“推理”不一定是两个人工拼装模块；它们可以成为同一序贯策略中的不同动作类型。真正的问题转向：什么训练分布能让策略学会**何时检索、检索什么、何时重新检查**？

官方来源：[ICLR 2026 Oral Program](#)

Research Frontier | MC-Search: Agentic RAG 需要过程级评测

会议身份：ICLR 2026 Oral。MC-Search 把多模态 RAG 扩展为长链 agentic search，除最终答案外，还评价逐步 retrieval 与 planning 的正确性，并报告过度检索、检索不足与 modality-misaligned planning 等系统错误。

研究启示：端到端 accuracy 太粗。一个 Agent 可以“最后蒙对”，也可能“检索完全正确但生成器用错”。如果不测 trajectory，很难知道算法究竟改善了哪里。

官方来源：[ICLR 2026 Oral Program](#)




图 19.1 Frontier Lab 19：一次性 top- k 与“先找桥接信息、再局部检索”的自适应策略。图展示机制而非真实 RAG benchmark。

Mini Lab | Frontier Lab 19: Adaptive Retrieval / Value of Information

运行 `labs/frontier/ch19_agentic_retrieval.py`。实验构造带隐藏 cluster 的文档库：一次检索只能依赖弱全局相关性，而 agentic 策略先花一次预算获得 bridge signal，再在局部搜索。请修改 bridge 噪声、预算与 distractor 数量，观察何时“多一步规划”值得它的额外成本。

From Textbook to Research | 从 RAG 到 POMDP，只差一个概念升级

当检索动作改变我们对世界的 belief，并影响下一步行动时，RAG 已经不再只是“给 LLM 拼上下文”。下一章将正式把隐藏世界、观测、belief、动作与长期回报写进同一个数学对象：POMDP。

19.7 Deep Dive: Retrieval 的真正对象是后验，而不是相似度

假设候选证据集合为 $z \in \{1, \dots, M\}$ 。一个校准良好的 retriever 可以被理解为近似

$$p(z \text{ relevant} \mid x).$$

embedding score 本身没有概率意义；只有经过训练和校准后，排序分数才可能支持风险敏感的停止规则。若两个 query 的 score scale 不同，固定阈值会产生系统偏差。

19.7.1 从 Bayes rule 看 query rewriting

第一次观测 o_1 后，对隐藏答案 Y 的后验为

$$p(y \mid x, o_1) \propto p(o_1 \mid x, y)p(y \mid x).$$

新的 query $q_2 = q(x, o_1)$ 的作用，是让搜索分布更贴近这个更新后的后验，而不是机械扩展原 query。于是 query rewriting 可以理解为一种 **belief-dependent action**。

19.8 Deep Dive: Expected Information Gain 的推导

查询 q 的信息增益定义为 posterior 与 prior 的 KL：

$$\mathbb{E}_o D_{\text{KL}}(p(Z \mid h, q, o) \parallel p(Z \mid h)).$$

展开可得

$$\begin{aligned} & \sum_o p(o \mid h, q) \sum_z p(z \mid h, q, o) \log \frac{p(z \mid h, q, o)}{p(z \mid h)} \\ &= H(Z \mid h) - H(Z \mid O, h, q) = I(Z; O \mid h, q). \end{aligned}$$

因此 active search 与信息论在这里重新会合。

19.8.1 EIG 并不自动等于 VOI

若最终动作只依赖 $g(Z)$ 而不是完整 Z , 那么区分 Z 中与 g 无关的细节会产生 EIG, 却不产生决策收益。更精确的设计应围绕 downstream utility 或 task-relevant sufficient statistic。

19.9 Deep Dive: 把 RAG 看成一个受预算约束的最优控制问题

定义状态为当前证据集合与模型 belief: $s_t = (x, z_{1:t}, b_t)$; 动作包括 query、retrieve、verify、answer; 每个工具动作都有成本 $c(a_t)$ 。一个自然目标是

$$\max_{\pi} \mathbb{E}_{\pi} \left[R_{\text{answer}} - \lambda \sum_t c(a_t) \right].$$

于是固定 k 、固定轮数的 RAG 只是这个控制问题的一类手工策略。Agentic RAG 的研究空间来自: 学习状态表示、学习 query policy、学习停止规则、学习 verifier, 以及在不同预算下优化 Pareto frontier。

19.9.1 研究实验升级路线

课堂 toy lab 只展示“桥接信息”的价值。论文规模复现应至少报告: 不同 retrieval budgets、不同 retriever calibration、不同 context windows、oracle retrieval、oracle utilization、不同 stopping policy, 以及对 query distribution shift 的鲁棒性。否则无法知道收益来自更强检索器还是更强生成器。

19.10 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

主动检索把静态 context 变成 action, 为第 20 章 POMDP 的 information action 提供自然入口。

Worked Example | Retrieval 的价值应减去成本

若当前最优动作价值为 $V(b)$, 检索动作 q 产生 observation o 并更新 belief, 则信息动作净价值可写

$$\text{VOI}(q) = \mathbb{E}_o[V(b^{q,o})] - V(b) - c(q).$$

定理 19.1 保证完美免费信息不降低期望价值; 真实 RAG 却有延迟、token 成本和错误证据, 因此最优策略可以选择不检索。

Proof Clinic | RAG 错误分解

把失败拆成至少三类：gold evidence 不在候选库（coverage error）；在库中却未被 retriever 找到（retrieval error）；已经给到 generator 却未正确利用（utilization error）。只有第三类主要属于语言模型推理。若不分解，换 retriever 或换 generator 的实验结论会互相污染。

Research Assignment | Agentic retrieval stopping

在具有查询成本的 toy QA 环境实现 stop/retrieve policy。比较固定 retrieve-k、entropy threshold 和近似 VOI 策略；报告准确率-成本 Pareto frontier，而不是单一 accuracy。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. 论文优化的是 retrieval recall、answer accuracy，还是 cost-adjusted utility？
2. 增加检索预算时，利用率是否下降？是否报告 oracle-context 上界？
3. multi-hop 方法的提升来自 query policy，还是仅来自更多 token / 更多调用次数？
4. stopping rule 是否依赖一个经过校准的不确定性信号？
5. “相关文档”标签与真正改变最终决策的 evidence 是否等价？
6. 是否评价了 trajectory fidelity，而不仅是 final answer？

分层习题

- A1** 推导 InfoNCE 对正样本与负样本相似度的梯度，并解释 temperature 的作用。
- A2** 写出 top- k RAG 对潜变量求和的近似，指出归一化常数如何改变。
- A3** 给定 $\text{recall}@5 = 0.8$ 、 $P(C | R) = 0.75$ 、 $P(C | \neg R) = 0.1$ ，计算端到端准确率。
- B1** 证明完美信息价值非负；给出有查询成本时信息价值为负的例子。
- B2** 构造一个“mutual information 很大但 decision value 很小”的二元决策例子。
- B3** 将 iterative RAG 写成长度 T 的轨迹概率 $p(\tau | x)$ 。
- C1** 设计一个 benchmark，分别测 retrieval、utilization、attribution 与 stopping quality。
- C2** 将 Frontier Lab 改成 learned stopping policy，并画 success-cost Pareto frontier。