


第 20 章 MDP/POMDP——Agent 的序贯决策数学

本章问题

LLM 在一次 prompt 上输出答案时，我们研究 $p(y | x)$ ；Agent 则必须让今天的动作影响明天看到什么。数学对象因此从静态条件分布升级为**轨迹分布**。本章建立 MDP、Bellman 方程、occupancy measure 与 POMDP belief update，并解释为什么“记住历史”不是 Agent memory 的严格定义。

- Prerequisite Recall | 先把这些知识唤醒**
- 熟悉条件概率、Bayes 更新与期望回报。
 - 理解“状态”是为预测未来服务的统计摘要。
 - 已见过 sequential decision / policy 的基本符号。



Misconception Check | 本章最容易掉进去的坑

把聊天历史全文塞进 prompt，不等于构造了 Markov state。历史很长仍可能缺关键环境变量、包含噪声，或让模型无法可靠提取 sufficient statistic。

Concept Contrast | 把相邻概念主动分开

	MDP state s_t	POMDP belief $b_t(s)$
对世界状态更新	假设可观测/充分	用分布表达不确定性
信息动作	通常隐含	Bayes filter
		可显式有价值

Checkpoint | 开始正文前的 30 秒自测

belief 为什么可以成为 POMDP 的“新状态”？**检查答案：**在给定 belief 与当前动作后，未来观测与 belief 更新的分布不再需要完整历史；belief 是历史的充分统计量（在模型已知等假设下）。

20.1 从 supervised pair 到 trajectory

MDP 由

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma, \rho_0)$$

构成。轨迹

$$\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots)$$

在策略 π 下的概率为

$$p_\pi(\tau) = \rho_0(s_0) \prod_{t \geq 0} \pi(a_t | s_t) P(s_{t+1} | s_t, a_t).$$

目标是

$$J(\pi) = \mathbb{E}_{\tau \sim p_\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right].$$

注意：这里模型不只预测“正确答案”，而是在改变未来数据分布。策略越强，它访问到的状态越可能偏离训练数据。

20.2 Markov 性：状态必须对未来足够

Markov property 要求

$$P(s_{t+1} | s_{0:t}, a_{0:t}) = P(s_{t+1} | s_t, a_t).$$

它不是说“世界没有历史”，而是说我们选择的 s_t 已经包含了预测未来所需的历史信息。若 prompt summary 丢掉了用户早期限制，那么这个 summary 就不是任务的 Markov state。

定义 20.1 (价值函数与动作价值函数).

$$V^\pi(s) = \mathbb{E}_\pi[G_t | s_t = s], \quad Q^\pi(s, a) = \mathbb{E}_\pi[G_t | s_t = s, a_t = a],$$

其中 $G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$ 。

20.3 Bellman 方程把长时域问题递归化

由回报分解

$$G_t = r_t + \gamma G_{t+1}$$

得到

$$V^\pi(s) = \mathbb{E}_{a \sim \pi, s' \sim P}[r(s, a) + \gamma V^\pi(s')].$$

最优价值满足

$$V^*(s) = \max_a \mathbb{E}_{s'}[r(s, a) + \gamma V^*(s')].$$

定理 20.1 (Bellman 最优算子的压缩性). 定义

$$(TV)(s) = \max_a \mathbb{E}_{s'}[r(s, a) + \gamma V(s')].$$

当 $0 \leq \gamma < 1$ 时, T 在 $\|\cdot\|_\infty$ 下是 γ -contraction:

$$\|TV - TW\|_\infty \leq \gamma \|V - W\|_\infty.$$

证明. 对任意 s , 利用 $|\max_a x_a - \max_a y_a| \leq \max_a |x_a - y_a|$, 有

$$|(TV)(s) - (TW)(s)| \leq \gamma \max_a \mathbb{E}_{s'} |V(s') - W(s')| \leq \gamma \|V - W\|_\infty.$$

对 s 取上确界即可。若奖励有界, 则 Bellman 算子把有界价值函数映回有界价值函数; 在这个完备空间上, Banach 不动点定理保证唯一有界不动点 V^* , 且 value iteration 从任意有界初值按几何速率收敛。□

20.4 Occupancy measure: Agent 实际“活在哪些状态里”?

折扣状态访问分布定义为

$$d_\pi(s) = (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t P_\pi(s_t = s).$$

于是长期目标可以写成

$$J(\pi) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_\pi, a \sim \pi}[r(s, a)].$$

这条式子揭示 Agent training 的核心困难: 策略更新不仅改变动作概率, 也改变训练分布 d_π 本身。因而单轮 SFT 的 iid 直觉在长时域环境中会失效。

20.5 部分可观测性：真实 Agent 看不到 world state

POMDP 在 MDP 上加入 observation o_t 与观测模型 $O(o_t | s_t, a_{t-1})$ 。Agent 实际拥有的是历史

$$h_t = (o_{1:t}, a_{1:t-1}).$$

理想内部状态是 belief

$$b_t(s) = P(s_t = s | h_t).$$

它是对隐藏世界状态的后验分布。

Bayes filter: belief 怎样更新?

执行动作 a_t 后先做 prediction:

$$\bar{b}_{t+1}(s') = \sum_s P(s' | s, a_t) b_t(s).$$

看到新观测 o_{t+1} 后做 correction:

$$b_{t+1}(s') = \frac{O(o_{t+1} | s', a_t) \bar{b}_{t+1}(s')}{\sum_{\tilde{s}} O(o_{t+1} | \tilde{s}, a_t) \bar{b}_{t+1}(\tilde{s})}.$$

这和第 3 章的 Bayes rule 完全相同，只是现在每个时间步都要更新一次。

命题 20.1 (belief state 是 POMDP 的充分状态). 在已知 POMDP 模型下，未来最优决策不需要完整历史 h_t ，只需要当前 belief b_t 。

证明思路 | 为什么成立?

给定 b_t 与未来动作，下一状态和下一观测的分布都可以由转移模型与观测模型计算；历史对未来的影响已经被后验 b_t 汇总。因此 POMDP 可以转化为连续 belief space 上的 MDP。

20.6 Information Action: 有些动作的价值在于“让我知道更多”

在部分可观测环境中，动作不仅改变 world state，也改变 observation distribution。问用户一个澄清问题、打开日志、运行单元测试、搜索网页，都可能没有即时任务 reward，却提升 belief quality。

最简单的分解是

$$Q(b, a) = \underbrace{r(b, a)}_{\text{即时任务收益}} + \gamma \underbrace{\mathbb{E}_o V(\tau(b, a, o))}_{\text{未来决策收益}},$$

其中 τ 是 belief update。第 19 章的 Value of Information 因而成为 POMDP 的一个特例。

Research Frontier | Shoot First, Ask Questions Later? Building Rational Agents that Explore and Act Like People

会议身份：ICLR 2026 Oral。该工作用 decision-oriented dialogue 研究语言模型如何在“询问信息”和“立即行动”之间权衡，并借鉴 Bayesian Experimental Design 构造 Monte Carlo 推断策略。论文报告其方法显著提高 expected information gain 与任务表现。

教材连接：这正对应 POMDP 中的 information action：澄清问题不是对话礼仪，而是一个有机会成本的 belief-improving action。

官方来源：[ICLR 2026 Oral Program](#)

20.7 多轮失败为什么比单轮失败更危险？

单轮错误通常只影响一个输出；闭环 Agent 的错误会改变后续状态与观测，形成 path dependence。早期误解用户意图后，后续每一步都可能在错误 belief 上继续优化。

Research Frontier | LLMs Get Lost In Multi-Turn Conversation

会议身份：ICLR 2026 Outstanding Paper。该工作大规模比较单轮与多轮、under-specified 任务，官方 proceedings 摘要报告被测模型多轮表现平均显著下降，并将问题分解为 aptitude 的较小损失与 unreliability 的明显增加；模型一旦在早期“走错”，往往难以恢复。

教材连接：强 $p(y | x)$ 并不推出强闭环 policy。Agent 还需要稳定 state update、belief revision 与 recovery policy。

官方来源：[ICLR Outstanding Paper announcement](#)

Research Frontier | Gaia2: 静态 benchmark 为什么不足以评价 Agent?

会议身份：ICLR 2026 Oral。Gaia2 把环境设计为动态、异步：环境可以在 Agent 不行动时继续变化，任务包含时间约束、噪声事件、歧义与协作，并提供 action-level verifier。

研究意义：在静态网页或固定数据库上，policy 可以把环境当作不会变化的函数；异步环境迫使我们真正面对 $P(s_{t+1} | s_t, a_t)$ 、时间和 partial observability。

官方来源：[ICLR 2026 Oral Program](#)




图 20.1 Frontier Lab 20: 在脚本采用的 Tiger POMDP 奖励、观测准确率与折扣参数下, 中间 belief 区域由“listen”占优, 因为信息能改善后续动作选择; 修改 listen cost 或 observation accuracy 后该区域会改变。

Mini Lab | Frontier Lab 20: Belief State 与 Information Action

运行 `labs/frontier/ch20_belief_pomdp.py`。脚本用离散 belief grid 对经典 Tiger POMDP 做 value iteration。修改 observation accuracy、listen cost 与 discount factor, 观察“应该继续获取信息”的 belief 区域怎样变化。

From Textbook to Research | 下一步: 从“应该做什么”到“怎样找到那条动作序列”

MDP/POMDP 定义了最优决策问题, 但大型工具空间里无法枚举所有动作。下一章转向 planning、search、tool schema 与 replanning: Agent 怎样在有限计算预算内寻找可执行的长期计划?

20.8 Deep Dive: Policy Improvement Theorem

给定策略 π , 若新策略 π' 对所有状态满足

$$\mathbb{E}_{a \sim \pi'(\cdot|s)} Q^\pi(s, a) \geq V^\pi(s),$$

则 $V^{\pi'}(s) \geq V^\pi(s)$ 。

证明. 由条件可得

$$V^\pi(s) \leq \mathbb{E}_{a \sim \pi'}[r(s, a) + \gamma \mathbb{E}_{s'} V^\pi(s')].$$

不断将右侧的 V^π 用同样不等式展开：

$$V^\pi(s) \leq \mathbb{E}_{\pi'}[r_0 + \gamma r_1 + \cdots + \gamma^k V^\pi(s_{k+1})].$$

令 $k \rightarrow \infty$ ，由于 $\gamma < 1$ 且价值有界，末项消失，得到 $V^\pi(s) \leq V^{\pi'}(s)$ 。 $\square$

这一定理解释了“verifier-guided search”为什么可以被理解为近似 policy improvement：关键不是生成更多轨迹，而是新动作分布在旧 Q 下是否真的更优。

20.9 Deep Dive: POMDP belief MDP 的转移核

belief 本身是连续状态。给定 b, a ，观测概率为

$$P(o | b, a) = \sum_{s, s'} b(s) P(s' | s, a) O(o | s', a).$$

观察 o 后 belief 确定地更新为 $\tau(b, a, o)$ ，因此 belief-MDP 的转移其实由 observation randomness 诱导。其 Bellman 方程为

$$V(b) = \max_a \left[r(b, a) + \gamma \sum_o P(o | b, a) V(\tau(b, a, o)) \right].$$

这条式子把“记忆”“信息获取”“行动”真正统一在一起。

20.10 Deep Dive: 为什么摘要记忆会破坏 Markov 性?

设 memory compressor 为 $m_t = C(h_t)$ 。若存在两段历史 h, h' 满足 $C(h) = C(h')$ ，但对某个未来动作序列有不同的最优后果，那么 m_t 不是充分状态。形式上，若

$$P(G_{t:\infty} | h, a_{t:\infty}) \neq P(G_{t:\infty} | h', a_{t:\infty}),$$

则把二者压成同一 memory 必然产生不可恢复的信息损失。

20.10.1 Agent memory 的理论目标

因此 memory compression 的目标不是“摘要得像不像原文”，而是尽可能保留对未来价值有用的信息。一个理想目标可写成带容量约束的 predictive information bottleneck：

$$\max I(M_t; S_{t+1:\infty} | A_{t:\infty}) \quad \text{s.t.} \quad I(M_t; H_t) \leq C.$$

这为第 22 章的 memory budget 提供了理论入口。

20.11 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

本章给第 21 章 planning 与第 22 章 multi-agent / long-horizon learning 提供正式决策对象。

Worked Example | Bellman backup 手算

两状态 MDP：在 s 选择 action a 得即时奖励 1，并以 0.8 回到 s 、0.2 终止， $\gamma = 0.9$ 。若总是选 a ，

$$V(s) = 1 + 0.9 \cdot 0.8V(s), \quad V(s) = \frac{1}{1 - 0.72} \approx 3.571.$$

Bellman 方程把无限时域回报变成固定点；定理 20.1 保证在折扣条件下迭代会收敛。

Proof Clinic | Belief state 为什么足够

POMDP 的历史 $h_t = (o_{1:t}, a_{1:t-1})$ 可能无限增长，但命题 20.1 说明 posterior $b_t(s) = P(s_t = s | h_t)$ 保留了对未来决策所需的全部历史信息。在 LLM Agent 中，文本摘要只有在近似这个 sufficient statistic 时才是“好记忆”，短并不等于充分。

Research Assignment | Partial observability benchmark

实现 Tiger POMDP 后加入错误 observation、tool latency 与有限 context memory。比较 reactive policy、Bayes belief policy 和 heuristic scratchpad；报告 return 以及 belief calibration。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. 论文中的“state”是真实 world state、LLM context，还是作者定义的近似 state？
2. 环境是否满足 Markov 假设？若不满足，系统怎样维护 belief / memory？
3. benchmark 是静态、同步，还是环境会自主变化？
4. 是否测量 recovery，而不是只测最终 success？
5. 信息获取动作有没有显式成本？模型是否可能通过无限询问提高成绩？

6. policy 改善来自更强单步 LM, 还是更好的闭环 state update?

分层习题

A1 为“订一张满足预算和时间约束的机票”定义状态、动作、转移、奖励与观测。

A2 从 $G_t = r_t + \gamma G_{t+1}$ 推导 Bellman expectation equation。

A3 证明 Bellman 最优算子是 γ -contraction。

B1 推导两状态 POMDP 的 Bayes belief update。

B2 解释为什么 prompt context 一般不是 Markov state。

B3 用 occupancy measure 重写 discounted return, 并解释 on-policy 数据为什么会漂移。

C1 设计一个“询问用户 vs 直接行动”的 benchmark, 并给出 expected utility 指标。

C2 把 Frontier Lab 改成 observation model miscalibration, 观察 belief policy 如何失效。