

第 22 章 Memory、Multi-Agent 与 Agent Learning——让智能体跨时间积累能力


本章问题

最后一章讨论 Agent 真正跨越“会调用工具”的门槛之后会遇到什么：有限上下文下该记什么、忘什么？多个 Agent 同时学习时，环境为什么变得非平稳？长期稀疏 reward 怎样分配到多轮动作？以及怎样设计评价目标，避免规模化优化只学会钻 evaluator 的空子？

Prerequisite Recall | 先把这些知识唤醒

- 熟悉 belief/state、policy、trajectory credit 与 no-regret。
- 会区分模型参数、短期 context 与持久外部 memory。
- 理解多 Agent 环境中 transition 会随其他学习者策略变化。

Visual Derivation | 先看结构，再读公式



Memory 不是静态“知识库”，而是 policy 的一部分：写入、检索和遗忘都应由任务价值与预算共同决定。

Misconception Check | 本章最容易掉进去的坑

Memory 越多不一定越好。无限追加 history 会产生检索噪声、冲突、陈旧信息与 context 成本；真正的问题是写什么、保留多久、何时检索、何时更新/遗忘。

Concept Contrast 把相邻概念主动分开			
	Working	Episodic	Semantic memory
时间尺度	当前任务	过去事件	稳定抽象知识
典型操作	scratch/state	append/retrieve	consolidate/update
主要风险	溢出	相似事件干扰	陈旧/错误固化

Checkpoint | 开始正文前的 30 秒自测

为什么多 Agent 投票在错误高度相关时收益很小？**检查答案：**独立错误才能通过平均显著抵消；共享模型/数据/提示导致相关失败时，增加 Agent 数并没有增加同等数量的独立证据。

22.1 Memory 不是数据库，而是受预算约束的状态估计

把历史记作 H_t ，内部 memory 为

$$M_t = C_\phi(H_t).$$

如果可以无限保留历史，最简单方法是 append everything；但计算、延迟、隐私与干扰都要求容量约束。因此 memory learning 可以写成

$$\max_{C_\phi} \mathbb{E}[V^\pi(M_t)] \quad \text{s.t.} \quad \text{cost}(M_t) \leq B.$$

核心不是“压缩率最高”，而是在固定预算下保留最有未来决策价值的信息。

22.2 Working / Episodic / Semantic Memory 是不同统计对象

- 一个有用的 Agent memory taxonomy 是：
- **working memory**：当前 episode 的短期状态与约束；
 - **episodic memory**：过去具体轨迹 (s, a, r, o) ；
 - **semantic memory**：从许多 episode 中抽取的稳定规律、技能或事实；
 - **procedural memory**：可执行的工具、option 或 policy fragment。
- RAG 更像从 episodic/semantic store 读取；memory consolidation 则把高成本 episode 压成更短的 state 或 reusable skill。

22.3 选择性遗忘：Memory Allocation 的最小模型

假设第 i 条记忆未来被需要的概率为 p_i ，保留收益为 u_i ，存储成本为 c_i ，预算 B 。最简单的 memory selection 是 knapsack：

$$\max_{m_i \in \{0,1\}} \sum_i p_i u_i m_i \quad \text{s.t.} \quad \sum_i c_i m_i \leq B.$$

这已经说明 FIFO 不是原则，只是一个无任务信息的 heuristic。若未来 query hazard 可预测，memory 应该围绕 expected future utility 分配。

Research Frontier | MemAgent：把 memory update 本身训练成 policy

会议身份：ICLR 2026 Oral。MemAgent 分段处理长文本并以 overwrite 方式更新 memory，同时用 RL 直接优化 memory ability；论文报告从较短训练 context 外推到极长 QA / retrieval setting。

教材连接：这把“摘要器”升级成 state-update policy：每次写 memory 都是在决定什么信息继续影响未来。

官方来源：[ICLR 2026 Oral Program](#)

Research Frontier | MemoryAgentBench：Memory 不能只测 retrieval

会议身份：ICLR 2026 Conference Paper。该 benchmark 将 Agent memory 分解为多项核心能力，包括准确检索、test-time learning、长程理解以及选择性遗忘/冲突处理，并采用增量多轮交互而非一次性长文 QA。

研究意义：“记住一句旧事实”与“遇到新证据后正确更新旧 memory”是完全不同的能力。静态 RAG benchmark 无法充分评价后者。

论文入口：[arXiv](#) / [ICLR 2026 paper](#)

22.4 Agent Learning：从 token credit 回到 trajectory credit

第 18 章已有 sequence policy gradient。对工具 Agent，动作是结构化 decision，轨迹更长：

$$\nabla_{\theta} J = \mathbb{E} \left[\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | h_t) A_t \right].$$

困难来自：最终 reward 可能在几十次工具调用后才出现；早期错误会改变后续状态；不同长度轨迹的方差巨大；环境交互成本远高于离线文本。

22.5 On-policy 与 Off-policy: 复用旧经验要付什么代价?

若轨迹由行为策略 μ 采样, 却要估计目标策略 π , importance ratio 为

$$w(\tau) = \prod_t \frac{\pi(a_t | s_t)}{\mu(a_t | s_t)}.$$

于是

$$\mathbb{E}_{\tau \sim \pi}[R(\tau)] = \mathbb{E}_{\tau \sim \mu}[w(\tau)R(\tau)].$$

长 horizon 下乘积权重方差可能爆炸。这就是为什么 Agent 的 off-policy replay 虽然省环境成本, 却比静态 supervised replay 更难稳定。

Research Frontier | AgentGym-RL: Long-Horizon Agent 需要扩大真实环境交互

会议身份: ICLR 2026 Oral. AgentGym-RL 提供面向多轮真实环境的模块化训练框架, 并提出 staged long-horizon training: 从短交互逐渐扩展, 以缓解直接长 horizon RL 的训练不稳定。官方 Oral 摘要强调, 复杂 Agent 不应只依赖内部 reasoning, 还需要扩大外部 environment interaction。

教材连接: 这正对应 occupancy shift 与 exploration: 没有真实交互, 就看不到 policy 自己会进入的新状态。

官方来源: [ICLR 2026 Oral Program](#)

22.6 Multi-Agent: 当“环境”里还有别的学习者

随机博弈可写成

$$(\mathcal{S}, \mathcal{A}_1, \dots, \mathcal{A}_n, P, r_1, \dots, r_n).$$

对 Agent i 而言, 其他 Agent 的策略改变会让有效转移分布随训练变化:

$$P^{\pi_{-i}}(s' | s, a_i) = \sum_{a_{-i}} P(s' | s, a_i, a_{-i}) \pi_{-i}(a_{-i} | s).$$

因此即使物理环境固定, 学习问题也是非平稳的。

22.7 Nash、No-Regret 与 Self-Play

Nash equilibrium 要求任何单个 Agent 都无法通过单边偏离提高收益。实际训练更常用 no-regret: 若外部 regret

$$R_T = \max_a \sum_{t=1}^T r_t(a) - \sum_{t=1}^T r_t(a_t)$$

满足 $R_T/T \rightarrow 0$, 则长期平均表现不会比事后最好的固定动作差很多。在两人零和博弈中, 双方 no-regret learning 的时间平均策略会趋近 minimax equilibrium。

Research Frontier | MARS: Multi-Agent Reasoning 能否通过 Self-Play 训练?

会议身份: ICLR 2026 Conference Paper。MARS 用 cooperative / competitive strategic games 做端到端 self-play RL, 引入 turn-level 与 agent-specific advantage 处理长时域、agent-specific credit assignment, 并报告所学策略向未见游戏和多 Agent reasoning benchmark 的迁移。

研究问题: self-play 学到的是一般 social reasoning, 还是训练游戏中的策略模式? 回答它需要 held-out game、population diversity 与 exploitability 等比单一胜率更严格的测量。

论文入口: [arXiv](#) / [ICLR 2026 paper](#)

22.8 多 Agent 不自动等于更强: 相关错误会一起放大

若 n 个 Agent 独立地以概率 $p > 1/2$ 判断正确, 多数投票随 n 增大可快速提高准确率; 但实际 LLM agents 共享预训练数据、架构和提示, 错误高度相关。若相关性接近 1, 增加 Agent 数量几乎没有 ensemble gain。

因此 multi-agent debate 的核心变量不是“人数”, 而是:

diversity, independence, communication topology, incentives, verification.

22.9 Reward Hacking: 优化器会主动寻找测量漏洞

真实目标 $U(\tau)$ 往往不可直接优化, 只能使用代理 reward $\hat{R}(\tau)$ 。随着 policy 越来越强, 训练分布向

$$\arg \max_{\tau} \hat{R}(\tau)$$

移动, 恰好会进入 evaluator 最容易出错的区域。于是 reward model error 不再是随机噪声, 而是被优化过程选择的误差。

Research Frontier | ScienceAgentBench: 先测可验证科学工作流, 再谈“自动科学家”

会议身份: ICLR 2025 Conference Paper。ScienceAgentBench 从同行评议论文提取数据驱动科学任务, 把输出统一为可执行 Python 程序, 并同时评价代码、执行结果与成本。

教材连接: 研究级 Agent benchmark 应让 outcome 可验证、cost 可计量、failure 可定位, 而不是依赖 impressionistic demos。

官方来源: ICLR Proceedings




图 22.1 Frontier Lab 22A: 在固定 memory budget 下, utility-aware selective retention 明显不同于 FIFO。




图 22.2 Frontier Lab 22B: matching pennies 中 multiplicative-weights self-play 的平均外部 regret 下降。瞬时策略可持续变化, 而长期平均趋于稳定。

Mini Lab | Frontier Lab 22: Memory Allocation + No-Regret Self-Play

运行 `labs/frontier/ch22_memory_selfplay.py`。第一部分模拟未来 query hazard 不均匀时的 memory budget；第二部分在零和博弈中观察 no-regret self-play。扩展任务：让 memory utility 依赖当前 policy，或让多 Agent communication 本身有成本。

22.10 把全书重新写成一个式子

第 1 章从经验风险最小化开始：

$$\theta^* = \arg \min_{\theta} \frac{1}{n} \sum_i \ell(f_{\theta}(x_i), y_i).$$

到最后，学习对象变成闭环策略：

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\tau \sim \pi} [U(\tau) - \lambda C(\tau)]$$

其中轨迹分布由模型、工具、其他 Agent、记忆更新、环境与评价器共同决定。前 18 章学习的概率、信息、表示、优化、Attention、Scaling 和 RL，并没有被 Agent “替换”；它们在这里全部成为闭环系统的组成部分。

From Textbook to Research | 全书最后的问题：目标函数够好吗？

能力规模化最终会把优化压力施加到我们定义的一切 measurement 上。于是最深的 Agent 问题不是“还能加什么工具”，而是：**怎样构造一个可验证、可修正、在分布漂移和战略行为下仍与真实意图一致的学习目标？** 这把机器学习重新带回统计、因果、博弈、控制与科学方法本身。

22.11 Deep Dive: Memory 可以看成 Rate-Distortion 问题

历史 H 被压成有限 memory M 。若 distortion 不是文本重构误差，而是未来决策损失

$$d(h, m) = V^*(h) - V^{\pi_m}(h),$$

那么 Agent memory 的理想问题类似 task-aware rate-distortion：

$$\min I(H; M) \quad \text{s.t.} \quad \mathbb{E}[d(H, M)] \leq D.$$

这解释了为什么“更短摘要”与“更好记忆”没有单调关系；关键是被删除的信息是否影响未来最优动作。

22.12 Deep Dive: Off-policy 长轨迹的方差危机

trajectory ratio

$$w_T = \prod_{t=1}^T \rho_t, \quad \rho_t = \frac{\pi(a_t | s_t)}{\mu(a_t | s_t)}$$

取对数得到

$$\log w_T = \sum_{t=1}^T \log \rho_t.$$

即使每一步 log-ratio 方差有限, 和的方差通常随 T 增长, 因此 w_T 在原尺度上可能呈指数级 heavy tail。这就是 per-decision IS、clipping、V-trace 与 hybrid on/off-policy 方法反复出现的原因。

22.13 Deep Dive: No-Regret 为什么与 Multi-Agent equilibrium 有关?

两人零和博弈 payoff 为 $u(a, b)$ 。若双方外部 regret 都满足 $R_T^1/T \rightarrow 0$ 、 $R_T^2/T \rightarrow 0$, 记经验平均策略为 $\bar{\pi}_T, \bar{\sigma}_T$, 则

$$\max_a u(a, \bar{\sigma}_T) - o(1) \leq u_T \leq \min_b u(\bar{\pi}_T, b) + o(1),$$

其中 ν_T 是平均实际 payoff。由 minimax theorem, gap 收缩意味着经验策略逼近 minimax equilibrium。

这给 self-play 一个重要理解: 我们未必要求每一时刻的 policy 收敛; 在 rock-paper-scissors 一类博弈中, 瞬时策略可以循环, 而时间平均仍然有意义。

22.14 Deep Dive: 相关错误决定 Multi-Agent ensemble 的上限

设 $X_i \in \{0, 1\}$ 表示 Agent i 是否正确, $\mathbb{E}X_i = p$, 两两相关系数为 ρ 。总正确票数 $S = \sum_i X_i$ 的方差包含

$$\text{Var}(S) = np(1-p) + n(n-1)\rho p(1-p).$$

若 $\rho = 0$, 标准差只按 $\sqrt{n}$ 增长; 若 $\rho > 0$ 固定, 第二项是 $O(n^2)$, 多数投票的独立性优势大幅减弱。这就是为什么“复制五个同模型 Agent”不等价于五个独立专家。

22.15 Deep Dive: 从 Reward Hacking 到 Robust Evaluation

若 evaluator $\hat{R} = U + \epsilon$, 普通泛化分析关注平均 ϵ ; 优化 Agent 更关心条件误差

$$\mathbb{E}[\epsilon(\tau) \mid \tau \text{ 被 policy 高概率选择}].$$

选择机制会让这个量产生偏差。更稳健的评测因此需要隐藏测试、随机审计、多 evaluator、过程约束和 distribution shift。真正困难的是 evaluator 也必须随 Agent 能力共同升级。

22.16 Proof & Worked Example Clinic

Dependency Check | 先修与跨章连接

本章是全书收束：memory 对应信息压缩，multi-agent 对应博弈，Agent learning 对应长时域 policy optimization。

Worked Example | Memory 是有预算的状态压缩

设历史 H_t 被压缩为 memory M_t , 预算约束 $I(H_t; M_t) \leq B$ 。理想 memory policy 想在有限 bit/token 预算下最大化与未来回报相关的信息 $I(M_t; G_t)$ 。这与 rate-distortion 的精神相同：不是保存最多，而是保存对未来决策最有价值的东西。

Proof Clinic | No-regret 如何连接多智能体稳定性

两玩家零和重复博弈中，若双方平均 regret 都趋于 0，则时间平均策略逼近 min-max/Nash 集。直觉是：任何一方都不能回头说“如果始终换成另一个固定策略会显著更好”。这给 self-play 一个比单次胜率更稳定的理论目标，但一般和非零和 Agent 仍更复杂。

Research Assignment | 长期 Agent 的失败账本

在带 memory budget 的多轮环境中比较 FIFO、similarity memory 与 value-aware memory；再加入 self-play learner。必须同时报告任务回报、memory hit/usefulness、regret proxy、reward hacking incidents 与 catastrophic forgetting。

最低交付：1 页假设与指标声明；可复现代码与固定 seed；主结果图；至少一个失败/反例；200–400 字结论边界。**禁止：**只报告最好一次 run、只给截图、把 mechanism-level reproduction 表述为 paper-scale replication。

研究阅读与复现检查表

1. memory 方法优化的是 storage、retrieval, 还是 downstream decision value?
2. benchmark 是否包含更新、冲突和遗忘, 而不只是静态 recall?
3. Agent RL 的数据是 on-policy、off-policy 还是混合? 长 horizon 校正如何做?
4. multi-agent 提升是否控制了额外 token / compute / model calls?
5. 多 Agent 的错误相关性是否被测量? 是否报告 exploitability 或 held-out opponents?
6. reward / verifier 是否可能被 policy exploit? 有没有 hidden evaluator 或 adversarial audit?
7. 论文声称“自主科学发现”时, 哪些子任务有独立可验证 ground truth?

分层习题

- A1** 将 memory selection 写成 0-1 knapsack, 并解释 FIFO 对应什么隐含假设。
- A2** 推导 off-policy trajectory importance ratio。
- A3** 说明长 horizon 下 importance sampling 方差为什么容易爆炸。
- B1** 写出两人零和 stochastic game 的定义, 并说明为什么独立 Q-learning 面临非平稳环境。
- B2** 证明 matching pennies 的唯一 Nash equilibrium 是双方各以 1/2 随机化。
- B3** 给出 reward hacking 的最小 MDP, 使 proxy-optimal policy 与 true-utility-optimal policy 不同。
- C1** 设计一个 memory benchmark, 同时测 retrieval、update、conflict resolution、forgetting 和 cost。
- C2** 设计一个 multi-agent benchmark, 报告 exploitability / diversity, 而不仅是平均胜率。
- C3** 为一个“科学 Agent”设计 evaluation contract: 哪些 outcome 可以自动验证? 哪些必须人工审计?